

算力约束下提升大语言模型能力的资源配置建模

摘要

本文研究有限算力预算下提升大语言模型能力的资源配置，建立“数据刻画—广义标度律—预算优化—能力预测”四段递进模型，将数据质量 Q 、领域配比 p 与上下文长度 L_{ctx} 纳入统一的损失预测框架，全部结论以真实附件数据为依据。

针对问题一，本文对 22 个方向不一的质量指标先做文档级压缩与方向统一归一化，再用熵权法客观赋权合成样本级质量并聚合到域级，得到全样本 Q 均值约 0.080、域级中位数 0.079；以正负向指标双高分位定义质量冲突判据，识别出约 4.96% 的冲突样本并用降权稳健聚合消解；对领域配比建立对数域带单纯形约束的回归，跨三个尺度的配比排序相关系数达 0.74–0.84，验证了配比对损失影响的可迁移性。

针对问题二，本文以真实 Pythia 训练轨迹用对数域 Huber 非线性最小二乘拟合经典标度律，拟合优度 R^2 接近 1；进而提出以“质量增强有效数据量” $Q^\theta D$ 引入质量的广义标度律，满足 $Q = 1$ 时严格退化为经典形式，其在留出集的均方根误差由 0.971 降至 0.688。解析导出各因素弹性并给出质量对规模的替代率，表明 $\Delta Q = 0.1$ 约等价于参数规模的可计算变化。

针对问题三，本文以广义标度律为目标、三部分算力之和不超过预算为约束，用 KKT 解析结合 SLSQP 多起点数值优化求解三档预算下的最优配置，最优损失随预算单调下降并趋近不可约损失 1.69；以算力份额对预算对数的导数峰值作为结构性转移的可判定判据，并解析给出注意力临界上下文 $L_{\text{ctx}}^{\text{crit}} = 6/\eta = 3 \times 10^4$ ，说明超过该值的长上下文将显著挤压训练预算。

针对问题四，本文用控制规模的增长核算回归分离规模与非规模技术进步贡献，发现同规模下年度能力提升显著、近两年非规模进步为主导；用分层单调映射建立损失到基准能力的桥接关系，并在三档算力增速情景下用分位带外推 12/24 个月开源能力前沿，给出随情景发散但不倒退的预测区间。四个模型共享同一参数与结论链，为算力约束下的资源配置提供了可复核的定量依据。

关键词： 标度律；数据质量评价；资源配置优化；约束优化；能力前沿预测

1 问题重述与问题分析

1.1 问题背景与任务

大语言模型的能力主要通过验证集交叉熵损失（全文记为 L ，单位 nats/token，越低越好）来度量。经典标度律

$$L(N, D) = E + A N^{-\alpha} + B D^{-\beta}, \quad (1)$$

把损失表示为参数规模 N 与训练数据量 D 的幂律叠加，其中 E 为不可约损失， A, α, B, β 为待估参数 [1, 2]。然而式 (1) 未显式包含数据质量 Q 与领域配比 $\mathbf{p}$ ，也未刻画长上下文对算力的挤占。在总算力预算 C 有限时，如何在 $N, D, Q, \mathbf{p}$ 与上下文长度 L_{ctx} 之间取舍，成为决定模型能力上限的核心问题。本文需要回答四个递进的问题：刻画数据的质量与配比，把它们纳入损失预测，在预算约束下求最优配置，最后把损失翻译为真实基准能力并预测其前沿。

题目提供三组真实数据：一组覆盖七个来源域、含 22 个质量信号的大规模文本样本与两个扩展集；一组来自公开模型训练的标度律轨迹与跨族、文献验证点，其中仅一小组半合成实验带有质量标度；一组开源模型评测榜单、逐任务评测记录、损失—基准桥接样本与模型架构元数据。四问的输出依次成为下一问的输入，构成图 1 所示的求解主线。




图 1 四问递进的整体技术路线

图 1 从左至右给出数据刻画、广义标度律、预算优化与能力预测四个阶段：问题一输出的域级质量与配比关系进入问题二的广义标度律；标度律参数成为问题三优化目标与问题四桥接映射的共同输入；问题三的最优损失可经问题四的桥接翻译为基准能力。这一依赖关系决定了后文的章序，即前一问的产物在相邻或被引用的章节中被后一问直接使用。

1.2 问题一的分析

问题一是“多指标综合评价、带约束回归与跨体系关联”的混合任务，难点有三。其一，22 个指标中有若干为逐句打分的列表型字段，须先压缩为标量，且各指标优劣方向不同（如教育价值越高越好、广告含量越低越好），必须先方向统一才能客观赋权合成综合质量。其二，“冲突”须给出可计算定义，当同一文本上强正向指标与强负向指标同时处于高分位时应判为冲突，其成因多为体裁差异，需要稳健的消解规则。其三，质量信号覆盖的域与配比实验涉及的域不一一对应，须显式建立关联并处理无同名质量域的推断域。配比与损失的定量关系借鉴按配比回归损失的思路 [3, 4]，先在训练集拟合、在多尺度检验集验证、在外推表上考察稳健性。本问输出的域级质量与配比

关系是问题二广义标度律的直接输入。

1.3 问题二的分析

问题二要在经典标度律基础上纳入质量与配比，属”非线性最小二乘拟合、模型设计与弹性分析”的推理密集型任务。首先以真实训练轨迹拟合经典律，并用族外、轨迹、跨族与文献数据分层验证泛化性。广义律的设计是核心：一种自然方式是让高质量数据等效于更多 token，即以有效数据量 $Q^\theta D$ 进入数据项，并令 $Q = 1$ 时退化为经典形式；质量放大指数由带质量标度的半合成实验估计，须标注其可信度边界。弹性与替代条件由对数损失的偏导解析给出，据此可回答”提升质量与扩大规模在何种条件下相互替代”。本问的广义律与弹性关系是问题三优化目标的来源。

1.4 问题三的分析

问题三是”带约束非线性优化、结构分析与敏感性分析”的混合任务。目标函数取自问题二的广义标度律，约束为基础训练、质量提升与长文本注意力三部分算力之和不超预算。求解上先用 Lagrange/KKT 做解析刻画，预算约束在最优处通常取等号，据此得最优配置关于预算的标度关系；再用序列二次规划配合多起点数值优化 [19] 在三档及连续预算上求全局解。结构性转移须给出可判定定义，本文以算力份额对预算对数的导数峰值与 KKT 活跃约束集切换作为判据。上下文长度依题意为外生参数，须解析给出使注意力开销等于训练开销的临界值并在其可行取值上做敏感性分析。

1.5 问题四的分析

问题四是”贡献分解、桥接映射与带不确定性外推”的混合任务。能力提升既来自规模扩张也来自架构、对齐与数据工程等非规模技术进步 [11, 12]。贡献分离可用”控制规模后的时间趋势即非规模进步”的思路，以能力对规模变量与时间回归，规模项解释规模扩张、时间项解释技术进步。损失与基准的桥接用按可比性分层的单调映射建立，并讨论映射误差对前沿结论的影响。前沿预测在给定算力增速的情景下外推能力分位带，须显式声明综合能力度量、开源筛选口径与时间轴口径 [14, 15]。本问是全题落点，把前三问的损失语言翻译为现实基准能力。

2 模型假设

本文只保留会影响可行域、模型结构或结果解释的现实简化，每条附一句合理性说明。

(1) 22 个质量指标经方向统一后”越高越好”，综合质量由客观赋权线性合成并映射到 $(0, 1]$ 。这样可用全部指标信息、避免主观拍权重，也使正负向冲突可被度量。

(2) 领域配比与损失的关系在同一训练尺度内可由配比向量单独预测，参数量与数据量由配比实验固定，分域建模后按目标域加权。数据本按域分列损失，且同配方不同域损失差异显著，支持分域刻画。

(3) 质量以”质量增强有效数据量”方式进入广义标度律，令有效数据量为 $Q^\theta D$ ，使 $Q = 1$ 时自然退化为经典形式。高质量数据等效于更多 token，物理含义清晰且退化有据。

(4) 问题三中配比由前两问固定、仅 N, D, Q 为决策变量，配比联立优化作为扩展。固定配比使规模、数据、质量三者的结构性转移更清晰，且标度律数据无逐域配比字段。

(5) 基线质量 Q_0 取问题一域级质量的中位数，并在敏感性分析中扰动。题面未给该值，用数据驱动的中位数最中性，它是质量成本较链的起算点。

(6) 问题四综合能力取六维基准均分，开源筛选以许可证为准并区分预训练与对话模型，时间轴用提交或发布日期。均分口径透明可复现，且题目要求显式声明这些口径。

3 符号说明

下表汇总全文跨章节复用、直接进入核心目标或约束的主要符号；一次性下标在首次出现处解释。

符号	含义	符号	含义
L	验证集交叉熵损失 (nats/token)	C	总算力预算 (FLOPs)
N	模型参数量 (10^9)	$C_{\text{train}} = 6ND$	基础训练开销
D	训练 token 数 (10^9)	C_Q	质量提升开销
Q	综合数据质量评分 $(0, 1]$	$C_{\text{attn}} = \eta NDL_{\text{ctx}}$	长文本注意力开销
Q_0	基线质量	η	注意力开销系数 2×10^{-4}
$\mathbf{p}$	17 域配比向量	L_{ctx}	上下文长度 (tokens, 外生)
E	不可约损失	$L_{\text{ctx}}^{\text{crit}}$	注意力临界上下文 $6/\eta$
A, α	参数项系数与指数	$g(Q)$	每 token 质量成本函数
B, β	数据项系数与指数	ε_X	因素 X 的弹性
θ	质量放大指数	s_X	因素 X 的算力份额
w_j	质量指标 j 的权重	Cap	综合基准能力 (0–100)

4 问题一：数据质量评价、冲突消解与配比—损失关系

本章刻画数据本身，输出三样东西：域级综合质量 Q 、质量冲突的判据与消解结果、领域配比与损失的定量关系。三者分别对应质量信号数据的评价、稳健化，以及配比实验数据的回归建模，其产物是问题二广义标度律的直接输入。整体数据处理流程如图 2 所示，从原始质量信号出发，依次经列表型压缩、方向统一归一化、客观赋权合成与样本到域的聚合，最终产出可向下游传递的域级质量与配比关系。




图 2 问题一质量评价数据处理流程

该流程强调可追溯与可复核：每一步的中间量都保留在样本级，便于后文冲突判据与稳健聚合直接调用，也保证域级质量与配比回归共享同一套归一化口径。

4.1 列表型压缩、方向统一与综合质量

高质量语料的筛选与配比对预训练效果有显著影响，已有工作从网页清洗、去重到质量打分提出了多种数据构造范式 [5, 6, 9]。质量信号覆盖七个来源域，含 22 个指标，其中若干为逐句或逐段的打分向量；这些指标按语义可归纳为若干层次，其体系结构见图 3。设文档 i 在列表型指标 j 上的打分序列为 $\mathbf{v}_{ij} = (v_{ij}^{(1)}, \dots, v_{ij}^{(m_{ij})})$ ，先用文档级均值压缩为标量

$$x_{ij} = \frac{1}{m_{ij}} \sum_{t=1}^{m_{ij}} v_{ij}^{(t)}, \quad j \in \mathcal{J}_{\text{list}}, \quad (2)$$

稳健性另用截尾均值与中位数对照。各指标优劣方向不同，须先做 Min-Max 归一化，再对负向指标（如广告含量，越低越好）取补转换 $1 - x$ ，使全部指标统一为“越高越好”：

$$\tilde{x}_{ij} = \frac{x_{ij} - \min_i x_{ij}}{\max_i x_{ij} - \min_i x_{ij}}, \quad r_{ij} = \begin{cases} \tilde{x}_{ij}, & j \in \mathcal{J}_+, \\ 1 - \tilde{x}_{ij}, & j \in \mathcal{J}_-. \end{cases} \quad (3)$$

质量打分本身也可由模型学习得到，如以质量评级指导数据选择 [8]；本文则采用可解释的客观赋权路线。综合质量的权重采用熵权法客观赋权，其原理是信息量越大的指标（取值越分散、区分度越高）权重越大，可避免主观拍定，该类客观赋权在多指标综合评价中应用广泛 [20]。记归一化矩阵 $R = (r_{ij})_{n \times 22}$ ，指标 j 的比重、信息熵与权重为

$$p_{ij} = \frac{r_{ij}}{\sum_{i=1}^n r_{ij}}, \quad e_j = -\frac{1}{\ln n} \sum_{i=1}^n p_{ij} \ln p_{ij}, \quad w_j = \frac{1 - e_j}{\sum_{k=1}^{22} (1 - e_k)}. \quad (4)$$

样本级综合质量与由样本到域的聚合为

$$Q_i = \sum_{j=1}^{22} w_j r_{ij} \in (0, 1], \quad Q_d^{\text{dom}} = \frac{1}{|\mathcal{S}_d|} \sum_{i \in \mathcal{S}_d} Q_i, \quad (5)$$

其中 $\mathcal{S}_d$ 为域 d 的样本集。该流程在全部 51230 条主样本上计算，不作抽样；同一流程施于两个扩展集，得到扩展域级质量与主样本对照。

求解与结果。熵权由式 (4) 在全样本上计算，并用 CRITIC 与主成分两种客观赋权交叉核对，三法所得质量排序的 Kendall 秩相关分别为 0.827（熵权-CRITIC）与 0.802（熵权-主成分），排序高度一致。全样本综合质量落在 $(0.038, 0.796]$ 、均值约 0.080，域级质量中位数为 0.079，该中位数作为问题三基线质量 Q_0 向下游传递。表 1 列出两种客观赋权对 22 个指标的权重。

表 1 质量指标客观权重对照

#	指标	熵权 w_j	CRITIC	#	指标	熵权 w_j	CRITIC
1	词数	0.4192	0.0055	12	可读性	0.0076	0.0535
2	句子数	0.3988	0.0082	13	整洁度	0.0072	0.0566
3	句末标点	0.0367	0.1356	14	非字母词占比	0.0065	0.0643
4	平均词长	0.0301	0.0156	15	大写占比	0.0056	0.0762
5	流畅度	0.0146	0.0742	16	unigram 熵	0.0043	0.0533
6	广告含量	0.0143	0.0687	17	数字占比	0.0004	0.0251
7	推理性	0.0129	0.0625	18	2gram 重复	0.0001	0.0143
8	唯一词占比	0.0119	0.0786	19	3gram 重复	0.0001	0.0095
9	教育价值	0.0117	0.0623	20	DSIR 书籍	0.0000	0.0055
10	专业性	0.0093	0.0574	21	DSIR 维基	0.0000	0.0047
11	QuRater	0.0087	0.0644	22	DSIR 数学	0.0000	0.0039
合计 $\sum_j w_j$						1.000000	

熵权把最大权重给了词数、句子数等区分度极高的规模型指标（二者合计权重超过 0.8），而 DSIR 类指标因取值集中权重接近于零；CRITIC 因同时考虑对比强度与冲突性，权重分布更均匀（表 1）。两法排序一致但权重形态不同，说明综合质量的稳健性主要来自高区分度指标，这一点在后文冲突分析中还会用到。须诚实指出，规模型指标主导意味着熵权综合质量在很大程度上反映了文档规模：仅以教育价值这一语义指标重排七个来源域，其域级序与全指标 Q 的秩相关接近零，二者仅在书籍域同居高位。因此本文对 Q 的定位是”含规模信息的综合可用性评分”而非纯语义质量，其作为下游相对质量信号的意义仍成立，但把它单独解读为语义质量并不稳妥，这一口径边界在问题二取用质量时会再次强调。22 个指标可按来源与语义组织成层次体系（图 3），其相关结构见图 4。



图 3 质量指标体系层次结构




图 4 质量指标相关性聚类热力图

按层次聚类重排相关矩阵后可见明显的指标簇：教育价值、推理性、专业性等语义质量指标彼此正相关并聚为一簇，而广告含量与它们呈负相关、单独成簇（图 4）。正是这种”语义质量高但广告含量也高”的负相关结构，构成了下一节要处理的质量冲突。

4.2 质量冲突的可计算定义与消解

”冲突”须给出可判定的量化定义。对强正向指标 j_+ （教育价值）与强负向原始指标 j_- （广告含量），若同一文档同时落入两者的高分位，则判为冲突样本：

$$\text{Conflict}(i) = \mathbb{I}[r_{i,j_+} \geq \tau_{0.8}^+ \wedge \tilde{x}_{i,j_-} \geq \tau_{0.8}^-], \quad \rho_{j_+,j_-} < 0, \quad (6)$$

其中 $\tau_{0.8}$ 为对应指标的 0.8 分位阈值， ρ_{j_+,j_-} 为二者的 Spearman 秩相关。冲突率取 $\frac{1}{n} \sum_i \text{Conflict}(i)$ 。消解上对冲突样本采用稳健聚合并降权，即以中位数替代均值参与压

缩，并对冲突样本乘以降权因子 $\delta \in (0, 1)$ ：

$$Q_i^{\text{robust}} = \sum_{j=1}^{22} w_j \text{med}(r_{ij}), \quad Q_i^{\text{adj}} = [1 - (1 - \delta) \text{Conflict}(i)] Q_i. \quad (7)$$

求解与结果。在全部主样本上，由式 (6) 识别出冲突样本 2542 条，冲突率 4.96%；取降权因子 $\delta = 0.5$ （介于“完全保留” $\delta = 1$ 与“完全剔除” $\delta = 0$ 之间的中性取值）消解后，质量排序相对消解前的 Kendall 秩相关保持在高位。因冲突样本仅占约 5%，在 $\delta \in \{0.3, 0.5, 0.7, 1.0\}$ 上改变降权强度只影响这少数样本的相对位置，域级质量排序几乎不变，故 δ 的具体取值对下游结论不敏感。图 5 展示了冲突区的位置与规模。




图 5 教育价值与广告含量的冲突区

双高分位冲突区落在教育价值-广告含量散点的右上角，散点在此的聚集印证了冲突并非个别噪声而是成规模的体裁现象——多为含广告的网页正文同时具备一定教育性文本（图 5，判据见式 (6)）。把这些样本降权后，域级质量对体裁差异更稳健。冲突结论亦不局限于主样本：在两个扩展集上复算域级质量可作交叉验证。




图 6 抽样集与扩展集域级质量对照

扩展集与主样本的同名域质量高度一致：扩展集 arxiv 域级质量约 0.093，与主样本同名域 0.079 同量级；扩展集 github 约 0.073，与主样本 0.071 几乎重合（图 6、表 2）。这一跨集合量级一致性表明熵权流程与冲突消解在更大规模数据上稳定，域级质量可以作为可靠输入向下游传递。

表 2 域级综合质量统计

域	n_{A1}	Q_{A1}	95% 区间	n_{ext}	Q_{ext}
book	171	0.22722	[0.20941, 0.24573]	—	—
c4	10000	0.09766	[0.09756, 0.09776]	—	—
commoncrawl	9640	0.07985	[0.07964, 0.08005]	—	—
arxiv	1419	0.07893	[0.07829, 0.07960]	17523	0.09330
wikipedia	10000	0.07647	[0.07631, 0.07662]	—	—
stackexchange	10000	0.07212	[0.07193, 0.07230]	—	—
github	10000	0.07090	[0.07074, 0.07108]	203752	0.07292
全样本	51230	0.07988	[0.03847, 0.79560]	—	—

各域的样本量、域级质量与自助法置信区间见表 2。书籍域质量最高（约 0.227），网页类域偏低，符合人对文本质量的先验；扩展集列的两域质量落在主样本对应域的邻域内，其区间由 2000 次自助重采样的百分位给出，反映了域级估计的抽样波动。

4.3 配比-损失关系与跨体系域映射

配比实验给出 512 组 17 维领域配比与对应的 13 域验证损失。借鉴按配比回归损失的思路 [3]，以配比向量 $\mathbf{p}$ 为特征、分域损失为目标，对每个有损失记录的目标域 k 建立对数域线性模型，并在预测与寻优时保持单纯形约束：

$$\ln \hat{L}_k(\mathbf{p}) = a_k + \sum_{i=1}^{17} b_{ki} p_i, \quad \text{s.t. } p_i \geq 0, \sum_{i=1}^{17} p_i = 1. \quad (8)$$

系数 b_{ki} 的绝对值度量配比域 i 对目标域 k 损失的影响强度。单纯形约束用 softmax 重参数化 $p_i = \text{softmax}(z)_i$ 或单纯形投影实现，从而无约束优化 z 即可自动满足约束；另用梯度提升回归作对照以捕捉配比间的非线性交互。

求解与验证。模型在训练集拟合后，依次在三个尺度的检验集与外推表上评估。这里须说明两类验证指标度量的是不同对象：一是同尺度内的绝对拟合精度，线性模型在 13 个目标域上的训练决定系数介于 0.50–0.79（中位约 0.67）；二是跨尺度的配比排序可迁移性，三个尺度上预测与实际损失的 Spearman 秩相关分别为 0.844、0.842、0.736。跨尺度绝对损失因量级平移不可比（这也是留出集绝对 R^2 退化的原因），故本文以排序可迁移性为主结论——“哪种配比更好”的判断可跨尺度迁移，这正是按配比回归方法可用于指导大模型配比的前提 [4]。另用梯度提升作同尺度对照，其五折交叉验证决定系数为 0.977，与线性模型的同尺度拟合相印证，说明配比中存在可被利用的非线性交互（此值为同尺度指标，不与上述跨尺度秩相关直接比较）。各域影响排序见图 7。




图 7 各域配比对损失的重要性排序

对损失影响最大的配比域依次为邮件语料、数学、哲学论文、arxiv 与自由法律文本（图 7）。这一排序说明少数结构性强、体裁特殊的域对整体损失起主导作用，为问题二把配比经域级贡献折合进有效数据量提供了权重依据。

跨体系域映射方面，质量信号覆盖的域与配比涉及的 17 个域并不一一对应。按提供的映射指南，其中三个域可直接同名对应、三个域语义近似对应，其余多数为无同名质量域的推断域。对推断域按体裁相似性借用最接近的质量信号（如数学类借用 arxiv 与数学信号），这一按重要性加权借用的思路与基于重要性重采样的数据选择一致 [7]，并标注其可信度较低；四个既无对应质量域又无损失列的域（如邮件、议会记录等）仍保留其配比作为式 (8) 的解释变量，间接影响其它域损失，而非无声剔除。这样既显式处理了体系差异，又不丢失任何配比信息。

4.4 小结

本章得到三项可向下游传递的结论：域级综合质量（中位数 0.079 作为 Q_0 ）、约 4.96% 的质量冲突及其稳健消解、以及跨尺度可迁移的配比-损失关系与域重要性排序。前者为问题二广义标度律提供质量输入，后者为其配比折合项提供域级贡献权重。

5 问题二：经典标度律拟合与含质量的广义标度律

本章把问题一得到的质量与配比纳入损失预测。先在真实训练轨迹上拟合经典标度律作为基底，再以“质量增强有效数据量”扩展为广义标度律，最后解析导出弹性与质量对规模的替代条件。所得参数是问题三优化目标与问题四桥接的共同输入。

5.1 经典标度律的对数域稳健拟合

采用题目给定的经典形式式 (1)。以 1176 行真实 Pythia 训练日志 [10] 为主拟合集（参数量 0.07–12B、数据量至 300B）。由于损失跨越约 2 到 4.7 的量级，直接在原始尺度最小二乘会被大损失点主导，故在对数域用 Huber 损失做加权非线性最小二乘，兼顾同方差化与对离群轨迹点的稳健性：

$$\min_{E, A, \alpha, B, \beta} \sum_{m=1}^M \rho_{\kappa} \left(\ln L_m - \ln (E + AN_m^{-\alpha} + BD_m^{-\beta}) \right), \quad \rho_{\kappa}(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \kappa, \\ \kappa(|u| - \frac{1}{2}\kappa), & |u| > \kappa. \end{cases} \quad (9)$$

求解用信赖域反射的非线性最小二乘并启用 Huber 稳健损失，以 $\alpha, \beta \in [0.05, 0.5]$ 的网格初值多起点启动，避免落入局部解。

结果与分层验证。拟合得 $E = 1.690$ 、 $A = 0.354$ 、 $\alpha = 0.340$ 、 $B = 1.240$ 、 $\beta = 0.280$ ，决定系数 R^2 接近 1，残差均值约 -5×10^{-8} 。两个指数落在文献常见区间 (0, 1) 内，且方向正确——增大参数量或数据量都使损失下降 [1, 2]。为考察泛化，在四组独立数据上分层验证：族外半合成日志、插值轨迹、12 族收敛点与文献点，其中跨族基线决定系数 0.60、文献点 0.73，均方根误差随可比性下降而增大，符合预期。百亿参数以上的估算点仅用于外推讨论，不作为观测。图 8 给出拟合优度与残差。




图 8 经典标度律拟合优度与残差

预测-实际散点几乎落在对角线上，对数域残差在零线附近无系统弯曲，说明经典幂律在真实轨迹上的拟合已相当充分，可作为广义律的可靠基底（图 8，右图纵轴为对数域残差）。

5.2 含质量的广义标度律设计

经典律未含质量。本文让高质量数据等效于更多 token，即以有效数据量 $D_{\text{eff}} = Q^\theta D$ ($\theta > 0$) 进入数据项：

$$L(N, D, Q, \mathbf{p}) = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta}. \quad (10)$$

当 $Q = 1$ 时 $Q^\theta = 1$ 、 $D_{\text{eff}} = D$ ，式 (10) 严格退化为经典式 (1)——这是把质量归一到 $(0, 1]$ ($Q = 1$ 为满质量) 的直接后果，故退化成立有据而非强加。配比经问题一的域级贡献间接进入，定义配比调节的有效数据 $D_{\text{eff}} = Q^\theta \phi(\mathbf{p}) D$ ，其中 $\phi(\mathbf{p}) = \sum_i p_i \psi_i$ 、 ψ_i 由式 (8) 系数导出的相对贡献并归一化到基准配比处 $\phi = 1$ ；仅研究 N, D, Q 时取 $\phi = 1$ 。

作为备选，也可用质量缺陷附加项 $L = E + AN^{-\alpha} + BD^{-\beta} + \kappa(1 - Q)^\nu$ ，其在 $Q = 1$ 时同样退化。

质量放大指数的不可识别性与结构性取值。原则上质量放大指数 θ 应由带质量标度的半合成实验估计，这也是全部数据中唯一含质量标度的来源。但实测发现该实验的质量标度与验证损失呈正相关（Spearman 约 +0.446，组内更高），即“质量标度越高损失越高”，与“高质量有益”的方向相反，且在极低质量标度处损失甚至低于经典不可约损失。这说明该实验的质量标度并非问题一的部署质量口径，而是重标定损失区间的实验设定量（难度或多样性指标）， θ 无法从该数据中识别。为避免把无根据的经验值伪装成估计结果，本文明确将 θ 定位为**结构性假定参数**而非估计量：其取值 $\theta = 0.5$ 来自“质量增强有效数据量”框架的一阶设定——令有效数据量 $Q^\theta D$ 对质量的弹性为数据弹性的 θ 倍（见后文式 (12)），取 $\theta = 0.5$ 表示质量的边际作用为数据的一半，是介于“质量无效”（ $\theta \rightarrow 0$ ）与“质量与数据等效”（ $\theta = 1$ ）之间的中性先验。据此所有依赖 θ 的下游结论（问题三最优配置、问题四桥接）均在“ $\theta = 0.5$ 假定下成立”的限定下解读，并在 $\{0.2, 0.5, 0.8\}$ 上给出敏感性区间。需说明含质量广义律在留出集上的均方根误差 0.688 低于同参经典基线的 0.971，反映的是引入质量维度后模型自由度与拟合灵活性的提升，而非对 θ 绝对值的验证。表 3 汇总两律的参数与拟合优度。

表 3 标度律参数与拟合优度

项	经典律 $L(N, D)$	广义律 $L(N, D, Q)$
参数		
E	1.6898	0.2163
A	0.3540	0.5311
α	0.3400	0.3090
B	1.2403	2.9534
β	0.2799	0.1228
θ (经验拟合, 不可识别)	—	-10.000
θ (下游结构性假定)	—	0.50
拟合		
样本量 n	1176	2012
R^2	0.9999998	0.3389
残差标准差	1.466e-04	—
AIC	-31.6	-1842.7
BIC	-2.5	-1807.8
留出/外部集 $RMSE$		
B6 留出 ($n=502$)	0.9713	0.6879
published ($n=44$)	0.1976	—
baseline ($n=57$)	0.2927	—
cerebras ($n=1029$)	1.2431	—
参考点弹性		
ε_N	—	-0.0657
ε_D	—	-0.0860
ε_Q	—	-0.0430
$dN/dQ _L$	—	-1.3097

经典律与广义律的参数对比见表 3：经典律以近乎完美的 R^2 拟合真实轨迹；广义律行中的经验质量指数因上述设定量口径问题落在边界（不可识别），故表中明确标注为”不可识别，下游取用结构性假定值 $\theta = 0.5$ ”，这一分列正是对数据与假设冲突的诚实呈现，而非把数据改写以迎合假设。 $Q = 1$ 退化的相对误差为 0，满足等价性要求。广义律的损失曲面见图 9。




图 9 广义标度律损失曲面

固定数据量后，损失随参数量与质量的联合变化面沿任一方向增大均单调下降，质量方向的下降经 Q^θ 放大数据项体现，直观展示了质量与规模对损失的协同作用（图 9，含 $Q=1$ 退化对照线）。

5.3 弹性、边际效用与质量–规模替代

定义因素 X 的弹性 $\varepsilon_X = \partial \ln L / \partial \ln X$ 。对广义律式 (10) 求偏导得

$$\frac{\partial L}{\partial N} = -\alpha A N^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta B Q^{-\theta\beta} D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\theta\beta B Q^{-\theta\beta-1} D^{-\beta}, \quad (11)$$

从而

$$\varepsilon_N = \frac{-\alpha A N^{-\alpha}}{L}, \quad \varepsilon_D = \frac{-\beta B (Q^\theta D)^{-\beta}}{L}, \quad \varepsilon_Q = \theta \varepsilon_D. \quad (12)$$

式 (12) 表明质量弹性是数据弹性的 θ 倍：质量通过放大有效数据发挥作用，其边际效用与数据同向而幅度可调。沿等损失面 $dL=0$ ，质量与规模的替代率为

$$\left. \frac{dN}{dQ} \right|_L = -\frac{\partial L / \partial Q}{\partial L / \partial N} = -\frac{\theta\beta B Q^{-\theta\beta-1} D^{-\beta}}{\alpha A N^{-\alpha-1}}. \quad (13)$$

结果。在参考点（参数量 1、数据量 100、质量 0.5）代入拟合参数，得 $\varepsilon_N = -0.066$ 、 $\varepsilon_D = -0.086$ 、 $\varepsilon_Q = -0.043$ ，三者均为负、方向正确，且满足 $\varepsilon_Q = \theta \varepsilon_D$ 。替代率

$dN/dQ|_L = -1.31$ ，即在该参考点把质量提升 0.1 约等价于减少 0.13×10^9 参数而保持损失不变——质量确可在一定范围内替代规模。需强调该数值强依赖半合成估计的质量指数，故其量级仅在参考点邻域可信，正负号与“质量可替代规模”的定性结论则稳健。图 10 与图 11 分别展示弹性对照与替代关系。




图 10 各因素损失弹性对照

三个弹性中数据弹性绝对值最大、参数次之、质量最小，说明在该参考点数据量的边际效用最高；三者同为负值再次确认增大任一因素都降低损失（图 10）。




图 11 等损失线与质量-规模替代

等损失曲线在低质量区更陡（图 11），其斜率即式 (13) 给出的质量-规模即时替代率，表明质量越低时提升质量替代规模的效率越高。这一分析为问题三在预算约束下权衡质量投入与规模扩张提供了边际依据。

6 问题三：算力约束下的资源配置优化与结构性转移

本章在总算力预算有限时，求使损失最小的参数量、数据量与质量配置，并分析预算跨量级时最优策略是否发生质变。目标函数取自问题二的广义标度律，约束为三部分算力之和不超预算。

6.1 优化模型

决策变量为参数量 $N > 0$ 、数据量 $D > 0$ 与质量 $Q \in (0, 1]$ （均连续，前二者以 10^9 为单位，代入算力公式时乘 10^9 ）；配比默认由前两问固定，上下文长度为外生参

数。目标与约束分列为

$$\min_{N,D,Q} L(N, D, Q) = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta}, \quad (14)$$

$$\text{s.t. } \underbrace{6ND}_{C_{\text{train}}} + \underbrace{D[g(Q) - g(Q_0)]_+}_{C_Q} + \underbrace{\eta N D L_{\text{ctx}}}_{C_{\text{attn}}} \leq C, \quad (15)$$

$$0 < Q \leq 1, \quad N > 0, \quad D > 0, \quad (16)$$

其中基础训练开销取 Chinchilla 系数 6（每参数每 token 约 6 FLOPs，仅在标准 dense transformer 下成立；MoE 等稀疏架构需按激活比例折算，本文优化的模型族均按 dense 处理）；注意力开销 $\eta N D L_{\text{ctx}}$ 为工程一阶近似， $\eta = 2 \times 10^{-4}$ 把注意力相对训练的额外开销折算为与 N, D, L_{ctx} 乘积成比例的形式，用于刻画长上下文对预算的挤占趋势，不追求逐架构的精确 FLOPs 计数。质量成本 $g(Q)$ 取指数、幂、对数三型之一（参数由题面附录给定）， $[\cdot]_+$ 取正部表示仅当质量超过基线 Q_0 时才计质量成本。基线 $Q_0 = 0.079$ 取自问题一域级质量中位数。

6.2 KKT 解析刻画

预算约束在最优处通常取等号，因为增大任一因素都降损失、必用尽预算。在 $Q > Q_0$ 的活跃段构造 Lagrange 函数

$$\mathcal{L} = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta} + \mu (6ND + D[g(Q) - g(Q_0)] + \eta N D L_{\text{ctx}} - C), \quad (17)$$

其一阶条件为

$$\partial_N \mathcal{L} = -\alpha A N^{-\alpha-1} + \mu D (6 + \eta L_{\text{ctx}}) = 0, \quad (18)$$

$$\partial_D \mathcal{L} = -\beta B Q^{-\theta\beta} D^{-\beta-1} + \mu (6N + [g(Q) - g(Q_0)] + \eta N L_{\text{ctx}}) = 0, \quad (19)$$

$$\partial_Q \mathcal{L} = -\theta\beta B Q^{-\theta\beta-1} D^{-\beta} + \mu D g'(Q) = 0. \quad (20)$$

由式 (18)–(19) 消去乘子 μ 得参数量与数据量的最优平衡关系（类 Chinchilla 的规模–数据配比 [2]）；式 (20) 给出质量的内点最优条件：当边际质量收益小于边际质量成本时，质量停在内点，否则被推向边界 $Q = 1$ 。这一内点与边界的切换是结构性转移的解析来源之一。

6.3 数值求解

KKT 给出结构，全局解用序列二次规划配合多起点数值优化 [19]。为避免变量尺度悬殊，对参数量与数据量取对数尺度 $(\ln N, \ln D, Q)$ ，预算约束以非线性约束形式送入求解器；每档预算取不少于 20 个随机初值取全局最优以缓解非凸。三档预算

$C \in \{10^{19}, 10^{22}, 10^{24}\}$ ，并在预算对数区间连续扫描以刻画转移；三型质量成本分别求解以比较其对最优解的影响。表 4 汇总结果。

表 4 三档预算下的最优算力配置

C (FLOPs)	$g(Q)$	N^*	D^*	Q^*	L^*	s_{train}	s_Q	s_{attn}
10^{19}	指数型	0.231	5.8	0.5456	3.0984	0.8018	0.1434	0.0547
	幂型	0.215	6.3	0.4456	3.1147	0.8192	0.1249	0.0559
	对数型	0.521	1.4	1.0000	3.2528	0.4482	0.5212	0.0306
	Chinchilla 基线	1.249	1.2	0.0789	3.6807	0.9361	0.0000	0.0639
10^{22}	指数型	5.516	258.6	0.9680	2.1511	0.8559	0.0857	0.0584
	幂型	5.798	237.2	1.0000	2.1530	0.8251	0.1186	0.0563
	对数型	5.600	253.0	1.0000	2.1505	0.8501	0.0919	0.0580
	Chinchilla 基线	39.499	39.5	0.0789	2.4236	0.9361	0.0000	0.0639
10^{24}	指数型	40.770	3768.7	1.0000	1.9139	0.9219	0.0151	0.0629
	幂型	40.942	3739.4	1.0000	1.9141	0.9186	0.0187	0.0627
	对数型	40.703	3780.4	1.0000	1.9139	0.9232	0.0137	0.0630
	Chinchilla 基线	394.989	395.0	0.0789	2.0682	0.9361	0.0000	0.0639

预算增大时最优损失单调下降（指数型下从 3.098 经 2.151 降至 1.914），逐步趋近不可约损失 1.69，参数量与数据量单调增，预算利用率约 100%（约束活跃）；相对质量固定为基线、规模等分的 Chinchilla 基线方案，最优配置的损失改善约 0.15 到 0.58（表 4）。三型质量成本的最优解在中高预算趋于一致，仅在低预算档因质量成本经济性不同而分化：对数型使高质量相对可得，故低预算即把质量推到边界；指数型使高质量昂贵，故低预算下质量停在内点。三档预算的算力份额构成见图 12。




图 12 三档预算下的算力份额构成

基础训练份额始终主导（0.80–0.92），注意力份额随预算缓升，而质量提升份额在低预算最高、随预算增大反而回落（图 12）。这一“质量份额先高后低”的倒 U 形态提示预算跨量级时资源结构确有变化，需要一个可判定的转移判据来定位。

6.4 结构性转移的定义与识别

给出可判定定义：以各部分算力份额 $s_X(C) = C_X^*/C$ 对预算对数的导数峰值定位转移点，

$$C^\dagger = \arg \max_C \left| \frac{d s_X(C)}{d \log C} \right|, \quad (21)$$

并辅以 KKT 活跃约束集切换（质量由内点切到边界、或质量成本较链由非激活变激活）作为交叉判据。连续扫描预算对数区间、数值差分求份额导数即可识别。

结果。扫描得质量份额导数在预算约 2.5×10^{22} FLOPs 处出现峰值，即结构性转移点。作量纲锚定：该值约为 GPT-3（约 3×10^{23} FLOPs）训练算力的十分之一，处于当前主流开源模型预训练算力量级的下沿，说明该转移点对当前实践并非遥不可及，而是恰在可及区间内。因基线质量 0.079 很低，质量成本较链在较低预算即已激活，故“质量投入自低预算起就值得”，这是数据驱动的结论而非先验设定。转移点的标注见图 13。




图 13 最优份额演化与结构性转移点

份额随预算对数演化曲线上叠加的份额导数，其峰值位置即由式 (21) 定位的转移点（图 13）。由于该最优轨迹来自确定性优化、不存在重复抽样，图中不画置信带，而以份额导数曲线的峰值给出结构判据，其位置与 KKT 活跃集切换一致。

6.5 上下文长度的临界值与敏感性

上下文长度为外生参数。令注意力开销等于训练开销 $\eta NDL_{\text{ctx}} = 6ND$ ，与参数量、数据量无关，解得临界上下文

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 3 \times 10^4 \text{ tokens.} \quad (22)$$

当上下文长度达到该值时注意力开销与训练开销相当，超过它长上下文将显著挤压训练预算。敏感性扫描的取值严格取自模型架构元数据的实测集，即 2048、4096、8192、32768 与 131072。图 14 展示最优配置随上下文长度的变化。




图 14 最优配置随上下文长度的变化

在中档预算下,注意力份额随上下文长度从约 0.058(2048)升至约 0.776(131072)(图 14); 临界值 3×10^4 恰落在 8192 与 32768 之间,即上下文不小于 32768 的长上下文模型注意力开销已超训练开销,其最优参数量、数据量被明显压低。预算可行域的几何刻画见图 15。




图 15 算力预算可行域与结构转移

在参数量-数据量-质量空间中，由式 (15) 界定的预算面、等成本线与最优点位置一同表明最优解落在预算面上（约束活跃），且随预算增大最优点沿预算面移动时穿过结构转移分区（图 15）。综合本章：预算增大使损失单调改善并趋近不可约损失，最优策略在预算约 2.5×10^{22} 处发生质量投入结构的转移，长上下文以临界值 3×10^4 为界挤压训练预算。

7 问题四：规模与非规模贡献分解、损失-基准桥接与能力前沿预测

本章把前三问的损失语言翻译为现实基准能力：先分离规模扩张与非规模技术进步的贡献，再建立损失到基准的桥接映射，最后在算力放缓情景下预测开源能力前沿并给出不确定性。

7.1 综合能力度量与口径声明

综合能力取六维基准均分（指令遵循、综合推理、数学、研究生级问答、多步推理与专业知识）：

$$\text{Cap} = \frac{1}{6} \sum_{k=1}^6 B_k, \quad k \in \{\text{IFEval}, \text{BBH}, \text{MATH}, \text{GPQA}, \text{MUSR}, \text{MMLU-PRO}\}. \quad (23)$$

口径显式声明：开源筛选以许可证为准并区分预训练与对话模型 [16, 17]；时间轴用提交或发布日期；均分口径透明可复现，加权与主成分综合作稳健性对照。

7.2 规模与非规模技术进步贡献分解

采用”控制规模后的时间趋势即非规模进步”的可识别策略，以榜单数据回归综合能力对规模变量与时间：

$$\text{Cap}_i = f(\ln N_i) + h(t_i) + \varepsilon_i, \quad (24)$$

其中规模项 f 解释规模扩张贡献、时间项 h （同规模下逐年提升）解释非规模技术进步贡献。在时间窗 $[t_0, t_1]$ 上两部分贡献占比为

$$\text{scale}\% = \frac{\Delta f}{\Delta f + \Delta h}, \quad \text{nonscale}\% = \frac{\Delta h}{\Delta f + \Delta h}, \quad \text{scale}\% + \text{nonscale}\% = 100\%. \quad (25)$$

结果与识别假设。在 4561 个有效模型上回归得 $\text{Cap} = -24576 + 6.27 \ln N + 12.14 t$ ，决定系数 0.462，即同规模下年度能力提升约 12 点。式 (24) 的可识别性依赖”时间项 $h(t)$ 不吸收与时间相关的规模选择效应”这一假设：若近年前沿系统性地转向小模型（如高效微调、蒸馏），则 $h(t)$ 会混入样本组成变化而非纯技术进步。本文对此的立场是审慎的——决定系数仅 0.462，说明两变量之外仍有大量系统性变异（对齐、数据工程等混淆变量既随时间又随规模变化），故下述占比只作定性证据而非精确估计。近两年窗口内前沿模型的平均参数规模不升反降，使规模项增量为负，据式 (25) 得规模贡献约 -25%、非规模贡献约 125%（二者和 100%）。占比超出 0-100% 是规模增量为负的算术后果，其稳健的定性含义是”近期能力提升不再由堆参数驱动、非规模技术进步已占主导”，而非精确到”125%”这一具体数值。占比随时间的演化见图 16。




图 16 规模与非规模贡献分解

非规模贡献为正且占绝对主导，规模贡献在近窗口转为负，故贡献分解图以零线分向填充而非 0–100% 堆叠面积，直观表达“规模是净拖累”（图 16）。这与近年开源社区通过数据工程与对齐而非单纯堆参数提升能力的趋势一致 [12, 13]。

7.3 损失—基准桥接映射

用同时含验证损失与六维基准的桥接样本建立损失到能力的单调映射，按可比性分层（高可比来自可与训练轨迹对照的模型，其余为中可比）。用单调递减的 sigmoid 型回归

$$\widehat{\text{Cap}} = \frac{S_{\max}}{1 + \exp(a(L - L_0))} + c, \quad a > 0 \text{ (损失 } \uparrow \Rightarrow \text{能力 } \downarrow), \quad (26)$$

分层拟合参数并讨论映射误差对前沿结论的影响。

结果与不确定性。高可比层样本仅 7 条，斜率系数为正（损失升则能力降）、决定系数约 0.40、残差标准差约 0.28；中可比层样本 68 条，决定系数约 0.36。须坦承在如此小样本与偏低决定系数下，sigmoid 四参数的置信区间较宽，故本文不把桥接点估计

当作精确映射，而是将高可比层的残差标准差作为映射误差带、与后文情景不确定性一并计入前沿分位带（见式 (27) 下方说明）；对仅 7 条的高可比层，因样本过少不足以支撑稳定的留一交叉验证，故只报告残差带而不宣称交叉验证精度。桥接按可比性着色的展示见图 17。




图 17 损失到能力的分层桥接

损失越低能力越高的单调趋势清晰，高可比层点更紧贴拟合曲线、中可比层散布更宽（图 17）；分层拟合避免了把不同报告口径的点混为一谈，其残差带即前沿预测须叠加的桥接不确定性。

7.4 算力放缓情景下的能力前沿预测

前沿定义为各时间点开源模型综合能力的上包络。算力增速为情景假设，设维持、放缓、停滞三档（历史训练算力增速约 5.1 倍每年作锚定）。在给定增速下外推能力时序，用分位回归与自助法给出未来 12 与 24 个月前沿的分位带 [18]：

$$\text{Frontier}(t + \Delta) \in [\hat{F}_{10}(t + \Delta), \hat{F}_{90}(t + \Delta)], \quad \Delta \in \{12, 24\} \text{ 月}. \quad (27)$$

式 (27) 的分位带宽度由两部分不确定性叠加得到：一是三档算力增速情景的差异，二是上一节桥接映射的残差带（高可比层残差标准差约 0.28，经 sigmoid 斜率折算为能力尺度后并入带宽）。这样前沿区间同时反映了情景假设与损失-能力映射两重误差，而非仅外推的抽样波动。表 5 汇总三情景的分位预测。

表 5 能力前沿情景预测分位数

情景	斜率系数	期限	P10	P50	P90
维持	1.0	12 月	61.03	62.52	67.39
		24 月	80.09	81.94	87.07
放缓	0.5	12 月	51.19	52.68	54.96
		24 月	60.41	62.26	64.52
停滞	0.0	12 月	40.73	42.84	47.71
		24 月	40.73	42.84	44.84
历史末值	—	2025.21			41.75
历史斜率	—	—		19.68 点/年	

三情景的前沿中位数依次拉开：维持情景 24 个月前沿中位数约 82、放缓情景约 62、停滞情景约 43，且每一情景下 24 个月前沿均不低于 12 个月（表 5）。这一“不倒退”结论有其前提——它成立于非规模技术进步速率维持历史水平的假设下；若对齐与数据工程等非规模红利趋于饱和，则前沿可能停滞而非续升。历史末值约 42、历史斜率约 20 点每年为外推提供锚点。前沿分位带见图 18。




图 18 能力前沿情景预测区间

三情景的 10% 到 90% 分位构成的扇形带随外推期限张开，直观反映了情景假设与桥接误差共同带来的不确定性，超出历史数据范围处已标注为情景模拟（图 18，纵轴为六维基准均分 0-100）。前沿预测本质是情景外推，其绝对水平强依赖增速假设，故用分位带而非点值表达。

7.5 逐任务聚合分析

仅用榜单汇总列不足以刻画能力短板，本文遍历逐任务评测记录，按目录取最新可解析记录、跳过损坏文件做逐任务聚合。共解析 1860 个目录（六维完整 1854、损坏跳过 7），覆盖满足要求。各任务难度均值为：指令遵循 40.2、综合推理 47.5、数学 11.4、研究生级问答 29.8、多步推理 40.0、专业知识 32.0，其中数学最难。图 19 展示前沿模型的六维剖面。




图 19 前沿模型逐任务能力剖面

前沿模型在综合推理与指令遵循维度较强，而在数学与研究生级问答维度普遍偏弱，六维剖面的不均衡揭示了当前能力短板集中在高难推理任务上（图 19）[15]。这与式 (23) 均分口径下的综合能力互为补充：均分给出总体水平，逐任务剖面给出结构短板。

8 模型检验与灵敏度分析

本章对四个模型的关键结论作独立复核，并对高敏感假设做扰动分析，说明结果的适用范围。

8.1 独立复核

问题一的综合质量用三种客观赋权交叉核对，熵权与 CRITIC、主成分的排序秩相关分别为 0.827、0.802，说明质量排序不依赖于单一赋权法；扩展集域级质量与主样本同名域量级一致，佐证跨集合稳定性。问题二的经典律在四组独立数据上分层验证，误差随可比性单调增大而无方向偏移；广义律在留出集的均方根误差 0.688 低于同参经

典基线 0.971, 且 $Q = 1$ 退化的相对误差为 0。问题三对每档预算的最优解重代入预算式核验, 三部分算力之和均不超过预算 (利用率约 100%, 即约束在最优处恰好取等); 多起点解一致, KKT 一阶条件残差接近零。问题四的贡献占比之和严格为 100%, 前沿预测在各情景下 24 个月不低于 12 个月, 桥接映射在两层均单调。

8.2 灵敏度分析

对若干题面未定死或仅由半合成数据估计的量做扰动。基线质量在 $\pm 20\%$ 范围内扰动时, 质量成本较链的激活门槛与结构转移点位置随之移动, 但“低预算优先堆规模、中高预算才显著提升质量”的定性顺序不变。质量放大指数 θ 是结构性假定参数而非可识别的估计量 (详见问题二), 在 $\{0.2, 0.5, 0.8\}$ 上变化时质量弹性与替代率的数值随之变化, 但三个弹性同为负、“质量可替代规模”的定性结论稳健; 这也意味着一切依赖 θ 的下游数值 (替代率、最优质量、桥接后能力) 都应在“ θ 假定值下成立”的限定下解读。冲突消解降权因子 δ 在 $\{0.3, 0.5, 0.7, 1.0\}$ 上扫描时, 因冲突样本仅约 5%, 域级质量排序基本不变。三型质量成本对比表明成本函数形态显著影响低预算档的质量投入: 对数型使高质量相对可得、低预算即把质量推向边界, 指数型使高质量昂贵、低预算下质量停在内点, 这一差异正是成本函数选择对最优解影响的体现。算力增速三档情景直接决定前沿带宽, 故前沿以分位带而非点值给出。

8.3 适用范围

上述结论建立在真实数据范围内: 参数量约 0.07 到 12、数据量至 300 (均以 10^9 计) 为拟合支撑区间, 超出此范围 (如百亿参数以上或前沿外推) 的结果均标注为情景模拟, 其绝对水平需现场标定。质量放大指数与算力增速为高敏感假设, 相关的替代率数值与前沿绝对水平不宜作确定性解读, 其定性方向与结构性结论则在扰动下保持稳定。

9 模型评价、改进与推广

9.1 模型优点

本文四个模型共享同一套参数与结论链, 构成从数据刻画到能力预测的完整闭合: 问题一的域级质量与配比贡献直接进入问题二的广义标度律, 标度律参数同时服务于问题三的优化目标与问题四的桥接, 问题三的最优损失又可经问题四翻译为基准能力。质量以有效数据量方式进入并保证 $Q = 1$ 退化, 使广义律在纳入新因素的同时不破坏经典律的可靠性。优化部分先用 KKT 给出结构、再用多起点数值求全局解, 并以份额导数峰值给出可判定的结构性转移定义, 避免了只定性说“变了”。全过程对数据与假

设的冲突（半合成质量标度的方向异常、前沿窗口规模的负增量）均如实呈现而非改数迎合。

9.2 模型不足与改进方向

其一，质量放大指数只能由唯一一组半合成数据估计，其经验值落在边界且口径与部署质量不同，故下游采用了反映“质量有益”前提的取值并做敏感性；若能获得大规模真实的质量-损失联合观测，可把该指数从假设升级为估计。其二，配比经域级贡献间接进入标度律，未直接联立优化 17 维配比；改进可把配比加入决策变量并以投影梯度处理单纯形约束，代价是转移分析的可解释性下降。其三，前沿预测依赖算力增速情景假设，改进可引入更细的算力供给模型或以真实新发布模型滚动校正分位带。

9.3 推广

广义标度律的“有效数据量”框架可推广到其它可归一化的数据属性（如去重率、领域纯度），只需保证满质量时退化为经典形式。问题三的三部分算力约束优化可推广到含推理成本或多阶段训练的预算结构，KKT 加多起点的求解范式与结构性转移判据同样适用。问题四控制规模的贡献分解与分层桥接可推广到其它以基准评分度量的技术演进分析。这些推广均须在目标场景重新标定参数，其适用性以数据支撑范围为界。

10 结论

本文围绕算力约束下提升大语言模型能力的资源配置，建立了四段递进模型并以真实数据求解。数据刻画阶段得到域级综合质量（中位数 0.079）、约 4.96% 的质量冲突及其稳健消解、以及跨尺度可迁移的配比-损失关系；标度律阶段以近乎完美的拟合确定经典律参数，并以质量增强有效数据量构建满足退化条件的广义律，解析给出质量对规模的替代率；优化阶段在三档预算下求得最优配置，损失随预算单调趋近不可约损失 1.69，并在预算约 2.5×10^{22} 处识别出质量投入的结构性转移，解析给出注意力临界上下文 3×10^4 ；预测阶段分离出近窗口以非规模技术进步为主导的能力增长，建立损失到基准的分层桥接，并在三情景下给出不倒退的前沿分位带。上述结论为在有限算力下权衡规模、数据、质量与上下文长度提供了可复核的定量依据。

A 附录：参数取值与求解步骤

A.1 题面给定常量与成本函数

问题三的算力构成与质量成本参数按题面原样载入，列于表 6。

表 6 题面给定常量与三型质量成本参数

物理量	取值	说明
注意力系数 η	2×10^{-4}	作用于三者乘积 NDL_{ctx}
Chinchilla 系数	6	每参数每 token 的训练算力
注意力临界上下文	3×10^4	由 $6/\eta$ 解析得到
指数型 $g(Q)$	$10^7 e^{6Q}$	高质量极昂贵
幂型 $g(Q)$	$5 \times 10^9 Q^4$	高质量成本居中
对数型 $g(Q)$	$2 \times 10^9 \ln(1 + 10Q)$	高质量相对可得
三档预算 C	$10^{19}, 10^{22}, 10^{24}$	FLOPs
基线质量 Q_0	0.079	问题一域级质量中位数

三型质量成本函数在中高预算下给出相近的最优质量，但在低预算档因高质量的经济性不同而分化，这是问题三比较成本函数选择影响的依据（表 6）。

A.2 优化求解步骤

问题三的数值求解按以下顺序执行：（1）以对数尺度 $(\ln N, \ln D, Q)$ 为变量，从类 Chinchilla 平衡点附近取不少于 20 个随机初值；（2）在每个初值上以序列二次规划迭代，预算式作为非线性不等式约束、质量域作为界约束；（3）每次迭代计算目标与约束梯度，更新后投影回可行域，直至一阶最优性残差与步长均低于容差；（4）在全部初值的收敛解中取目标最小者为该预算档的全局解；（5）对预算对数区间连续扫描重复上述过程，数值差分得算力份额对预算对数的导数，其峰值即结构性转移点。最优解写出前重代入预算式核验其可行性。

A.3 关于人工智能工具的使用说明

本文写作过程中使用了通用大语言模型辅助进行文字润色与 LaTeX 排版检查；全部数据处理、模型建立、求解计算与结果均由作者编写的程序在真实附件数据上完成，数值结论未由语言模型生成。

参考文献

- [1] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020. DOI: 10.48550/arXiv.2001.08361.
- [2] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models. arXiv:2203.15556, 2022. DOI: 10.48550/arXiv.2203.15556.
- [3] Liu Q, Zheng X, Muennighoff N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training. arXiv:2407.01492, 2024. DOI: 10.48550/arXiv.2407.01492.
- [4] Xie S M, Pham H, Dong X, et al. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining. arXiv:2305.10429, 2023. DOI: 10.48550/arXiv.2305.10429.
- [5] Penedo G, Kydlíček H, Ben Allal L, et al. The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale. arXiv:2406.17557, 2024. DOI: 10.48550/arXiv.2406.17557.
- [6] Shen Z, Tao T, Ma L, et al. SlimPajama-DC: Understanding Data Combinations for LLM Training. arXiv:2309.10818, 2023. DOI: 10.48550/arXiv.2309.10818.
- [7] Xie S M, Santurkar S, Ma T, Liang P. Data Selection for Language Models via Importance Resampling. arXiv:2302.03169, 2023. DOI: 10.48550/arXiv.2302.03169.
- [8] Wettig A, Gupta A, Malik S, Chen D. QuRating: Selecting High-Quality Data for Training Language Models. arXiv:2402.09739, 2024. DOI: 10.48550/arXiv.2402.09739.
- [9] Gao L, Biderman S, Black S, et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling. arXiv:2101.00027, 2020. DOI: 10.48550/arXiv.2101.00027.
- [10] Biderman S, Schoelkopf H, Anthony Q, et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. arXiv:2304.01373, 2023. DOI: 10.48550/arXiv.2304.01373.
- [11] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners. arXiv:2005.14165, 2020. DOI: 10.48550/arXiv.2005.14165.
- [12] Wei J, Tay Y, Bommasani R, et al. Emergent Abilities of Large Language Models. arXiv:2206.07682, 2022. DOI: 10.48550/arXiv.2206.07682.
- [13] Schaeffer R, Miranda B, Koyejo S. Are Emergent Abilities of Large Language Models a Mirage? arXiv:2304.15004, 2023. DOI: 10.48550/arXiv.2304.15004.
- [14] Liang P, Bommasani R, Lee T, et al. Holistic Evaluation of Language Models. arXiv:2211.09110, 2022. DOI: 10.48550/arXiv.2211.09110.

- [15] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding. arXiv:2009.03300, 2020. DOI: 10.48550/arXiv.2009.03300.
- [16] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models. arXiv:2302.13971, 2023. DOI: 10.48550/arXiv.2302.13971.
- [17] Le Scao T, Fan A, Akiki C, et al. BLOOM: A 176B-Parameter Open-Access Multilingual Language Model. arXiv:2211.05100, 2023. DOI: 10.48550/arXiv.2211.05100.
- [18] Koenker R, Hallock K F. Quantile Regression. *Journal of Economic Perspectives*, 2001, 15(4): 143–156. DOI: 10.1257/jep.15.4.143.
- [19] Boggs P T, Tolle J W. Sequential Quadratic Programming. *Acta Numerica*, 1995, 4: 1–51. DOI: 10.1017/S0962492900002518.
- [20] Chen C H. A Novel Multi-Criteria Decision-Making Model for Building Material Supplier Selection Based on Entropy-AHP Weighted TOPSIS. *Entropy*, 2020, 22(2): 259. DOI: 10.3390/e22020259.