



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 浙江工商大学

参赛队号 26103530179

队员姓名 1.张桦彬

2.李卓梁

3.朱舒昱

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目：算力约束下提升大语言模型能力的资源配置建模

摘 要

在总算力受限条件下，模型规模、数据数量与质量及上下文长度共同影响大语言模型的训练损失与能力。本文围绕数据质量评价、广义标度律、资源配置和能力前沿构建递进模型，区分附件统计、参数估计与条件情景，分析各类投入的收益及适用边界。

针对问题一，对 22 项指标进行语义解码，采用 A1 固定经验分位归一化与三组平衡赋权，建立可复算的质量评分。七域质量中位数为 0.487876；按高教育价值与广告判定冲突的规则，总冲突率为 0.303%，C4 域内冲突率最高，为 1.03%。权重敏感性分析揭示域排序对评分假设的依赖，配比回归的跨尺度预测仍有局限。

针对问题二，采用 **Huber** 稳健损失与多起点拟合估计经典标度律，并以质量加权的有效数据量扩展广义模型，推导弹性及等损失替代关系。在相同设置分组留出下，含质量模型的均方根误差为 0.675，低于无质量基线的 0.784，但改善主要来自 B8。鉴于质量标度尚未统一校准，下游将质量指数 0.5 作为结构性假设并开展敏感性分析。

针对问题三，将基础训练、质量提升与注意力开销纳入统一预算，结合 **KKT** 条件、预算消元与质量剖面搜索求解，并用独立 **SLSQP** 核验。在指数型质量成本下，预算为 10^{19} 、 10^{22} 、 10^{24} FLOPs 时，候选质量分别为 0.506、0.967、1.000，损失分别为 3.073、2.151、1.914。闭式基线与收益分解进一步区分规模配置收益和质量提升收益；注意力开销与基础训练开销相当的上下文长度为 30,000 tokens。

针对问题四，采用描述性增长分解、分层单调桥接及月度前沿 **Bootstrap**，计算停滞、放缓和维持趋势三类情景。在五次一步滚动检验中，趋势模型平均绝对误差为 1.773，高于末值基线的 1.475，因此远期区间仅作条件情景解释。结果表明，资源配置应同时考虑质量收益、处理成本和边界约束；评分与训练收益的联合校准及外部预测验证仍需更多真实数据。

关键词：数据质量评价；广义标度律；算力约束；资源配置；能力前沿

目录

1	问题重述与问题分析	3
1.1	问题背景与任务	3
1.2	问题一的分析	4
1.3	问题二的分析	4
1.4	问题三的分析	4
1.5	问题四的分析	4
1.6	数据证据分层与四问之间的数值接口	4
2	模型假设	5
3	符号说明	5
4	问题一：数据质量评价、冲突识别与配比-损失关系	6
4.1	字段解码、归一化与综合质量	6
4.2	质量冲突的判据与对照处理	8
4.3	配比-损失关系与跨体系域映射	10
4.4	固定百分位参照的数学性质与评分解释	11
4.5	组间权重敏感性与局部冲突的区别	12
4.6	小结	13
5	问题二：经典标度律拟合与含质量的广义标度律	14
5.1	经典标度律的对数域稳健拟合	14
5.2	含质量的广义标度律设计	14
5.3	弹性、边际效用与质量-规模替代	15
5.4	分来源留出误差与质量项的适用范围	18
5.5	质量标度变换与参数可识别性	19
5.6	有限质量增量的精确替代与近似误差	19
6	问题三：算力约束下的资源配置优化与结构性转移	20
6.1	优化模型	20
6.2	KKT 解析刻画	21
6.3	固定质量问题的唯一性与解析基线	21
6.4	质量边界条件与预算的边际价值	22
6.5	数值求解	23
6.6	结构性转移的定义与识别	23
6.7	上下文长度的临界值与敏感性	24
6.8	质量剖面与最优配置的稳定性	26
6.9	总收益中规模配比与质量投入的分离	28
7	问题四：规模与非规模贡献分解、损失-基准桥接与能力前沿预测	29
7.1	综合能力度量与口径声明	29
7.2	规模与年份项的描述性分解	29
7.3	损失-基准桥接映射	30
7.4	能力趋势情景下的经验前沿预测	31
7.5	逐任务聚合分析	33
7.6	样本组成变化与分类型前沿	33
7.7	滚动回测中的可用信息与预测失误	34
7.8	桥接与情景区间所覆盖的不确定性	36
8	模型检验与灵敏度分析	36
8.1	独立复核	36
8.2	灵敏度分析	37
8.3	评分假设向资源配置传播的路径	37
8.4	复核层级与结论的证据边界	38
8.5	适用范围	38
9	模型评价、改进与推广	38
9.1	模型优点	38
9.2	模型不足与改进方向	38
9.3	推广	38
10	结论	39
A	附录：参数取值与求解步骤	42
A.1	题面给定常量与成本函数	42

A.2	优化求解步骤	42
A.3	关于人工智能工具的使用说明	42
B	附录：核心算法代码摘录	42
B.1	问题一：质量评分与配比回归	42
B.2	问题二：经典与广义标度律	44
B.3	问题三：预算约束下的资源配置	46
B.4	问题四：能力前沿与情景预测	48

1 问题重述与问题分析

1.1 问题背景与任务

大语言模型的能力主要通过验证集交叉熵损失（全文记为 L ，单位 nats/token，越低越好）来度量。经典标度律

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (1)$$

把损失表示为参数规模 N 与训练数据量 D 的幂律叠加，其中 E 为不可约损失， A, α, B, β 为待估参数^[2, 3]。然而式 (1) 未显式包含数据质量 Q 与领域配比 p ，也未刻画长上下文对算力的挤占。在总算力预算 C 有限时，如何在 N, D, Q, p 与上下文长度 L_{ctx} 之间取舍，成为决定模型能力上限的核心问题。本文需要回答四个递进的问题：刻画数据的质量与配比，把它们纳入损失预测，在预算约束下求最优配置，最后把损失翻译为真实基准能力并预测其前沿。

题目提供三组真实数据：一组覆盖七个来源域、含 22 个质量信号的大规模文本样本与两个扩展集；一组来自公开模型训练的标度律轨迹与跨族、文献验证点，其中仅一小组半合成实验带有质量标度；一组开源模型评测榜单、逐任务评测记录、损失—基准桥接样本与模型架构元数据。四问按数据、标度律、预算配置与能力分析组织；实际计算依赖关系在图 1 中说明。




图 1 四问递进的整体技术路线

图 1 从左至右给出数据刻画、广义标度律、预算优化与能力预测四个阶段：问题一的域级质量作为问题三基线；配比关系为独立的辅助分析，当前广义律计算固定配比因子为

1；标度律参数用于问题三优化目标；问题四的桥接由独立样本拟合；问题四的桥接可探索性地把损失映射到能力，但当前前沿预测直接基于榜单能力值。章节顺序对应问题的分析层次，并不意味着每一项上游量均进入下游数值模型。

1.2 问题一的分析

问题一先按字段语义解码二分类与六分类 logits，再用 A1 固定经验百分位、三组平衡权重合成质量；A2/A3 沿用 A1 参照。局部冲突定义为高教育价值且判有广告，降权仅作敏感性对照。配比实验另行拟合分域损失，区分观测留出集与估计值外推表。域级质量进入问题三基线；配比系数未进入广义律或预算优化的数值计算。

1.3 问题二的分析

问题二要在经典标度律基础上纳入质量，并讨论配比扩展，是推理密集型任务。首先以真实训练轨迹拟合经典律，并用族外、跨族与文献数据分层验证泛化性；其余轨迹附件登记覆盖情况。广义律的设计是核心：一种自然方式是让高质量数据等效于更多 token，即以有效数据量 $Q^0 D$ 进入数据项，并令 $Q = 1$ 时退化为经典形式；半合成实验的质量标度方向与模型假设冲突，质量指数在下游取结构性假定值。弹性与替代条件由对数损失的偏导解析给出，并以有限增量计算检验局部近似的适用范围。本问的广义律与弹性关系是问题三优化目标的来源。

1.4 问题三的分析

问题三是“算力约束下的资源配置优化与结构性转移”的混合任务。目标函数取自问题二的广义标度律，约束为基础训练、质量提升与长文本注意力三部分算力之和不超过预算。求解上先用 Lagrange/KKT 做解析刻画，预算约束在最优处通常取等号，据此得最优配置关于预算的标度关系；数值上采用预算消元与质量剖面搜索，在三档及连续预算上求候选配置，并以多起点序列二次规划^[20]交叉核验。结构性转移须给出可判定定义，本文以算力份额对预算对数的导数峰值作为数值判据，并检查边界状态。上下文长度依题意为外生参数，须解析给出使注意力开销等于训练开销的临界值并在其可行取值上做敏感性分析。

1.5 问题四的分析

问题四是“贡献分解、桥接映射与带不确定性外推”的混合任务。能力提升既来自规模扩张也来自架构、对齐与数据工程等非规模技术进步^[12, 13]。以能力对规模变量与时间回归，可作描述性分解；年份项可能混入样本组成和未观测因素，不作因果贡献解释。损失与基准的桥接用按可比性分层的单调映射建立；前沿预测直接用榜单能力值，不传播桥接误差。前沿预测在给定能力趋势系数的情景下外推能力分位带，须显式声明综合能力度量、开源筛选口径与时间轴口径^[15, 16]。本问是全题落点，把前三问的损失语言翻译为现实基准能力。

1.6 数据证据分层与四问之间的数值接口

同一附件中的数字承担不同角色，必须先区分“构造评分”“拟合函数”“检验预测”和“设定情景”。例如，A1 的字段可用于定义质量分数，但没有直接给出按该分数筛选后的训练损失；B1 有参数量、训练量和损失，却没有与 A1 同标度的质量标签。将两组数据接入同一个模型，需要显式保留连接假设。本文据此将主要证据分为表 1 所列的四类。

数值接口按“输入标度一致、单位一致、用途明确”的顺序建立。问题一输出样本评分、域均值和域级中位数；问题三只读取其中的 Q_0 作为质量成本起算点。问题二输出的 B1 经典参数用于资源配置，而半合成经验拟合用于检验质量字段的预测信息，两套参数不拼接。问题四的损失-能力桥接与月度前沿预测也分别计算，前者检验损失和能力之间是否存在可用映射，后者直接描述榜单能力随提交月份的变化。

表 1 主要附件的证据角色与使用边界

数据类别	本文用途	可支持的判断	不直接支持的判断
A1、A2、A3	固定参照评分与同名域对照	相对评分、冲突发生率	评分提高必然降低训练损失
B1、B2、B4、B5	经典律拟合与分层验证	同族拟合及跨来源误差	任意架构上的通用参数
B6–B8	质量项的条件预测比较	半合成设置内的误差差异	A1 质量指数的因果估计
估算外推表与趋势情景	一致性检查、条件配置和外推	假设成立时的数值后果	真实未来性能或无条件预测

为使各问结论可追溯，本文对数值结果区分三种来源：从附件直接统计得到的量，例如样本数与域均值；从指定模型估计得到的量，例如经典律系数；从给定参数和情景推导得到的量，例如预算最优配置与两年前沿分位数。第一类也会受抽样和字段定义影响，第二类还会受函数形式影响，第三类则进一步依赖外推假设。后文每次比较均保持数据标度与检验角色一致，不把模型内部的一致性检查当作外部预测验证。

这种分层也决定了问题之间的解释方向。得到较高的相对质量分数，表示在当前参照与权重下更靠近所选指标的有利端；它不能直接转换成提升多少基准分数。预算模型给出的是条件损失最小的配置，仍需在实际行动中确认其损失；即使损失得到验证，能力收益也应在统一基准上再检验。由此形成“数据评分–损失模型–资源配置–能力验证”的完整研究路线，同时明确本题附件已经覆盖与尚未覆盖的环节。

2 模型假设

本文只保留会影响可行域、模型结构或结果解释的现实简化，每条附一句合理性说明。

(1) 22 个质量字段按类别语义解码并统一方向，用 A1 经验百分位归一化；模型评分、DSIR 和结构信号三组各占 1/3。该权重是可检验的建模选择， Q 是相对可用性评分，不是真实质量概率。

(2) 领域配比与损失的关系在同一训练尺度内可由配比向量单独预测，参数量与数据量由配比实验固定，分域建模后按目标域加权。数据本按域分列损失，且同配方不同域损失差异显著，支持分域刻画。

(3) 质量以“质量增强有效数据量”方式进入广义标度律，令有效数据量为 $Q^\theta D$ ，使 $Q = 1$ 时自然退化为经典形式。高质量数据等效于更多 token，物理含义清晰且退化有据。

(4) 问题三中配比由前两问固定、仅 N, D, Q 为决策变量，配比联立优化作为扩展。固定配比使规模、数据、质量三者的结构性转移更清晰，且标度律数据无逐域配比字段。

(5) 基线质量 Q_0 取问题一七个域级评分的中位数，并在敏感性分析中扰动。题面未给该值；它是当前评分标度下质量成本铰链的起算点，随评分方法变化。

(6) 问题四综合能力取六维基准均分，前沿样本要求许可证有明确名称、排除未知及空值，并排除明确关闭权重的记录；时间轴用榜单提交日期，该操作性代理不能核实严格的开源属性。均分口径透明可复现，且题目要求显式声明这些口径。

3 符号说明

下表汇总全文跨章节复用、直接进入核心目标或约束的主要符号；一次性下标在首次出现处解释。

符号	含义	符号	含义
L	验证集交叉熵损失 (nats/token)	C	总算力预算 (FLOPs)
N	模型参数量 (10^9)	C_{train}	基础训练开销
D	训练 token 数 (10^9)	C_Q	质量提升开销
Q	综合数据质量评分 (0, 1]	C_{attn}	长文本注意力开销
Q_0	基线质量	η	注意力开销系数 2×10^{-4}
$\mathbf{p}$	17 域配比向量	L_{ctx}	上下文长度 (tokens, 外生)
E	不可约损失	$L_{\text{ctx}}^{\text{crit}}$	注意力临界上下文 $6/\eta$
A, α	参数项系数与指数	$g(Q)$	每 token 质量成本函数
B, β	数据项系数与指数	ε_X	因素 X 的弹性
θ	质量放大指数	s_X	因素 X 的算力份额
w_j	质量指标 j 的权重	Cap	综合基准能力 (0–100)

4 问题一：数据质量评价、冲突识别与配比–损失关系

本章用 A1 的 51230 条质量信号记录定义样本级质量，用 A2/A3 检验跨集合稳定性；另用 RegMix 配比实验建立配比–损失关系。质量评分与配比回归使用不同附件，后者的系数不进入本章的 Q 。计算流程见图 2。

4.1 字段解码、归一化与综合质量

质量信号覆盖七个来源域、22 个字段。依数据集字段说明^[1]，fluency_en 和 ad_en 是二分类 logits，四个 ModernBERT PRRC 字段是有序六分类 logits；直接对 logits 求均值没有类别含义。二分类取正类 softmax 概率：流畅度取 fluent 类，广告指标取 no-ad 类。六分类取等级 0, ..., 5 的 softmax 期望并除以 5。fineweb_edu 取单一评分，qurater 的四个评分在字段内等权平均；后者是明确的建模选择。DSIR 与 RPS 标量按原值读入。

缺失值以 A1 同字段中位数填充。词数、句数和平均词长先取 $\log(1+x)$ ，再截于 A1 的第 95 百分位；重复率、非字母词、大写和数字占比取反向。对方向统一后的字段 z_{ij} ，固定 A1 经验分布，以中秩百分位评分：

$$r_{ij} = \frac{\#\{z_{kj} < z_{ij}\} + \frac{1}{2}\#\{z_{kj} = z_{ij}\}}{n_{A1}}, \quad k \in A1; \quad Q_i = \sum_{j=1}^{22} w_j r_{ij}. \quad (2)$$

扩展集代入同一 A1 参考分布和缺失、截断参数，所得百分位截于 [0, 1]。模型评分 8 项、DSIR 3 项、结构 11 项各占总权重 1/3，组内等权，即 $w_j = 1/(3n_g)$ 。域级分数为域内 Q_i 的均值，问题三的 Q_0 取七个域均值的中位数。三组平衡是预先声明的建模选择，所得 Q 不是已校准的真实质量概率。

A1 的 Q 范围为 0.1459–0.8191，域级中位数 $Q_0 = 0.48788$ 。A1 全体均值恰为 0.500，是中秩百分位变换的数学性质，不能解释为质量达标率。C4 的域均值最高 (0.55822)，书籍最低 (0.38970，仅 171 条)。与全局 CRITIC、22 项等权和六分类 argmax 解码相比，七域排序 Kendall 相关依次为 0.333、0.238、0.810。若固定三组各占 1/3，仅组内改用 CRITIC，域序不变 (Kendall = 1)，域级中位数由 0.48788 变为 0.48648；但三组权重各在 0.2–0.5 的 36 种网格方案下，域序相关最低为 0.429，中位数范围为 0.455–0.511。主要不确定性在组间权重，不能把单一域排名当作客观质量真值。表 2 给出主权重与 CRITIC 对照，指标结构和相关性见图 3、4。




图 2 问题一质量评价数据处理流程

表 2 三组平衡主权重与 CRITIC 对照

#	指标	主权重 w_j	CRITIC	#	指标	主权重 w_j	CRITIC
1	DSIR 书籍	0.1111	0.0506	12	句末标点	0.0303	0.0432
2	DSIR 数学	0.1111	0.0509	13	句子数	0.0303	0.0469
3	DSIR 维基	0.1111	0.0507	14	词数	0.0303	0.0451
4	流畅度	0.0417	0.0401	15	非字母词占比	0.0303	0.0420
5	QuRater	0.0417	0.0390	16	2gram 重复	0.0303	0.0441
6	无广告概率	0.0417	0.0478	17	大写占比	0.0303	0.0455
7	教育价值	0.0417	0.0433	18	唯一词占比	0.0303	0.0508
8	整洁度	0.0417	0.0398	19	数字占比	0.0303	0.0464
9	推理性	0.0417	0.0428	20	平均词长	0.0303	0.0529
10	专业性	0.0417	0.0486	21	3gram 重复	0.0303	0.0445
11	可读性	0.0417	0.0412	22	unigram 熵	0.0303	0.0440
合计 $\sum_j w_j$						1.000000	

表中相同的主权重由“三组各占 1/3、组内等权”直接给出，并非熵权计算结果；CRITIC 列是数据驱动的对照，不能据此把主评分称作熵权法。




图 3 质量指标体系层次结构

4.2 质量冲突的判据与对照处理

冲突定义为同一文档的教育价值位于 A1 前 20%，且二分类模型给出的广告概率超过 0.5：

$$\text{Conflict}(i) = 1 \left[r_{i,\text{edu}} \geq \tau_{0.8}^{A1} \wedge P_i(\text{has-ad}) > 0.5 \right], \quad Q_i^{\text{adj}} = [1 - (1 - \delta)\text{Conflict}(i)] Q_i. \quad (3)$$

其中 $P(\text{has-ad}) = 1 - P(\text{no-ad})$ ； $\delta = 0.5$ 仅用于对照，主评分与 Q_0 不降权。A2/A3 沿用 A1 的教育价值阈值。

A1 检出 155/51230 条，冲突率 0.303%；C4 为七域最高，103/10000 = 1.03%。A2 的 arxiv 为 10/17523 = 0.057%，A3 的 github 为 24/203752 = 0.0118%。教育价值与广告概率的 A1 Spearman 相关为 -0.181，总体负相关与少量局部共现并不矛盾。 $\delta \in \{0.3, 0.5, 0.7, 1\}$ 时七域排序不变；降权因子没有下游损失标签校准，故不能声称其提高训练性能。

同一评分参照下，arxiv 的 A1/A2 域均值为 0.48788/0.48714，github 的 A1/A3 为 0.44874/0.44910。差值分别仅 -0.00074 与 +0.00036，说明这两个域的抽样分数较稳定；不能外推到其余五域。表 3 的自助区间只表示 A1 域内抽样波动，不包括评分方案的不确定性。




图 4 语义解码并归一化后质量指标的相关性

表 3 域级综合质量统计

域	n_{A1}	Q_{A1}	95% 区间	n_{ext}	Q_{ext}
c4	10000	0.55822	[0.55652, 0.55987]	—	—
stackexchange	10000	0.50741	[0.50600, 0.50887]	—	—
wikipedia	10000	0.50476	[0.50335, 0.50627]	—	—
arxiv	1419	0.48788	[0.48656, 0.48907]	17523	0.48714
commoncrawl	9640	0.48390	[0.48233, 0.48544]	—	—
github	10000	0.44874	[0.44668, 0.45065]	203752	0.44910
book	171	0.38970	[0.38223, 0.39686]	—	—
全样本	51230	0.50000	—	—	—




图 5 高教育价值与广告判定的局部共现

4.3 配比-损失关系与跨体系域映射

配比实验给出 512 组 17 维领域配比与对应的 13 域验证损失。对目标域 k 建立对数域线性模型^[4]:

$$\ln \hat{L}_k(\mathbf{p}) = a_k + \sum_{i=1}^{17} b_{ki} p_i, \quad p_i \geq 0, \quad \sum_i p_i = 1. \quad (4)$$

单纯形使截距与全部系数不能同时唯一识别；计算中令 $\sum_i b_{ki} = 0$ 并相应平移截距，预测不变。平均绝对系数仅描述相对平均配比的模型内对比，不能作因果解释。

1m 同尺度留出的平均对数损失 $R^2 = 0.664$ 、Spearman = 0.844；60m、1B 观测留出集的 R^2 分别为 -5.387、-265.290，排序相关为 0.842、0.736。A12-A15 是估计值表，不能当真实留出测试：10B/70B 的平均 $R^2 = -66.863/-81.042$ ，排序相关 0.498/0.421。这些结果表明固定 1m 模型不能直接预测大规模绝对损失；跨尺度排序也逐渐变弱。梯度提升模型的 1m 五折交叉验证 $R^2 = 0.977$ ，只检验同尺度拟合。

质量域与配比的 17 个域并不一一对应。依据附件映射指南，三个域可同名对应、三个域语义近似对应，其余是推断映射；无质量域的配比列仍保留在式 (4) 中。推断映射只为后续解释提供参考，不产生新的观测质量值，也未进入问题三数值求解。




图 6 A1 抽样域与 A2/A3 扩展域的质量对照

表 4 配比回归分尺度检验；末两行是附件估计值

尺度	配比数	平均 $\ln L$ 的 R^2	平均 Spearman
1m	256	0.664	0.844
60m	256	-5.387	0.842
1B	64	-265.290	0.736
10B (估计)	63	-66.863	0.498
70B (估计)	63	-81.042	0.421

4.4 固定百分位参照的数学性质与评分解释

中秩百分位变换同时解决了量纲不同和极端值影响的问题，但也引入了需要说明的性质。对某个方向已统一的字段，将 A1 中相等的观测分为若干组，第 v 组有 m_v 条，前面累计有 a_v 条，则该组每条记录的百分位为 $(a_v + m_v/2)/n$ 。对全部记录求和可得

$$\frac{1}{n} \sum_{i=1}^n r_{ij} = \frac{1}{n^2} \sum_v m_v \left(a_v + \frac{m_v}{2} \right) = \frac{1}{2}. \quad (5)$$

最后一个等式来自有序观测对计数：不同组的配对贡献与同组的一半贡献合起来为 $n^2/2$ 。因此，只要所有记录使用同一参考集、权重非负且和为 1，A1 样本总体的平均 Q 必然为 0.5。该性质与数据实际是否适合训练没有一一对应关系；平均数接近 0.5 不能用来验证评分“准确”。对 A2/A3 使用 A1 参照时，上述恒等式不再强制成立，扩展集平均分才可以与 A1 同名域作同标度对照。

固定参照还能避免重新排名产生的伪稳定性。若每个新增集合都在内部重新转成百分




图 7 零和编码下配比系数的相对对比强度

位，其总体平均分仍会回到 0.5，即使新集合的原始质量信号整体下降，均分也不一定反映下降。本文保存 A1 的中位数、截断阈值和经验分布，使后来的样本始终回答同一个问题：相对于 A1，该样本处在何种位置。超出 A1 支撑范围的数值被截在边界，因此边界附近的评分只表明超出参照，不提供超出程度的线性测量。

该变换对严格单调递增重参数化保持排序不变。例如在不发生截断时，正向字段先取对数再计算经验百分位，不会改变记录次序；长度字段的实际作用变化主要来自第 95 百分位截断形成的并列值。反向字段则通过方向转换明确“越低越好”。这些处理应由字段含义决定，不能因为某种方向让结果更符合预期就临时调整。缺失填补同样只是保证评分可计算的规则，并不表示缺失记录拥有真实的中等质量。

4.5 组间权重敏感性与局部冲突的区别

记三组平均百分位分别为 M_i, S_i, T_i ，则综合分可以写为

$$Q_i(\mathbf{a}) = a_M M_i + a_S S_i + a_T T_i, \quad a_M + a_S + a_T = 1, \quad a_g \geq 0. \quad (6)$$

其中 S_i 为 DSIR 组、 T_i 为结构组。对于两个域 d, e ，域均值之差等于三组域均值差与权重的内积。若一个域在三个组上都不低于另一域，则所有非负权重下的域序都一致；若各组的优势方向不同，改变权重就可能改变域序。因此，域排序稳定性反映了指标之间是否形成一致判断，不能仅由主方案某两个得分的差距判断。

图 8 展示三组权重各限于 0.2–0.5、步长为 0.05 的 36 个可行设置。每个点表示一个事先定义的权重组合，并非一次随机抽样。所得 Q_0 介于 0.45514 与 0.51139；C4 在 28 个设置中排名最高，arxiv 在 8 个设置中最高。书籍在 31 个设置中最低，github 在 5 个设置中最低。该有限网格刻画一组偏好变化下的结果范围，不是某域排名的概率或置信区间。




图 8 组间权重变化下的基线质量与域序稳定性；每点为一个确定性设置

组内 CRITIC 对照的域序完全不变，而组间权重改变会出现明显重排，说明进一步校准应优先回答“模型评分、DSIR 与结构信号各应占多大比例”。单纯增加赋权算法复杂度，无法替代与下游训练目标相对应的标签。对于当前题目，三组平衡主方案的优势在于规则透明、不会因某组指标数量较多而自动获得更高总权重；它仍然是一个可以被新数据修正的选择。

局部冲突与综合质量描述不同现象。表 5 同时列出发生数与域内比例：C4 不仅综合质量较高，其冲突率也最高。高综合分不会排除少数记录同时具有广告和教育价值，二者并不矛盾。书籍只有 171 条，一条冲突就对应约 0.585%；相比之下，github 的一条冲突对应 0.010%。仅按冲突数比较，或忽略分母直接排列比率，都可能误判数据治理的优先级。

表 5 A1 各域冲突计数与域内发生率

来源域	样本数	冲突数	域内冲突率
c4	10000	103	1.0300%
book	171	1	0.5848%
commoncrawl	9640	48	0.4979%
wikipedia	10000	2	0.0200%
github	10000	1	0.0100%
arxiv	1419	0	0.0000%
stackexchange	10000	0	0.0000%

实际使用时可保留两个分开的信息：以 Q 表示整体相对可用性，以冲突标记触发复核或专项处理。当前 δ 降权只用于敏感性分析，尚未计入训练质量收益。若后续获得清洗前后训练实验，应在相同 token 预算、相同模型结构与训练配方下比较，而不是仅以降权后的评分下降或排名稳定作为治理有效的证据。

4.6 小结

问题一给出七域质量中位数 $Q_0 = 0.48788$ 与明确判据下的 A1 冲突率 0.303%。二者均依赖所选评分标度和阈值。配比模型跨尺度预测失准，暂不用于预算配置。

5 问题二：经典标度律拟合与含质量的广义标度律

本章先在真实训练轨迹上拟合经典标度律，再构造含质量的有效数据量扩展，并解析弹性与质量对规模的替代条件。配比影响在本章保留为待识别扩展，数值计算固定其因子为 1；问题三使用这里的损失参数，问题四的桥接由另一组损失-基准样本独立拟合。

5.1 经典标度律的对数域稳健拟合

采用题目给定的经典形式式 (1)。以 1176 行真实 Pythia 训练日志^[11] 为主拟合集（参数量 0.07–12B、数据量至 300B）。由于损失跨越约 2 到 4.7 的量级，直接在原始尺度最小二乘会被大损失点主导，故在对数域用 Huber 损失做非线性最小二乘，兼顾同方差化与对离群轨迹点的稳健性：

$$\min_{E, A, \alpha, B, \beta} \sum_{m=1}^M \rho_{\kappa} \left(\ln L_m - \ln (E + A N_m^{-\alpha} + B D_m^{-\beta}) \right), \quad \rho_{\kappa}(u) = \begin{cases} \frac{1}{2} u^2, & |u| \leq \kappa, \\ \kappa (|u| - \frac{1}{2} \kappa), & |u| > \kappa. \end{cases} \quad (7)$$

求解用信赖域反射的非线性最小二乘并启用 Huber 稳健损失。初值中 α 取 0.1、0.2、0.34、0.5， β 取 0.1、0.28、0.4。仅保留收敛解，按实际优化的 Huber 目标值选择候选； R^2 作为报告指标，不参与择优。

结果与分层验证。拟合得 $E = 1.690$ 、 $A = 0.354$ 、 $\alpha = 0.340$ 、 $B = 1.240$ 、 $\beta = 0.280$ ， R^2 接近 1，残差均值约 -5×10^{-8} 。在 B2、B4、B5 上分别进行族外、跨族收敛点与文献点验证，RMSE 为 1.243、0.293、0.198，对应 $R^2 = -5.073, 0.605, 0.731$ 。B2 的负决定系数说明主拟合不能直接保证跨族迁移；B3 本次仅登记轨迹文件数量，不称为已完成验证。另读取 B9 的 132 条规模元数据和 B10 的 128 条估算基线；B10 均位于 B1 参数量范围之外，RMSE 约 0.0011，只反映估算数据的一致性，不能视作真实大模型的预测精度。图 9 给出主集拟合与残差。

预测-实际散点几乎落在对角线上，拟合残差 $\hat{L} - L$ 在零线附近无系统弯曲（残差标准差约 1.5×10^{-4} nats/token，量级远小于 L 本身），说明经典幂律在真实轨迹上的拟合已相当充分，可作为同族广义律的数值基底，跨族使用仍需校准（图 9，右图横轴为残差 $\hat{L} - L$ ，单位 nats/token）。

5.2 含质量的广义标度律设计

经典律未含质量。本文让高质量数据等效于更多 token，即以有效数据量 $D_{\text{eff}} = Q^{\theta} D$ ($\theta > 0$) 进入数据项：

$$L(N, D, Q) = E + A N^{-\alpha} + B (Q^{\theta} D)^{-\beta}. \quad (8)$$

当 $Q = 1$ 时 $Q^{\theta} = 1$ 、 $D_{\text{eff}} = D$ ，式 (8) 在代数上退化为经典式 (1)。问题一的 Q 是 A1 相对百分位的加权评分，1 是模型边界，没有经验样本被证明达到“完美质量”。评分还含文档长度信号；把 $Q^{\theta} D$ 解作有效 token 数是建模假设，其独立质量效应尚缺真实质量-损失联合观测验证。配比调节项 $\phi(\mathbf{p})$ 可作为扩展，但当前拟合和问题三计算均固定 $\phi = 1$ 。

质量指数的证据边界与公平对照。B6–B8 是半合成补充集，其质量标度与验证损失呈正相关（Spearman 约 +0.446）。在当前函数形式与边界下，经验指数取到下界 $\theta = -10$ ；这提示方向与参数识别问题，但不能仅凭相关性断言该字段就是难度或多样性。A1 百分位质量与这组实验标度的对应关系没有被验证。因此下游采用 B1 的五个经典参数和结构性假设 $\theta = 0.5$ ，并在 $\{0.2, 0.5, 0.8\}$ 上重求配置；该正指数不能解释为从 B6–B8 估计得到。

为评价质量项的预测增量，将相同 (N, D, Q) 设置的记录放入同一组，再随机留出约 20% 的设置组，实际留出 488 条记录，避免重复设置跨训练与测试泄漏。含质量模型与无




图 9 经典标度律拟合优度与残差

质量模型在同一训练集、相同公共参数边界和 Huber 目标下分别拟合；留出 RMSE 分别为 0.675 与 0.784。这个比较支持半合成数据中的条件预测增量，但不验证 A1 质量的因果效应。原先从含质量模型直接删去质量项的对照不公平，已替换。稳健拟合后的残差惩罚诊断不作为严格 AIC/BIC 检验。表 6 汇总当前结果。

表 6 的参数列分别对应 B1 经典拟合和 B6-B8 半合成经验拟合。留出检验的无质量列使用单独重拟合的模型，不能与 B1 参数列混同。后续曲面、弹性和问题三统一使用 B1 经典参数加假设 $\theta = 0.5$ ；不再把半合成经验拟合的五个参数与正指数拼接。 $Q = 1$ 退化相对误差为 0，属于代数一致性检查。图 10 展示该下游假设模型。

固定数据量后，损失随参数量与质量的联合变化面沿任一方向增大均单调下降，质量方向的下降经 Q^θ 放大数据项体现，直观展示了质量与规模对损失的协同作用（图 10，含 $Q = 1$ 退化对照线）。

5.3 弹性、边际效用与质量-规模替代

定义因素 X 的弹性 $\varepsilon_X = \partial \ln L / \partial \ln X$ 。对广义律式 (8) 求偏导得

$$\frac{\partial L}{\partial N} = -\alpha AN^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta BQ^{-\theta\beta} D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\theta\beta BQ^{-\theta\beta-1} D^{-\beta}, \quad (9)$$

从而

$$\varepsilon_N = \frac{-\alpha AN^{-\alpha}}{L}, \quad \varepsilon_D = \frac{-\beta B(Q^\theta D)^{-\beta}}{L}, \quad \varepsilon_Q = \theta \varepsilon_D. \quad (10)$$

表 6 标度律参数与拟合优度

项	经典律 $L(N, D)$	广义律 $L(N, D, Q)$
参数		
E	1.6898	0.2295
A	0.3540	0.5560
α	0.3400	0.3138
B	1.2403	2.8884
β	0.2799	0.1223
θ (经验)	—	-10.000
θ (下游取用)	—	0.50
拟合		
样本量 n	1176	2026
R^2	0.9999998	0.3547
残差标准差	1.466e-04	—
留出/外部集 RMSE		
B6-B8 分组留出 ($n=488$)	0.7836	0.6749
published ($n=44$)	0.1976	—
baseline ($n=57$)	0.2927	—
cerebras ($n=1029$)	1.2431	—
参考点弹性		
ε_N	—	-0.0497
ε_D	—	-0.0437
ε_Q	—	-0.0218
$dN/dQ _L$	—	-0.9007

式 (10) 表明质量弹性是数据弹性的 θ 倍：质量通过放大有效数据发挥作用，其边际效用与数据同向而幅度可调。沿等损失面 $dL = 0$ ，质量与规模的替代率为

$$\left. \frac{dN}{dQ} \right|_L = -\frac{\partial L / \partial Q}{\partial L / \partial N} = -\frac{\theta \beta B Q^{-\theta \beta - 1} D^{-\beta}}{\alpha A N^{-\alpha - 1}}. \quad (11)$$

结果。在参考点 $N = 1$ 、 $D = 100$ 、 $Q = Q_0 = 0.48788$ ，使用与问题三相同的参数，得 $\varepsilon_N = -0.04969$ 、 $\varepsilon_D = -0.04367$ 、 $\varepsilon_Q = -0.02184$ ，且 $\varepsilon_Q = \theta \varepsilon_D$ 。局部替代率为 $dN/dQ|_L = -0.9007$ ，线性化的 $\Delta Q = 0.1$ 对应 $\Delta N \approx -0.0901B$ 。直接求解有限增量的等损失方程，则可减少约 0.0767B 参数；若保持原质量，用增加参数量达到同样的降损效果，则需增加约 0.0855B 参数。这两个有限增量问题的约束不同，不能混用。上述结果仍依赖假设质量指数；图 11 与图 12 给出弹性和局部替代关系。

在当前参考点，参数量弹性的绝对值略大于数据量，质量弹性为数据量的一半；其它工作点的排序可以变化。负号由模型形式及正参数约束决定，不能单独作为经验验证（图 11）。

等损失曲线在低质量区更陡（图 12），其斜率即式 (11) 给出的质量-规模即时替代率，表明质量越低时提升质量替代规模的效率越高。这一分析为问题三在预算约束下权衡质量投入与规模扩张提供了边际依据。




图 10 广义标度律损失曲面




图 11 各因素损失弹性对照




图 12 等损失线与质量-规模替代

5.4 分来源留出误差与质量项的适用范围

总体留出 RMSE 能够概括给定样本混合下的预测误差，但各来源对该指标的贡献并不相同。设来源 s 的留出样本量为 n_s 、均方根误差为 R_s ，则总体误差满足

$$R_{\text{all}}^2 = \sum_s \frac{n_s}{\sum_u n_u} R_s^2. \quad (12)$$

因此，总体改进既取决于各来源误差变化，也取决于样本构成。表 7 在完全相同的分组留出划分下重新汇总 B6、B7、B8；各来源平方误差按样本量加权后，与已经报告的总体 RMSE 一致。

表 7 同一分组留出集上的来源分层误差

来源	留出数	含质量 RMSE	无质量 RMSE	后者减前者
B6	68	1.1876	0.4393	-0.7483
B7	83	1.1437	0.4369	-0.7067
B8	337	0.2298	0.8962	+0.6664

B6 与 B7 的含质量 RMSE 分别为 1.188 和 1.144，均高于无质量模型约 0.44 的误差；B8 则由无质量模型的 0.896 降为 0.230。B8 占 337/488 的留出记录，是总体改善的主要来源。由此可见，含质量扩展改善的是当前来源混合下的整体指标，并未在每一个来源上都占优。若部署时的来源比例变化，总体比较可能随之改变。

该分层结果还解释了为什么不能把总体误差下降直接当作“质量作用已被验证”。补充集之间可能存在配方、评分标度或生成方式的差别，单一质量指数会同时吸收其中若干关




图 13 广义律与无质量基线的分来源留出误差；两模型分别在同一训练集拟合

联。当前实验的可靠结论是：质量字段对该混合数据的条件预测有信息，但单一函数对各来源的兼容程度不一致。后续若增加来源截距或交互项，应再次进行按设置分组的验证，并保留完全独立的来源外测试；只改善训练误差不能说明迁移能力提高。

5.5 质量标度变换与参数可识别性

质量指数不仅依赖训练观测，也依赖质量坐标本身。考虑正数 c, r ，将质量重新定义为 $Q' = cQ^r$ ，则数据项可改写为

$$BQ^{-\theta\beta}D^{-\beta} = Bc^{\theta\beta/r}(Q')^{-\theta\beta/r}D^{-\beta}. \quad (13)$$

若同时令 $\theta' = \theta/r$ 、 $B' = Bc^{\theta\beta/r}$ ，预测损失保持不变。这说明在未固定质量定义时，指数数值本身没有独立可比性。不同论文采用不同归一化、不同组合权重或不同质量变量，即使得到不同的 Q_0 或 θ ，也不能仅凭数值大小判断谁的模型更准确。

上述等价关系适用于相应的幂式重参数化，任意经验百分位变换一般不属于这一类，不能仅调整一个指数就保证完全等价。问题一将各字段转成经验百分位，得到有界的相对评分；B6–B8 中的质量字段并未与该评分建立同一样本上的校准关系。因此，经验负指数与下游正指数承担不同角色：前者揭示补充数据中的相关模式及拟合边界，后者定义“质量提升增加有效数据量”的资源配置情景。本文保留这一差别，不把两者平均或简单变号后当作新的经验估计。

从实验设计看，识别独立质量效应至少需要在相近 N, D 下改变质量，在相近质量下改变训练量，并保持验证集与损失计量一致。否则，质量与数据量近似共线时， $\ln D + \theta \ln Q$ 的变化可以由不同参数组合解释。题目现有数据适合构造条件模型和敏感性分析，但不足以保证这类参数在跨数据集、跨训练尺度时都可识别。

5.6 有限质量增量的精确替代与近似误差

局部导数只描述参考点附近的变化。固定 $D = D_0$ 、目标损失 $L = L_0$ ，直接移项可得等损失配置

$$N(Q) = \left[\frac{A}{L_0 - E - BQ^{-\theta\beta}D_0^{-\beta}} \right]^{1/\alpha}, \quad L_0 - E - BQ^{-\theta\beta}D_0^{-\beta} > 0. \quad (14)$$

分母条件是可行性的组成部分：如果仅数据项已经达到或超过允许的可约损失，即使无限增大参数量，也无法达到目标 L_0 。反之，当质量改善而数据量固定时，数据项下降，为参数量提供更大损失空间，因而能够减少参数量。式 (14) 给出的参数节省仍然是同一假设损失函数上的替代，不是实际训练测得的压缩效果。

在参考点处作 Taylor 展开，有

$$N(Q_0 + \Delta Q) = N_0 + N'(Q_0)\Delta Q + \frac{1}{2}N''(\xi)(\Delta Q)^2, \quad (15)$$

其中 ξ 位于两质量值之间。本文参数均为正，令 $t = \theta\beta$ 、 $H = L_0 - E$ 、 $K = BD_0^{-\beta}$ ，在可行域上可由 $N = A^{1/\alpha}(H - KQ^{-t})^{-1/\alpha}$ 求得 $N''(Q) > 0$ 。因此等损失曲线在本例中为凸函数，切线在曲线下方；对正向质量增量，线性近似会高估能够节省的参数量。




图 14 有限质量增量下的精确参数节省与局部线性近似；固定 $D = 100B$

图 14 由式 (14) 逐点计算，并回代损失核验。 $\Delta Q = 0.1$ 时，局部近似的参数节省为 0.0901B，精确值为 0.0767B；增量继续扩大时两者差距增加。因此，小扰动分析适合解释边际关系，较大幅度配置变更应直接求解等损失关系或重新执行预算优化。资源配置还会同时改变 D ，不能将固定数据量的参数节省直接当作预算最优方案中的规模变化。

6 问题三：算力约束下的资源配置优化与结构性转移

本章在总算力预算有限时，求使损失最小的参数量、数据量与质量配置，并分析预算跨量级时最优策略是否发生质变。目标函数取自问题二的广义标度律，约束为三部分算力之和不超预算。

6.1 优化模型

决策变量为参数量 $N > 0$ 、数据量 $D > 0$ 与质量 $Q \in (0, 1]$ 。 N, D 分别以十亿参数、十亿 token 为单位；记 $U = 10^9$ ，则物理计数为 UN, UD 。上下文长度 L_{ctx} 为外生参数，

配比在当前数值模型中固定。目标与 FLOPs 约束为

$$\min_{N,D,Q} L(N, D, Q) = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta}, \quad (16)$$

$$\text{s.t. } \underbrace{6U^2ND}_{C_{\text{train}}} + \underbrace{UD[g(Q) - g(Q_0)]_+}_{C_Q} + \underbrace{\eta U^2NDL_{\text{ctx}}}_{C_{\text{attn}}} \leq C, \quad (17)$$

$$0 < Q \leq 1, \quad N > 0, \quad D > 0, \quad (18)$$

其中基础训练开销取 Chinchilla 系数 6（每参数每 token 约 6 FLOPs，仅在标准 dense transformer 下成立）。注意力开销是工程一阶近似， $\eta = 2 \times 10^{-4}$ 。 $g(Q)$ 为每个物理 token 的质量成本，取指数、幂、对数三型之一； $[\cdot]_+$ 表示仅当质量超过基线 Q_0 时计增量成本。重新评分后，问题一七域中位数给出 $Q_0 = 0.48788$ 。此基线取决于 A1 百分位评分口径，不能与旧评分数值直接比较。显式写出 U 可避免把“十亿”为单位的标度律变量直接代入物理 FLOPs 公式。

6.2 KKT 解析刻画

预算约束在最优处通常取等号，因为增大任一因素都降损失、必用尽预算。在 $Q > Q_0$ 的活跃段构造 Lagrange 函数

$$\mathcal{L} = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta} + \mu (U^2ND(6 + \eta L_{\text{ctx}}) + UD[g(Q) - g(Q_0)] - C), \quad (19)$$

其一阶条件为

$$\partial_N \mathcal{L} = -\alpha A N^{-\alpha-1} + \mu U^2 D (6 + \eta L_{\text{ctx}}) = 0, \quad (20)$$

$$\partial_D \mathcal{L} = -\beta B Q^{-\theta\beta} D^{-\beta-1} + \mu (U^2 N (6 + \eta L_{\text{ctx}}) + U[g(Q) - g(Q_0)]) = 0, \quad (21)$$

$$\partial_Q \mathcal{L} = -\theta\beta B Q^{-\theta\beta-1} D^{-\beta} + \mu U D g'(Q) = 0. \quad (22)$$

由式 (20)–(21) 可消去乘子 μ ，得到参数量与数据量的边际平衡关系^[3]。质量条件须分段理解： $Q < Q_0$ 时提高质量不增加 C_Q 却降低损失，故候选最优解不会停在该段；在 $Q = Q_0$ 处比较铰链两侧的单边导数，在 $Q_0 < Q < 1$ 的内点使用式 (22) 的边际收益等于边际成本条件，在 $Q = 1$ 时检查上界条件。以上均为局部必要条件，不能单独证明全局最优。

6.3 固定质量问题的唯一性与解析基线

预算消元不仅减少一个决策变量，也使固定质量问题的解结构可以直接分析。对给定 $Q \in [Q_0, 1]$ ，令 $k = U^2(6 + \eta L_{\text{ctx}}) > 0$ 、 $h = U[g(Q) - g(Q_0)] \geq 0$ ，并将数据项记为

$$T(N, Q; C) = B Q^{-\theta\beta} \left(\frac{kN + h}{C} \right)^\beta. \quad (23)$$

当 $N \rightarrow 0^+$ 时，参数项 $A N^{-\alpha} \rightarrow \infty$ ；当 $N \rightarrow \infty$ 时，预算允许的数据量趋于零，数据项趋于无穷。因此固定质量下的极小值不会逃向参数量的两个边界。在对数参数 $x = \ln N$ 上，其一阶条件为

$$\alpha A N^{-\alpha} = \beta T(N, Q; C) \frac{kN}{kN + h}. \quad (24)$$

左侧严格下降。令右侧为 $R(N) > 0$ ，则

$$\frac{d \ln R}{d \ln N} = 1 + (\beta - 1) \frac{kN}{kN + h} > 0. \quad (25)$$

由于 $0 < kN/(kN + h) \leq 1$ 且 $\beta > 0$ ，该不等式成立。两侧在正半轴上恰交一次，导数在交点前为负、之后为正，因此该驻点是固定质量问题的唯一全局极小点。这一结论只针对固定 Q 的一维问题，不自动推广到外层质量剖面；对外层仍需比较内部候选与端点。

当 $Q = Q_0$ 时 $h = 0$ ，式 (24) 可以直接解得

$$N_0^*(C) = \left[\frac{\alpha A}{\beta B} Q_0^{\theta\beta} \left(\frac{C}{k} \right)^\beta \right]^{1/(\alpha+\beta)}, \quad (26)$$

$$D_0^*(C) = \frac{C}{kN_0^*(C)}. \quad (27)$$

表 8 由该解析式独立计算，并与预算消元程序保存的固定质量解逐项比较，相对差异低于 10^{-10} 。这种核验针对求解实现与单位换算，不能替代对损失模型的外部验证。

表 8 固定基线质量下的解析配置与数据参数比

C (FLOPs)	N_0^* (B)	D_0^* (B)	D_0^*/N_0^*	L_0^*
10^{19}	0.1882	8.290	44.05	3.07306
10^{22}	4.2582	366.394	86.05	2.16886
10^{24}	34.0626	4580.272	134.47	1.92606

解析式还给出两类资源随预算增长的条件标度： $N_0^* \propto C^{\beta/(\alpha+\beta)}$ ， $D_0^* \propto C^{\alpha/(\alpha+\beta)}$ 。当前 $\alpha \approx 0.340$ 、 $\beta \approx 0.280$ ，因此数据量的预算指数略大于参数量。数据参数比满足

$$\frac{D_0^*}{N_0^*} \propto C^{(\alpha-\beta)/(\alpha+\beta)}. \quad (28)$$

所以即使完全不投入额外质量成本，最优 D/N 也不必是常数，更不能由单位相同推出 $N = D$ 。实际比例同时依赖系数、指数、基线质量和上下文成本。等数值方案适合展示朴素配置的代价，固定质量解析解则适合隔离额外质量投入的收益，两种基线承担不同检验任务。

6.4 质量边界条件与预算的边际价值

记固定质量最优值为 $F(Q; C) = \tilde{L}(N^*(Q), Q)$ 。在可微内点上，参数驻点使关于 $N^*(Q)$ 的链式项消失，因而

$$\frac{dF}{dQ} = \beta T \left[-\frac{\theta}{Q} + \frac{h'(Q)}{kN^*(Q) + h(Q)} \right]. \quad (29)$$

方括号左项为提高质量对有效数据的相对增益，右项为质量成本增加导致的可训练数据量收缩。内点候选要求二者相等；在 Q_0 处，若右导数非负，局部上不应继续提高质量；在 $Q = 1$ 处，若左导数非正，继续沿可行方向降低质量会增大损失，上界满足相应必要条件。

式 (29) 也表明，判断是否购买质量不能只比较 $g(Q)$ 的绝对大小。相同的单位 token 质量成本，面对不同参数规模时占总成本的比例不同；同时，质量指数 θ 决定预期收益的强度。三型成本函数的参数和曲率均不相同，因此某一个预算档的排序不能作为所有预算档的固定排序。

对预算也可作包络分析。在候选最优解所在分支可微且预算活跃时，

$$-\frac{\partial L^*}{\partial \ln C} = \beta T^*, \quad \mu^* = \frac{\beta T^*}{C}, \quad (30)$$

其中 μ^* 是一阶预算影子价格。它描述预算发生小幅变化时的模型内边际降损，不是硬件报价，也不是增加一块设备必然带来的实际提升。在固定质量、无新增质量成本的基线上，两类可约损失按 $C^{-\alpha\beta/(\alpha+\beta)}$ 衰减，给出预算收益递减的解析解释。实际改变较大预算时，应使用重新优化后的差值，而不能把这一局部导数无限线性外推。

6.5 数值求解

数值求解先利用单调性消去预算约束。令 $k = U^2(6 + \eta L_{\text{ctx}})$ 、 $h(Q) = U[g(Q) - g(Q_0)]_+$ ，由于损失随数据量严格下降，有

$$D = \frac{C}{kN + h(Q)}, \quad \tilde{L}(N, Q) = E + AN^{-\alpha} + BQ^{-\theta\beta} \left(\frac{kN + h(Q)}{C} \right)^\beta. \quad (31)$$

在固定 Q 下，关于 $\ln N$ 的一阶平衡可写为 $\alpha AN^{-\alpha} = \beta BQ^{-\theta\beta} ((kN + h)/C)^\beta kN / (kN + h)$ ；左侧严格下降、右侧严格上升，故驻点唯一。质量低于 Q_0 不节省成本且损失更高，搜索区间可缩为 $[Q_0, 1]$ 。具体步骤为：

1. 在 129 个质量网格点上用括区间求根法求唯一的 N 驻点，并由预算等式计算 D 。
2. 对网格中的局部低值区间及两个端点相邻区间作有界细化，再显式比较 $Q = Q_0$ 、 $Q = 1$ 与所有候选。
3. 复算物理成本、参数驻点残差与质量单边条件；以 513 点质量网格和独立的 20 起点 SLSQP 交叉核验。SLSQP 不再接收迭代次数耗尽的结果。

九组主预算配置在两种求解器间的损失差小于 10^{-7} ，质量网格加密后的损失差小于 10^{-8} ，约化一阶残差低于 10^{-6} 。这些检查提高数值可信度，但外层质量搜索仍不是数学上的全局最优证明。结构转移仍在 $\log_{10} C \in [18, 25]$ 的 36 个预算点上计算份额导数。

以指数型质量成本和 $C = 10^{22}$ FLOPs 为例，候选配置为约 5.483B 参数、261.4B token、 $Q = 0.9665$ 。代回物理成本式，基础训练、质量与注意力开销分别约占预算的 0.860、0.081、0.059，三项之和约为 1。这一回代检验能发现单位错误或越预算解，但不能检验损失模型在该配置处的外推精度。

预算增大时指数型下的候选最低损失从 3.073 经 2.151 降至 1.914，逐步趋近不可约损失 1.69，参数量与数据量单调增，预算利用率约 100%。相对质量固定为当前 Q_0 、取 $N = D$ 的等数值对照方案（它不是 Chinchilla 最优比例），三档损失改善依次为 0.234、0.131、0.080。低预算时幂型与对数型的候选 Q 均停在 Q_0 ，指数型略升至 0.506；成本函数的区别仍会改变中档资源配置（表 9）。另固定 $Q = Q_0$ 后重新优化 N, D ，三档损失分别为 3.07306、2.16886、1.92606；与这一公平对照相比，指数型质量投入的净改善仅为 0.00018、0.01812、0.01215，其余改善来自规模与数据配比的调整。

指数型三档中的基础训练份额为 0.920、0.860、0.923；质量份额为 0.017、0.081、0.015，并非单调变化（图 15）。因此用连续预算扫描寻找候选结构转移位置。

6.6 结构性转移的定义与识别

给出可判定定义：以各部分算力份额 $s_X(C) = C_X^*/C$ 对预算对数的导数峰值定位转移点，

$$C^\dagger = \arg \max_C \left| \frac{d s_X(C)}{d \log C} \right|, \quad (32)$$

并检查数值解是否触及质量边界或质量成本铰链。连续扫描预算对数区间、数值差分求份额导数可给出候选转移点；离散网格和成本函数选择会影响其位置。

结果。在 $\theta = 0.5$ 、指数型质量成本和当前 36 点扫描网格下，质量份额导数的最大绝对值约在 10^{19} FLOPs，作为模型内候选转移点；按 10^{-7} 的质量容差，网格上的首次激活

表 9 三档预算下的最优算力配置

C (FLOPs)	$g(Q)$	N^*	D^*	Q^*	L^*	s_{train}	s_Q	s_{attn}
10^{19}	指数型	0.193	7.9	0.5057	3.0729	0.9205	0.0167	0.0628
	幂型	0.188	8.3	0.4879	3.0731	0.9361	0.0000	0.0639
	对数型	0.188	8.3	0.4879	3.0731	0.9361	0.0000	0.0639
	等数值基线 $N = D$	1.249	1.2	0.4879	3.3066	0.9361	0.0000	0.0639
	固定质量 最优基线	0.188	8.3	0.4879	3.0731	0.9361	0.0000	0.0639
10^{22}	指数型	5.483	261.4	0.9665	2.1507	0.8600	0.0813	0.0587
	幂型	5.758	240.3	1.0000	2.1525	0.8300	0.1133	0.0567
	对数型	5.225	287.8	1.0000	2.1458	0.9023	0.0361	0.0616
	等数值基线 $N = D$	39.499	39.5	0.4879	2.2813	0.9361	0.0000	0.0639
	固定质量 最优基线	4.258	366.4	0.4879	2.1689	0.9361	0.0000	0.0639
10^{24}	指数型	40.740	3773.9	1.0000	1.9139	0.9225	0.0145	0.0630
	幂型	40.893	3747.8	1.0000	1.9140	0.9195	0.0177	0.0628
	对数型	40.280	3854.6	1.0000	1.9136	0.9316	0.0048	0.0636
	等数值基线 $N = D$	394.989	395.0	0.4879	1.9935	0.9361	0.0000	0.0639
	固定质量 最优基线	34.063	4580.3	0.4879	1.9261	0.9361	0.0000	0.0639

点为 10^{19} FLOPs。基线处右导数过零给出连续候选阈值约 8.04×10^{18} FLOPs，上界驻点方程给出质量饱和候选阈值约 1.67×10^{22} FLOPs；后两者须与全轨迹对照。位置依赖评分基线、成本函数和搜索网格，不是纯数据驱动的物理阈值。转移点见图 16。

份额随预算对数演化曲线上叠加的份额导数，其峰值位置即由式 (32) 定位的转移点 (图 16)。由于该最优轨迹来自确定性优化、不存在重复抽样，图中不画置信带，而以份额导数曲线的峰值给出结构判据，已检查预算消元后的驻点及质量单边条件，但局部残差不能单独证明全局换支或转移位置。

6.7 上下文长度的临界值与敏感性

上下文长度为外生参数。令注意力开销等于训练开销 $\eta N D L_{\text{ctx}} = 6 N D$ ，与参数量、数据量无关，解得临界上下文

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 3 \times 10^4 \text{ tokens.} \quad (33)$$

当上下文长度达到该值时注意力开销与训练开销相当，超过它长上下文将显著挤压训练预算。敏感性扫描的取值严格取自模型架构元数据的实测集，即 2048、4096、8192、32768 与 131072。图 17 展示最优配置随上下文长度的变化。

在中档预算下，上下文由 2048 增至 131072 时，注意力份额从约 0.059 升至约 0.777 (图 17)。临界值 3×10^4 位于 8192 与 32768 之间；上下文不小于 32768 时，按当前成本模型，注意力开销超过基础训练开销。可行域见图 18。




图 15 三档预算下的算力份额构成




图 16 最优份额演化与结构性转移点




图 17 最优配置随上下文长度的变化

在参数量-数据量-质量空间中，式 (17) 的预算面与候选解位置表明预算约束活跃 (图 18)。综合本章：预算增大使候选最小损失下降；当前扫描显示约 10^{19} FLOPs 的质量份额变化峰值，长上下文在 3×10^4 tokens 附近使注意力开销赶上基础训练开销。

6.8 质量剖面与最优配置的稳定性

求得一个最优质量值之后，还应检查其附近损失曲线是否陡峭。图 19 在每一个固定质量上重新优化 N, D ，绘制相对于联合候选最优值的可约损失增幅：

$$P_C(Q) = 100 \frac{F(Q; C) - L^*(C)}{L^*(C) - E}. \quad (34)$$

使用 $L^* - E$ 作为分母，是为了避免不可约常数 E 掩盖可优化部分的差别。曲线上的非负增幅是确定性条件损失，并不是置信界。固定 Q 后重新配置其余变量，也区别于只改变质量而将参数量和数据量锁死的单因素扰动。

低预算下，候选最优质量只略高于基线；提高到更高质量将挤出大量训练数据，使总损失上升。中预算下最优值移向高质量端，但尚未完全触及上界；高预算下则以 $Q = 1$ 为候选最优。剖面反映了上述变化的连续过程：最优点位置给出条件决策，而最优点附近的曲率说明轻微偏离的代价。若某一段较平坦，保留更多质量小数位并不意味着工程决策更




图 18 算力预算可行域与结构转移




图 19 三档预算的质量剖面；每个质量点均重新优化参数量与数据量

加精确，还需考虑评分噪声和实施成本。

6.9 总收益中规模配比与质量投入的分离

将等数值基线、固定质量最优基线和联合优化值分别记为 L_{eq} 、 L_{Q_0} 与 L^* ，则总降损存在精确的分解

$$L_{\text{eq}} - L^* = \underbrace{L_{\text{eq}} - L_{Q_0}}_{\text{规模与数据配比调整}} + \underbrace{L_{Q_0} - L^*}_{\text{放开质量决策的净改善}}. \quad (35)$$

两项都在同一个损失函数、同一预算和同一上下文条件下比较。第二项允许质量变化后重新优化 N, D ，表示引入质量决策自由度的总净效益，并不等于只改变 Q 的偏导收益。由于联合可行集包含 $Q = Q_0$ 的解，精确求解时该净改善应非负；数值实现则用容差处理机器精度量级的差异。




图 20 连续预算下的收益分解及质量净改善占固定质量可约损失的比例

图 20 显示，相对朴素等数值方案的优势，不能全部归到数据质量上。低预算档放开质量决策仅带来约 0.00018 的降损，大部分收益来自重新配置模型规模与 token 数。中预算的质量净改善扩大到约 0.01812，高预算为约 0.01215；绝对改变量并非随预算一直增加。由于高预算下总可约损失也下降，相同绝对量与相对量可以呈现不同变化趋势，应分别报告。

还需区分质量水平和质量成本份额。预算增大时，模型可能选择更高的 Q ，但随着 N 增大， kN 相对于有界质量区间内的 $h(Q)$ 更大，从而 $C_Q/C = h/(kN + h)$ 可以下降。因此“高预算质量份额较低”不代表“高预算不重视质量”。在本模型中，达到质量上界后无法进一步增加 Q ，新增预算主要流向规模和数据，质量份额下降具有明确的约束解释。

这些结论可用于形成条件配置规则：先以固定质量解析方案作为可行起点；检查质量基线处的单边收益是否足以覆盖数据量收缩；若足以覆盖，再沿质量剖面寻找内部候选并比较上界；最后用统一的实际成本式回算预算。该顺序能够区分基线选择、单位错误和数值搜索失败，但不会消除对真实损失函数、数据质量成本与上下文成本的标定需求。

7 问题四：规模与非规模贡献分解、损失-基准桥接与能力前沿预测

本章分析规模和年份与基准能力的关联，建立损失到基准的探索性桥接，最后在三档能力趋势假设下预测有许可证记录模型的经验前沿。

7.1 综合能力度量与口径声明

综合能力取六维基准均分（指令遵循、综合推理、数学、研究生级问答、多步推理与专业知识）：

$$\text{Cap} = \frac{1}{6} \sum_{k=1}^6 B_k, \quad k \in \{\text{IFEval}, \text{BBH}, \text{MATH}, \text{GPQA}, \text{MUSR}, \text{MMLU-PRO}\}. \quad (36)$$

口径显式声明：前沿样本要求许可证有明确名称，排除空值、other、unknown，并排除 C4 匹配字段明确标注不开放权重的记录，得到 2509 个模型。此规则未逐项审核许可证条款，仍是可复现的操作性代理。时间轴明确使用榜单提交日期；另将模型分为预训练（含持续预训练）、对话或微调、合并及其它类型，分别保存月度前沿。C3 全量 4599 条记录中，4573 条来自榜单、26 条来自历史论文或报告；其日期粒度和评测口径不一致，因此单列覆盖检查，不混入月度主拟合。

7.2 规模与年份项的描述性分解

以榜单数据回归综合能力对规模变量与时间，检查两项在所选样本窗中的统计关联：

$$\text{Cap}_i = f(\ln N_i) + h(t_i) + \varepsilon_i, \quad (37)$$

其中规模项 f 和时间项 h 分别给出规模、年份与能力的统计关联。年份项可能同时吸收数据、训练配方、模型组成和评测变化，不能直接解释为纯技术进步。在时间窗 $[t_0, t_1]$ 上两项回归增量的形式占比为

$$\text{scale\%} = \frac{\Delta f}{\Delta f + \Delta h}, \quad \text{nonscale\%} = \frac{\Delta h}{\Delta f + \Delta h}, \quad \text{scale\%} + \text{nonscale\%} = 100\%. \quad (38)$$

结果与识别假设。在 4561 个有效模型上回归得 $\text{Cap} = -24576 + 6.27 \ln N + 12.14 t$ ，决定系数 0.462；年份系数是控制参数量后的条件关联，不具因果解释。两变量之外仍有大量系统性变异。所选时间窗内平均参数规模下降，使回归规模项增量为负；按式 (38) 计算的两项份额约为 -25% 与 125%。超出 0-100% 只是负增量下的比值结果，且分母由拟合增量而非观测到的能力变化构成。它只能描述这套回归与样本窗，不能据此证明非规模技术进步的因果份额。新增类型固定效应后，年份系数由 12.14 降至 9.96 点/年，HC3 标准误差约 0.57；说明类型构成确会影响时间关联。HC3 未进一步校正模型家族聚类。累计演化使用累计样本的平均提交年份，避免把窗口末日期误当均值。占比随时间的演化见图 21。

图 21 用零线标明规模项在所选窗口内的负增量。首期总增量仅约 0.0006 点，两项相互抵消使占比超过 $\pm 40000\%$ ；故下图采用对称对数轴（ $\pm 100\%$ 内为线性），保留全部数值，解释时优先依据上图的绝对增量。该结果对时间窗、样本组成和回归设定敏感，适合作为描述性分解，不宜称规模为能力提升的净拖累。




图 21 规模与年份项的回归增量分解

7.3 损失—基准桥接映射

用同时含验证损失与六维基准的桥接样本建立损失到能力的单调映射，按可比性分层（高可比来自可与训练轨迹对照的模型，其余为中可比）。用单调递减的 sigmoid 型回归

$$\widehat{\text{Cap}} = \frac{S_{\max}}{1 + \exp(a(L - L_0))} + c, \quad a > 0 \text{ (损失 } \uparrow \Rightarrow \text{能力 } \downarrow), \quad (39)$$

分层拟合参数，并约束 $0 \leq c \leq c + S_{\max} \leq 100$ ，保证预测在评分范围内；采用稳定 sigmoid 计算避免指数溢出，并逐点留一检验。

结果与不确定性。高可比层样本仅 7 条，决定系数约 0.40；中可比层 68 条，决定系数约 0.36。高可比层留一 RMSE 为 0.466，反而高于训练均值对照的 0.424；中可比层留一 RMSE 为 9.69，低于均值对照的 11.53。映射只能作为损失到基准能力的探索性桥梁，不能给出可靠的模型外推精度。下一节的前沿直接由榜单能力值计算，不经过这条桥接，因此其预测区间不含桥接误差。图 22 展示分层样本与拟合曲线。

分层拟合的函数按约束随损失单调下降，但散点仍有较大离散（图 22）。若用问题三的最优损失推算能力，必须另行传播桥接参数与残差的不确定性；此处未给出那类能力预测。




图 22 损失到能力的分层桥接

7.4 能力趋势情景下的经验前沿预测

将通过上述筛选的模型按月分箱，至少有两条记录的月份取六维均分的第 90 百分位作为经验前沿。实际有效月份仅 10 个，覆盖约 2024.46 至 2025.21。在这些月度点上拟合线性趋势；残差自助重采样后联合重新拟合截距与斜率，并从中心化原残差中独立抽取一次月度预测残差。以拟合的末期水平 $\hat{a}_T$ 为锚，情景系数 $s \in \{0, 0.5, 1\}$ 缩放历史能力前沿斜率。第 b 次自助样本在 Δ 个月后的预测为

$$F_{s,\Delta}^{(b)} = \text{clip}_{[0,100]} \left(\hat{a}_T^{(b)} + s \hat{\beta}^{(b)} \frac{\Delta}{12} + \epsilon^{(b)} \right), \quad \Delta \in \{12, 24\}. \quad (40)$$

其中 $\hat{a}_T^{(b)}$ 与 $\hat{\beta}^{(b)}$ 来自同次自助重拟合，保留二者的协方差； $\epsilon^{(b)}$ 独立抽取；共进行 2000 次。对 $F_{s,\Delta}^{(b)}$ 取经验分位数，得到相对样本末点约 2026.21 和 2027.21 的预测区间：

$$\text{Frontier}(t + \Delta) \in [\hat{F}_{10}(t + \Delta), \hat{F}_{90}(t + \Delta)], \quad \Delta \in \{12, 24\} \text{ 月}. \quad (41)$$

在 C4 中限定开放权重且领域包含语言的记录，2019–2025 年训练算力中位数约以每年 3.86 倍增长；同时登记训练数据量字段的可用覆盖，只为情景提供背景；数据并未估计训练算力增速与能力前沿斜率之间的弹性，因此三档系数是明确的假设。每个情景内的 P_{10} – P_{90} 区间包含趋势估计和月度残差的不确定性；不同情景之间的差异须单独比较，桥接误差参与计算。表 10 汇总三情景结果。

短期回测。为检验线性趋势是否至少优于简单基线，从前 5 个有效月度点开始，每次只用已观测点重新拟合并预测下一点，共得 5 次一步预测。趋势模型的平均绝对误差为 1.77 个能力点，平均误差（预测减实际）为 +0.80 点；直接沿用上一月前沿的平均绝对误差为 1.47 点。趋势模型在这一小样本回测中没有优于末值延续，表明斜率外推存在乐观偏差风险。一步回测既不能校准 12-24 个月区间，也无法覆盖未来模型组成变化；下表的远期数值仅作条件情景计算。

表 10 能力前沿情景预测分位数

情景	斜率系数	期限	P10	P50	P90
维持	1.0	12 月	58.86	64.05	70.17
		24 月	76.87	85.41	94.50
放缓	0.5	12 月	49.79	53.33	58.04
		24 月	58.86	64.05	70.17
停滞	0.0	12 月	40.45	42.52	46.65
		24 月	40.45	42.52	46.65
历史末值	—	2025.21			41.89
历史斜率	—	—		21.19 点/年	

按上述假设，24 个月中位数在系数 1、0.5、0 下分别约为 85.4、64.1、42.5（表 10）。零斜率情景的 12 与 24 个月分布相同；其余情景随时间上升是线性趋势和正系数的模型结果，不是已验证的能力不倒退规律。历史末值约 42、拟合斜率约 21.2 点每年；以不足一年数据外推两年，绝对数值应谨慎使用。前沿分位带见图 23。




图 23 能力前沿情景预测区间

图 23 展示各情景内的 10%–90% 分位带；零斜率情景的区间不随期限扩大，另两档随斜率估计误差扩大。图中超出历史范围的部分均为情景外推，纵轴为六维基准均分 0–100。

有限月度点、样本组成变化和情景映射假设均未被区间充分覆盖。

7.5 逐任务聚合分析

仅用榜单汇总列不足以刻画能力短板，本文遍历逐任务评测记录，按目录取最新可解析记录、跳过损坏文件做逐任务聚合。共解析 1860 个目录（六维完整 1854、损坏跳过 7），覆盖满足要求。六维缺项的 6 个模型不参与均分排名，各任务均值仍使用该任务可用记录。这里的原始指标未经过榜单的机会水平归一化，不能直接与上一节的综合榜单得分混用。各任务难度均值为：指令遵循 40.2、综合推理 47.5、数学 11.4、研究生级问答 29.8、多步推理 40.0、专业知识 32.0，其中数学的原始均值最低；不同任务的指标与机会水平不同，不能直接据此确定难度排序。图 24 展示前沿模型的六维剖面。

前沿模型在综合推理与指令遵循维度较强，而在数学与研究生级问答维度普遍偏弱，六维剖面提示应进一步在各任务自身的统一计分下分析薄弱环节（图 24）^[16]。这与式 (36) 均分口径下的综合能力互为补充：均分给出总体水平，逐任务剖面给出结构短板。




图 24 前沿模型逐任务能力剖面

7.6 样本组成变化与分类型前沿

总体经验前沿是按月份对当期样本分布取分位数，它并不对应一个固定模型随时间重复训练的轨迹。设第 t 月不同模型类型的比例为 π_{kt} 、各类型能力分布为 $H_{kt}(x)$ ，则总体分布为

$$H_t(x) = \sum_k \pi_{kt} H_{kt}(x), \quad F_t = \inf\{x : H_t(x) \geq 0.9\}. \quad (42)$$

一般情况下，总体第 90 百分位不等于各类型第 90 百分位的加权平均。即使每类能力分布保持不变，只要类型比例改变，总体前沿也可能移动；反过来，某一类型前沿上升，也未必使总体分位数等幅上升。因此，将所有月度变化直接解释为纯算法进步，会把样本构成效应混入趋势。

表 11 按模型类型分层的前沿样本与线性斜率

类型	总记录	月最少	月最多	斜率（点/年）
对话/微调	1589	80	234	+18.17
合并	674	19	116	+27.04
预训练	239	10	74	-7.30

表 11 使用与主前沿相同的筛选和计分规则，分别统计三类主要模型。“其它”类仅有 7 条记录，不为其拟合趋势。预训练组的月度样本量最少为 10，前沿波动也较大；该组的负拟合斜率不表示预训练技术随时间退步，而是当前观测窗口、当期提交对象和样本量共同决定的描述。对话或微调、合并模型占据绝大多数记录，其走势对总体前沿的影响更大。




图 25 同一筛选规则下的分类型月度能力前沿；各曲线描述当月提交样本

回归分析中的类型控制给出同样的提醒：加入类型虚拟变量后，年份系数由 12.14 降至 9.96 点/年，说明类型构成可以解释一部分时间关联，但仍不能据此把剩余年份系数认定为纯技术效应。模型家族、重复微调、参数来源、训练数据和评测版本都可能造成残余依赖。当前 HC3 标准误针对异方差调整，没有将同一家族的多条记录视为一个独立簇；其数值不应被解释为已经覆盖所有抽样相关性。

7.7 滚动回测中的可用信息与预测失误

前沿外推必须先通过只使用过去信息的检验。第 j 次测试将前 $j - 1$ 个有效月度点用于拟合，在第 j 月预测前沿；不能先用全部月份估计斜率，再把历史点称为测试集。本文从 5 个训练月份开始，依次得到 5 个一步预测，并以最近一期真实前沿作为简单基线。表 12 给出每次预测，而不仅报告平均误差。

表 12 扩展窗口的一步预测与实测前沿

测试时间	实测	趋势预测	末值预测	趋势误差
2024.875	34.592	37.039	34.670	+2.447
2024.958	39.953	37.518	34.592	-2.435
2025.042	39.986	40.670	39.953	+0.684
2025.125	40.779	42.350	39.986	+1.571
2025.208	41.887	43.616	40.779	+1.729

均方根误差和平均绝对误差分别为

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{j=1}^m (\hat{F}_j - F_j)^2}, \quad \text{MAE} = \frac{1}{m} \sum_{j=1}^m |\hat{F}_j - F_j|. \quad (43)$$

RMSE 对较大的预测偏差给予更高权重；平均有符号误差则检查是否持续高估或低估，不能替代绝对误差。当前趋势模型 MAE 为 1.773，RMSE 为 1.889，平均有符号误差为 +0.799。末值延续的 MAE 为 1.475。两者使用完全相同的测试月份，因而比较不受测试样本数量差异影响。




图 26 扩展窗口的一步前沿预测与误差；训练窗口仅包含测试月份之前的数据

图 26 将前沿的跳跃、平台与趋势预测放在同一时间轴上。一个较平稳的后续月份可能使末值基线表现良好，而前期上升趋势会继续向上外推；反之，出现跳跃时末值延续也

可能明显低估。当前只有五次检验，无法为两类方法的长期优劣作稳定排序，但已经足以提醒：线性趋势在这组数据上并没有获得优于简单基线的短期预测证据。

因此，本文保留趋势情景的用途在于展示不同能力增长假设的后果，而不是宣称已经找到预测未来的最佳模型。若要把这一情景工具改为部署预测，应扩大历史窗口，按滚动起点评估多个预测期限，并在模型选择之后保留最终未参与调参的时间段。对区间预测还需检查实际覆盖率与区间宽度；只给出 Bootstrap 分位带，不能保证远期观测以相应概率落在其中。

7.8 桥接与情景区间所覆盖的不确定性

损失-能力桥接和能力前沿外推需要分别解释。对桥接，单调性约束保证在同一拟合层内损失减小不会降低预测能力，但这种方向来自函数约束，并不是额外的验证结果。高可比层的留一 RMSE 与均值基线之比约为 1.10，中可比层约为 0.84；这一无量纲比较表明，两层的预测价值并不一致。层间原始误差数值相差很大，也与能力值的变化范围不同有关，不能据此说高可比层的泛化能力远好于中可比层。

对前沿，在尚未裁剪到 $[0, 100]$ 之前，令预测期限为 $u = \Delta/12$ 年，则抽样预测量的方差可展开为

$$\text{Var}(F_{s,\Delta}) = \text{Var}(\hat{a}_T) + s^2 u^2 \text{Var}(\hat{\beta}) + 2su \text{Cov}(\hat{a}_T, \hat{\beta}) + \text{Var}(\epsilon), \quad (44)$$

其中最后一项使用独立抽取的月度预测残差。联合重拟合保留了截距与斜率的协方差；若只扰动斜率而固定锚点，会遗漏前两者共同估计产生的变化。取经验分位数和边界裁剪之后，区间不再简单由正态方差决定，但该展开能说明各误差来源分别通过什么通道影响预测。

当 $s = 0$ 时，式 (44) 中含期限的项消失，故本实现的 12 月与 24 月停滞情景区间相同。这是“固定水平加同分布月度波动”的建模选择，不是越远期越没有额外风险。若未来存在随机游走、结构突变或评测改版，停滞情景的风险也可能随期限增加；当前区间并未包含这些机制。维持与放缓情景之间的差异属于假设差异，也不应并入单一情景的 Bootstrap 置信说明。

此外，C8 原始任务分数与榜单六维归一化分数存在口径差别。原始数学均值较低可用于描述该指标上的观测分布，却不能直接证明数学比所有其它任务更难；各任务的机会水平、评分上限和测试样本组成不同。使用桥接或前沿结果制定资源策略时，应先确定关心的是综合均分、某一任务的短板，还是某种部署约束下的表现，再选择对应的目标与验证集。

8 模型检验与灵敏度分析

本章对四个模型的关键结论作独立复核，并对高敏感假设做扰动分析，说明结果的适用范围。

8.1 独立复核

问题一另以不导入主评分模块的脚本从压缩原始记录重算，51230 条 A1 逐条分数与保存值最大差异为 2.3×10^{-16} ，A2/A3 的域均值与冲突计数均一致。与 CRITIC、22 项等权、argmax 解码的七域排序 Kendall 相关分别为 0.333、0.238、0.810，提示权重选择是主要不确定来源；A2/A3 的同名域均值接近 A1，不能证明其余域的泛化性。问题二的经典律在 B2、B4、B5 三组数据上分层验证；广义律在留出集的均方根误差 0.675 低于独立重拟合无质量基线的 0.784，但 $Q = 1$ 的零退化误差是公式恒等式。问题三把候选配置重代入物理 FLOPs 公式核验，三项总算力均未超预算；加密质量网格与独立 SLSQP 的损失差小于 10^{-7} ，约化一阶残差小于 10^{-6} ，但仍不能据此证明全局最优。问题四的一步滚动回测中，趋势模型平均绝对误差 1.77 高于末值延续的 1.47。

8.2 灵敏度分析

质量放大指数 θ 不是可由现有质量标度识别的估计量，故对 Q_0 与 θ 分别作条件扰动。在指数型质量成本、 $L_{\text{ctx}} = 2048$ 和同一预算消元与质量剖面求解规则下，重求三档预算的候选配置；结果见表 13。

表 13 质量基线与指数扰动下的候选最优质量

情景	Q_0	θ	$Q_{10^{19}}^*$	$Q_{10^{22}}^*$	$Q_{10^{24}}^*$
基准	0.4879	0.5	0.506	0.966	1.000
Q_0 降 20%	0.3903	0.5	0.528	0.967	1.000
Q_0 升 20%	0.5855	0.5	0.585	0.965	1.000
$\theta = 0.2$	0.4879	0.2	0.488	0.821	1.000
$\theta = 0.8$	0.4879	0.8	0.585	1.000	1.000

Q_0 上下扰动 20% 时，低预算候选质量从基准 0.506 变为 0.528 或 0.585；中预算约 0.965–0.967，高预算均为 1。因此低预算结果对新基线并非不敏感。固定 Q_0 而将 θ 从 0.2 改为 0.8，低预算质量由 0.488 升至 0.585，中预算由 0.821 升至边界 1。不同 θ 对应不同损失函数，情景间损失值不能解释为模型性能提升。

冲突降权因子 $\delta \in \{0.3, 0.5, 0.7, 1.0\}$ 的扫描中七域排序均不变。三型质量成本在低预算的候选 Q 为 0.506、0.488、0.488；中预算差异更大，为 0.967、1、1。能力前沿的三档斜率系数决定情景间差异，每档内的自助区间只覆盖趋势估计和月度残差，不包含情景选择或结构性模型误差。

8.3 评分假设向资源配置传播的路径

问题一评分变化会通过 Q_0 改变质量成本的起算位置，而质量指数变化会改变目标函数本身，两类扰动不能混为同一种误差。三组权重网格得到的 Q_0 范围约为 0.455–0.511，它是确定性评分方案的取值范围。问题三另外采用 Q_0 上下 20% 的压力情景，覆盖范围更宽；该压力情景不表示基线质量存在已估计的 20% 统计误差。

表 14 除质量水平外，还列出中档预算的参数量、数据量和质量增量。只比较 Q^* 容易忽略成本基线移动：相同 Q^* 在不同 Q_0 下，所需额外质量成本不同；而相近的质量水平也可以对应不同的规模与数据配置。基线提高时，部分原本需要支付的质量成本不再计入增量支出，节省的预算可以重新分配，不能据此推断现实中基线提高没有代价。

表 14 中档预算下的配置敏感性：绝对质量与增量质量

情景	$N^*(B)$	$D^*(B)$	Q^*	$Q^* - Q_0$
基准	5.483	261.38	0.9665	0.4786
Q_0 降 20%	5.499	260.04	0.9672	0.5769
Q_0 升 20%	5.455	263.83	0.9651	0.3797
$\theta = 0.2$	5.127	293.60	0.8215	0.3336
$\theta = 0.8$	5.632	250.32	1.0000	0.5121

对质量指数的扰动，正确的比较对象是决策变化及其敏感程度。 θ 越大，相同质量提升在目标函数中对应更强的数据项下降，候选质量通常更高；但不同 θ 下报告的损失来自不同函数，不能把二者的差值称为某个算法真实获得的提升。若要评价“按错误指数做决策”的损失代价，需要选定同一个参考损失函数，将所有情景配置回代该参考函数；这属于

新的稳健决策实验，与本表的条件配置比较不同。

8.4 复核层级与结论的证据边界

本文将复核分成四个层级。第一层为输入与定义核对，包括字段解码、归一化参照、样本去留和单位换算。第二层为代数与实现核对，包括百分位总体均值恒等式、 $Q = 1$ 退化、解析偏导与有限差分一致，以及固定质量解析解与数值解一致。第三层为独立算法核对，包括加密网格、SLSQP 交叉验证及预算回代。第四层为外部预测核对，包括跨来源损失误差、分组留出、桥接留一和逐月前沿回测。

前三层通过，表明程序按照声明的公式运行且主要数值误差受到控制；只有第四层直接涉及模型在未参与拟合的观测上的表现。即使第四层通过，结论也仍限于相应测试分布与预测期限。例如在一个月后的回测表现良好，不足以证明两年后区间经过校准；同尺度配比排名较准，也不等于跨尺度绝对损失准确。区分这些层级，可以避免把“程序无错误”误写成“模型已经验证”。

对新增图表，分来源 RMSE 已按样本数复原总体误差；有限增量替代曲线已回代同一目标损失；固定质量解析公式已对照主求解器保存值；滚动预测的逐月误差已重新合并复原原有 MAE。所有这些复核都围绕明确的数值对应关系进行，没有因正文扩展而改变原始附件或主模型的既有计算结果。

8.5 适用范围

经典律的直接拟合支撑范围约为参数量 0.07–12、数据量至 300（均以 10^9 计）；问题三的高预算解已超出该范围，其损失是公式外推。质量指数与能力前沿斜率系数均为高敏感假设，替代率、转移点及远期能力水平不宜作确定性解读。前沿仅有 10 个有效月度点，短期回测也未证明趋势模型优于简单基线。

9 模型评价、改进与推广

9.1 模型优点

本文四问覆盖从数据刻画到能力预测的主要环节，但数值链条仍有断点：问题一的域级质量用于问题三的质量成本基线；配比贡献尚未进入广义律数值计算；损失到能力的桥接是单独拟合的探索性映射。A1 固定参照与逐条复核使质量评分可重算；广义律在 $Q = 1$ 时满足代数退化。优化部分用 KKT 刻画结构、预算消元与质量剖面搜索候选解，并以份额导数峰值定义候选结构转移。对半合成质量标度方向异常和前沿窗口规模负增量均保留并讨论。

9.2 模型不足与改进方向

其一，质量放大指数无法从唯一一组半合成数据识别，其经验拟合落在边界且口径与部署质量不同，故下游采用了反映“质量有益”前提的取值并做敏感性；若能获得大规模真实的质量–损失联合观测，可把该指数从假设升级为估计。其二，配比没有进入当前标度律数值计算，也未联立优化 17 维配比；改进可把配比加入决策变量并以投影梯度处理单纯形约束，代价是转移分析的可解释性下降。其三，前沿预测依赖能力斜率情景假设，并未估计算力增速到能力斜率的映射，改进可引入更细的算力供给模型或以真实新发布模型滚动校正分位带。

9.3 推广

广义标度律的“有效数据量”形式可推广到其它可归一化的数据属性（如去重率、领域纯度），并在归一化边界 $Q = 1$ 退化为经典形式。问题三的三部分算力约束可扩展到含推理成本或多阶段训练的预算结构。问题四的描述性分解与分层桥接可用于其它基准体系；

这些推广均需在目标场景重新标定参数。

10 结论

本文用语义解码、A1 固定百分位参照和三组平衡权重重算问题一，得七域质量中位数 $Q_0 = 0.48788$ ；按高教育价值且判有广告的规则，A1 冲突率为 0.303%，其中 C4 的域内冲突率最高，为 1.03%。配比模型在同尺度检验上具有一定解释力，但跨尺度绝对损失预测失准。经典标度律拟合良好；广义律的质量指数仍属结构性假设。在新 Q_0 下，指数型质量成本的三档预算候选最低损失为 3.073、2.151、1.914，质量份额变化峰值约在 10^{19} FLOPs；注意力与基础训练开销相当的上下文长度为 3×10^4 tokens。能力前沿预测依赖情景斜率，不能视为已校准的无条件预测。质量分数与资源配置结论的主要限制是评分权重及成本函数尚无训练损失标签的联合校准。

参考文献

- [1] OpenDataLab. SlimPajama-Meta-rater dataset card, field descriptions. <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>.
- [2] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020. DOI: 10.48550/arXiv.2001.08361.
- [3] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models. arXiv:2203.15556, 2022. DOI: 10.48550/arXiv.2203.15556.
- [4] Liu Q, Zheng X, Muennighoff N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training. arXiv:2407.01492, 2024. DOI: 10.48550/arXiv.2407.01492.
- [5] Xie S M, Pham H, Dong X, et al. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining. arXiv:2305.10429, 2023. DOI: 10.48550/arXiv.2305.10429.
- [6] Penedo G, Kydlíček H, Ben Allal L, et al. The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale. arXiv:2406.17557, 2024. DOI: 10.48550/arXiv.2406.17557.
- [7] Shen Z, Tao T, Ma L, et al. SlimPajama-DC: Understanding Data Combinations for LLM Training. arXiv:2309.10818, 2023. DOI: 10.48550/arXiv.2309.10818.
- [8] Xie S M, Santurkar S, Ma T, Liang P. Data Selection for Language Models via Importance Resampling. arXiv:2302.03169, 2023. DOI: 10.48550/arXiv.2302.03169.
- [9] Wettig A, Gupta A, Malik S, Chen D. QuRating: Selecting High-Quality Data for Training Language Models. arXiv:2402.09739, 2024. DOI: 10.48550/arXiv.2402.09739.
- [10] Gao L, Biderman S, Black S, et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling. arXiv:2101.00027, 2020. DOI: 10.48550/arXiv.2101.00027.
- [11] Biderman S, Schoelkopf H, Anthony Q, et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. arXiv:2304.01373, 2023. DOI: 10.48550/arXiv.2304.01373.
- [12] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners. arXiv:2005.14165, 2020. DOI: 10.48550/arXiv.2005.14165.
- [13] Wei J, Tay Y, Bommasani R, et al. Emergent Abilities of Large Language Models. arXiv:2206.07682, 2022. DOI: 10.48550/arXiv.2206.07682.
- [14] Schaeffer R, Miranda B, Koyejo S. Are Emergent Abilities of Large Language Models a Mirage? arXiv:2304.15004, 2023. DOI: 10.48550/arXiv.2304.15004.
- [15] Liang P, Bommasani R, Lee T, et al. Holistic Evaluation of Language Models. arXiv:2211.09110, 2022. DOI: 10.48550/arXiv.2211.09110.
- [16] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding. arXiv:2009.03300, 2020. DOI: 10.48550/arXiv.2009.03300.
- [17] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models. arXiv:2302.13971, 2023. DOI: 10.48550/arXiv.2302.13971.
- [18] Le Scao T, Fan A, Akiki C, et al. BLOOM: A 176B-Parameter Open-Access Multilingual Language Model. arXiv:2211.05100, 2023. DOI: 10.48550/arXiv.2211.05100.
- [19] Koenker R, Hallock K F. Quantile Regression. *Journal of Economic Perspectives*, 2001, 15(4): 143–156. DOI: 10.1257/jep.15.4.143.

- [20] Boggs P T, Tolle J W. Sequential Quadratic Programming. *Acta Numerica*, 1995, 4: 1–51. DOI: 10.1017/S0962492900002518.
- [21] Chen C H. A Novel Multi-Criteria Decision-Making Model for Building Material Supplier Selection Based on Entropy-AHP Weighted TOPSIS. *Entropy*, 2020, 22(2): 259. DOI: 10.3390/e22020259.

A 附录：参数取值与求解步骤

A.1 题面给定常量与成本函数

问题三的算力构成与质量成本参数按题面原样载入，列于表 15。

表 15 题面给定常量与三型质量成本参数

物理量	取值	说明
注意力系数 η	2×10^{-4}	作用于三者乘积 NDL_{ctx}
Chinchilla 系数	6	每参数每 token 的训练算力
注意力临界上下文	3×10^4	由 $6/\eta$ 解析得到
指数型 $g(Q)$	$10^7 e^{6Q}$	高质量极昂贵
幂型 $g(Q)$	$5 \times 10^9 Q^4$	高质量成本居中
对数型 $g(Q)$	$2 \times 10^9 \ln(1 + 10Q)$	高质量相对可得
三档预算 C	$10^{19}, 10^{22}, 10^{24}$	FLOPs
基线质量 Q_0	0.48788	问题一七域质量中位数

三型质量成本函数在中高预算下给出相近的最优质量，但在低预算档因高质量的经济性不同而分化，这是问题三比较成本函数选择影响的依据（表 15）。

A.2 优化求解步骤

问题三先利用预算活跃条件消去 D ，在每个固定质量下求唯一的 $\ln N$ 驻点，再以质量网格、局部细化和端点比较选取候选。所有结果复算预算以及质量单边条件；另用 513 点加密网格及 20 起点 SLSQP 核验九组主预算。连续预算扫描输出份额导数和质量边界阈值。求解器一致性与局部残差不构成全局最优证明。

A.3 关于人工智能工具的使用说明

本文使用通用大语言模型辅助代码检查与修改、公式推导核验、图表生成、文字润色及 LaTeX 排版。报告数值以随文程序对题目附件的计算及已声明公式的复算为依据；模型假设、经验观测和情景外推分别标明，工具输出通过对应的数值检查后写入正文。

B 附录：核心算法代码摘录

下列代码摘自随文提交的计算脚本，仅展示关键算法；数据摄入、绘图和结果写出等实现不在纸质附录展开。完整程序见电子材料的 code/，问题一的语义解码和固定参照评分见 quality_scoring.py 与 q1_pipeline.py。

B.1 问题一：质量评分与配比回归

```

1 def _softmax(values: np.ndarray) -> np.ndarray:
2     z = values - np.max(values)
3     e = np.exp(z)
4     return e / e.sum()
5
6
7 def decode_value(name: str, value, *, mode: str = "softmax") -> float:
8     """Decode logits by class order; return NaN for missing/malformed values
9     ."""

```

```

9  if name not in LIST_INDICATORS:
10     try:
11         answer = float(value)
12         return answer if np.isfinite(answer) else np.nan
13     except (TypeError, ValueError):
14         return np.nan
15  if not isinstance(value, (list, tuple)):
16     return np.nan
17  try:
18     v = np.asarray(value, dtype=float)
19  except (TypeError, ValueError):
20     return np.nan
21  expected = 1 if name == "fineweb_edu" else 4 if name == "qurater" else 6
22     if name in PRRC else 2
23  if v.shape != (expected,) or not np.all(np.isfinite(v)):
24     return np.nan
25  if name == "fineweb_edu":
26     return float(v[0])
27  if name == "qurater":
28     # The four ratings share one source field; equal within-field
29     # averaging
30     # is an explicit modeling choice, not a claim that they are one
31     # construct.
32     return float(v.mean())
33  if mode == "argmax":
34     return float(np.argmax(v) / 5 if name in PRRC else np.argmax(v))
35  if mode != "softmax":
36     raise ValueError(f"unknown decoding mode: {mode}")
37  probs = _softmax(v)
38  return float((probs @ (np.arange(6) / 5)) if name in PRRC else probs[1])

```

代码 1 二分类与六分类信号的语义解码

```

1  def normalize(df: pd.DataFrame, reference: dict) -> pd.DataFrame:
2      """Midrank empirical CDF on A1; fixed map and clipping for A2/A3."""
3      columns = {}
4      for name in ALL_INDICATORS:
5          x = df[name].to_numpy(dtype=float)
6          x = np.where(np.isfinite(x), x, reference["median"][name])
7          x = _oriented(x, name, reference["cap"][name])
8          s = reference["sorted"][name]
9          left = np.searchsorted(s, x, side="left")
10         right = np.searchsorted(s, x, side="right")
11         columns[name] = np.clip((left + right) / (2 * len(s)), 0, 1)
12     return pd.DataFrame(columns, index=df.index)
13
14
15  def balanced_weights() -> dict[str, float]:
16      """Predeclared equal group shares and equal within-group shares, not

```

```

    entropy weights."""
17 return {name: 1 / (len(GROUPS) * len(members))
18         for members in GROUPS.values() for name in members}
19
20
21 def compute_q(R: pd.DataFrame, weights: dict[str, float] | None = None) ->
    np.ndarray:
22     weights = balanced_weights() if weights is None else weights
23     w = np.asarray([weights[name] for name in ALL_INDICATORS])
24     if not np.isclose(w.sum(), 1):
25         raise ValueError("quality weights must sum to one")
26     return np.clip(R[ALL_INDICATORS].to_numpy() @ w, 1e-6, 1.0)

```

代码 2 A1 固定百分位与三组平衡评分

```

1 def detect_conflict(df: pd.DataFrame, R: pd.DataFrame,
2                     edu_threshold: float) -> tuple[np.ndarray, dict]:
3     """High education rank AND predicted advertisement (probability > 0.5).
4     """
5     edu = R["fineweb_edu"].to_numpy(dtype=float)
6     has_ad = 1.0 - df["ad_en"].to_numpy(dtype=float)
7     mask = (edu >= edu_threshold) & (has_ad > 0.5)

```

代码 3 高教育价值与广告判定的冲突条件

```

1 for lc in loss_cols:
2     y = np.log(loss[lc].values.astype(float)) # 对数域 ln L
3     dom = lc.replace("metric/the_pile_", "").replace("_val_loss", "")
4     # 带截距的线性回归 ln L = a + b · p (p 已在单纯形上)
5     X = np.hstack([np.ones((len(P), 1)), P])
6     beta, *_ = np.linalg.lstsq(X, y, rcond=None)
7     yhat = X @ beta
8     # 截距与单纯形列线性相关: 统一为 sum(b)=0 的可识别对比编码。
9     b_mean = float(beta[1:].mean())
10    beta[0] += b_mean
11    beta[1:] -= b_mean
12    assert np.allclose(X @ beta, yhat, atol=1e-10)
13    ss_res = ((y - yhat) ** 2).sum()
14    ss_tot = ((y - y.mean()) ** 2).sum()
15    r2 = 1 - ss_res / ss_tot if ss_tot > 0 else 0.0
16    coefs[dom] = {"intercept": float(beta[0]),
17                 "b": {mix_cols[i].replace("train_the_pile_", ""): float(
18                     beta[i + 1])
19                     for i in range(17)}}

```

代码 4 单纯形配比回归及可识别系数编码

B.2 问题二：经典与广义标度律

```

1 def fit_classic(N, D, L, supplementary=False):

```

```

2  """对数域 Huber-NLS 多起点拟合经典律。返回最优参数与 R2。"""
3  N, D, L = (np.asarray(x, dtype=float) for x in (N, D, L))
4  if not all(np.isfinite(x).all() and (x > 0).all() for x in (N, D, L)):
5      raise ValueError("N,D,L 必须为有限正数")
6  upper = [max(L), 200, 1.5, 500, 1.5] if supplementary else [min(L) + 1e
7      -6, 50, 1.0, 50, 1.0]
8  best = None
9  # 多起点: alpha,beta 网格初值 + E,A,B 合理初值
10 for alpha0 in [0.1, 0.2, 0.34, 0.5]:
11     for beta0 in [0.1, 0.28, 0.4]:
12         x0 = [min(L) * 0.9, 0.5, alpha0, 1.0, beta0]
13         try:
14             res = least_squares(
15                 _residual_log_huber, x0, args=(N, D, L),
16                 loss="huber", f_scale=0.1,
17                 bounds=[0.0, 0.0, 0.01, 0.0, 0.01], upper),
18                 x_scale="jac", ftol=1e-12, xtol=1e-12, gtol=1e-10,
19                 max_nfev=20000)
20             if not res.success:
21                 continue
22             pred = classic_model(res.x, N, D)
23             ss_res = np.sum((L - pred) ** 2)
24             ss_tot = np.sum((L - L.mean()) ** 2)
25             r2 = 1 - ss_res / ss_tot
26             if best is None or res.cost < best["cost"]:
27                 best = {"params": res.x, "r2": float(r2),
28                     "cost": float(res.cost)}
29         except (ValueError, FloatingPointError):
30             continue
31 if best is None:
32     raise RuntimeError("经典标度律的全部初值均未收敛")
33 return best

```

代码 5 经典标度律的对数域稳健拟合

```

1 def generalized_model(params, N, D, Q):
2     """广义标度律  $L=E+A N^{-\alpha}+B (Q^{\theta} D)^{-\beta}$  (式9)。Q=1 退化经典。
3     """
4     E, A, alpha, B, beta, theta = params
5     # 质量增强有效数据量  $Q_{\text{eff}} = Q^{\theta} * D$  (Q=1 时退化经典)
6     Q_eff = np.power(Q, theta) * D # 等价  $Q^{\theta} * D$ 
7     Q_eff = np.clip(Q_eff, 1e-9, None)
8     return E + A * np.power(N, -alpha) + B * np.power(Q_eff, -beta)
9
10 def _residual_gen_log(params, N, D, Q, L):
11     pred = generalized_model(params, N, D, Q)
12     pred = np.clip(pred, 1e-6, None)
13     return np.log(L) - np.log(pred)

```

```

14
15
16 def fit_generalized(N, D, Q, L, classic_params, theta_bounds=(-10.0, 10.0))
17 :
18     """在经典参数基础上新增 theta, 用 B6-B8 拟合。theta 符号由数据决定（默认
19     自由）。"""
20     E0, A0, a0, B0, b0 = classic_params
21     lo_t, hi_t = theta_bounds
22     best = None
23     for theta0 in [-2.0, -0.5, 0.1, 0.5, 1.0, 2.0]:
24         if not (lo_t <= theta0 <= hi_t):
25             theta0 = 0.5 * (lo_t + hi_t)
26             # E 上界放宽: B6-B8 的 loss 尺度与 B1 不同 (Q_setpoint 重标定损失区
27             间)
28             Lmax = float(np.max(L))
29             x0 = [min(L) * 0.5, A0, a0, B0, b0, theta0]
30             try:
31                 res = least_squares(
32                     _residual_gen_log, x0, args=(N, D, Q, L),
33                     loss="huber", f_scale=0.1,
34                     bounds=([0.0, 0.0, 0.01, 0.0, 0.01, lo_t],
35                             [Lmax, 200, 1.5, 500, 1.5, hi_t]),
36                     x_scale="jac", ftol=1e-12, xtol=1e-12, gtol=1e-10, max_nfev
37                     =30000)
38                 if not res.success:
39                     continue
40                 pred = generalized_model(res.x, N, D, Q)
41                 ss_res = np.sum((L - pred) ** 2); ss_tot = np.sum((L - L.mean())
42                 ** 2)
43                 r2 = 1 - ss_res / ss_tot
44                 if best is None or res.cost < best["cost"]:
45                     best = {"params": res.x, "r2": float(r2), "cost": float(res.
46                     cost),
47                             "active_bounds": res.active_mask.tolist(),
48                             "jacobian_condition": float(np.linalg.cond(res.jac)),
49                             "optimality": float(res.optimality)}
50             except (ValueError, FloatingPointError):
51                 continue
52     if best is None:
53         raise RuntimeError("广义标度律的全部初值均未收敛")
54     return best

```

代码 6 广义标度律及质量指数拟合

B.3 问题三：预算约束下的资源配置

```

1 def solve_fixed_quality(C, Q, Q0, params, Lctx, gkind):
2     """消去预算等式中的 D; 固定 Q 时 ln N 的导数唯一过零。"""
3     E, A, alpha, B, beta, theta = params

```

```

4 k = (6.0 + ETA * Lctx) * UNIT_SCALE ** 2
5 h = UNIT_SCALE * max(g_Q(Q, gkind) - g_Q(Q0, gkind), 0.0)
6
7 def terms(log_n):
8     N = np.exp(log_n)
9     D = C / (k * N + h)
10    model_term = A * N ** (-alpha)
11    data_term = B * (Q ** theta * D) ** (-beta)
12    grad_n = -alpha * model_term + beta * data_term * k * N / (k * N + h
13        )
14    return N, D, model_term, data_term, grad_n
15
16 root = brentq(lambda x: terms(x)[-1], -80.0, 80.0, xtol=1e-12)
17 N, D, model_term, data_term, grad_n = terms(root)
18 Ct, Ctr, CQ, Cat = compute_total(N, D, Q, Q0, Lctx, gkind)
19 # Q0 处取右导数; Q<Q0 成本相同且损失更高, 故可排除。
20 grad_q = beta * data_term * (UNIT_SCALE * g_Q_prime(Q, gkind) / (k * N +
21     h) - theta / Q)
22 return {"N": float(N), "D": float(D), "Q": float(Q),
23     "L": float(E + model_term + data_term), "C_tot": float(Ct),
24     "C_train": float(Ctr), "C_Q": float(CQ), "C_attn": float(Cat),
25     "util": float(Ct / C), "profile_grad_logN": float(grad_n),
26     "profile_grad_Q": float(grad_q)}
27
28 def solve_budget(C, Q0, params, Lctx, gkind, n_starts=20, q_grid_size=129):
29     """预算消元 + 唯一 N 驻点 + Q 网格分段细化, 显式比较两 endpoints。
30
31     n_starts 仅保留旧调用接口; 主算法确定性, 不依赖随机初值。
32     Q 方向的网格细化不是全局最优证明, 另用 SLSQP 和加密网格复核。
33     """
34     if not (C > 0 and 0 < Q0 <= 1 and Lctx >= 0):
35         raise ValueError("C、Q0 或 Lctx 不满足定义域")
36     if not all(np.isfinite(params)) or min(params[1:]) <= 0:
37         raise ValueError("预算消元要求 A,alpha,B,beta,theta 为有限正数")
38     grid = np.linspace(Q0, 1.0, max(3, q_grid_size))
39     candidates = [solve_fixed_quality(C, q, Q0, params, Lctx, gkind) for q
40         in grid]
41     vals = [s["L"] for s in candidates]
42     for i in range(len(grid)):
43         if i in (0, len(grid) - 1) or (vals[i] <= vals[i - 1] and vals[i] <=
44             vals[i + 1]):
45             fit = minimize_scalar(
46                 lambda q: solve_fixed_quality(C, q, Q0, params, Lctx, gkind)[
47                     "L"],
48                 bounds=(grid[max(i - 1, 0)], grid[min(i + 1, len(grid) - 1)]),
49                 method="bounded",
50                 options={"xatol": 1e-12})
51             if not fit.success:

```

```

47         raise RuntimeError(f"Q profile minimization failed: {fit.
48             message}")
49     candidates.append(solve_fixed_quality(C, fit.x, Q0, params, Lctx,
50         gkind))
51     best = min(candidates, key=lambda s: s["L"])
52     q, dq = best["Q"], best["profile_grad_Q"]
53     state = "fixed" if Q0 == 1 else "baseline" if abs(q - Q0) < 1e-9 else "
54         upper" if abs(q - 1) < 1e-9 else "interior"
55     q_violation = 0.0 if state == "fixed" else max(0.0, -dq) if state == "
56         baseline" else max(0.0, dq) if state == "upper" else abs(dq)
57     best.update({"solver": "budget-eliminated profile", "quality_state":
58         state,
59         "q_grid_size": len(grid), "budget_relative_error": abs(best[
60             "util"] - 1),
61         "stationarity_residual": max(abs(best["profile_grad_logN"]),
62             q_violation)})
63     return best

```

代码 7 预算消元、质量剖面搜索与边界检验

B.4 问题四：能力前沿与情景预测

```

1 def _fit_bridge(L, cap):
2     """0<=下渐近线<=上渐近线<=100; expit 避免指数溢出。"""
3     def sigmoid(x, ratio, a, L0, c):
4         return c + (100 - c) * ratio * expit(a * (L0 - x))
5     bounds = ([0, 1e-3, L.min() - 1, 0], [1, 50, L.max() + 1, 100])
6     best = None
7     for a0 in (0.5, 2.0, 8.0):
8         p0 = [0.8, a0, np.median(L), max(0, cap.min() * .5)]
9         try:
10             par, cov = curve_fit(sigmoid, L, cap, p0=p0, bounds=bounds,
11                 maxfev=20000)
12             except (RuntimeError, ValueError):
13                 continue
14             pred = sigmoid(L, *par)
15             cost = np.sum((cap - pred) ** 2)
16             if best is None or cost < best[0]:
17                 best = (cost, par, pred)
18         if best is None:
19             raise RuntimeError("桥接的全部初值均未收敛")
20     _, par, pred = best
21     ratio, a, L0, c = par
22     return {"Smax": float((100 - c) * ratio), "a": float(a),
23         "L0": float(L0), "c": float(c)}, pred

```

代码 8 单调有界的损失到能力桥接

```

1 n_boot = 2000
2 boot_anchor = np.empty(n_boot)

```

```

3 boot_slope = np.empty(n_boot)
4 boot_noise = np.empty(n_boot)
5 for i in range(n_boot):
6     sampled = rng.choice(resid, size=len(resid), replace=True)
7     boot_slope[i], boot_anchor[i] = np.linalg.lstsq(A, fitted + sampled,
8         rcond=None)[0]
9     boot_noise[i] = rng.choice(resid)
10
11 frontier_pred = {}
12 for sc, rc in scenarios.items():
13     preds = {}
14     for months in [12, 24]:
15         dt = months / 12.0
16         t_target = t_last + dt
17         # 情景：算力放缓使斜率按 rc 缩放 (rc=1 维持历史增速, rc=0 停滞)
18         # 与滚动检验一致，使用拟合末期水平并保留截距/斜率协方差。
19         boot = np.clip(boot_anchor + rc * boot_slope * dt + boot_noise,
20             0.0, 100.0)
21         preds[f"{months}m"] = {"P10": float(np.percentile(boot, 10)),
22             "P50": float(np.percentile(boot, 50)),
23             "P90": float(np.percentile(boot, 90)),
24             "t_target": float(t_target)}
25     frontier_pred[sc] = preds
26     print(f"[Q4] 情景 {sc}(rc={rc}): 12m P50={preds['12m']['P50']:.2f} "
27         f"24m P50={preds['24m']['P50']:.2f}")

```

代码 9 联合重拟合截距与斜率的自助情景预测