

目录

1	问题重述与问题分析	3
1.1	问题背景与任务	3
1.2	问题一的分析	4
1.3	问题二的分析	4
1.4	问题三的分析	4
1.5	问题四的分析	4
2	模型假设	4
3	符号说明	5
4	问题一：数据质量评价、冲突消解与配比-损失关系	5
4.1	列表型压缩、方向统一与综合质量	6
4.2	质量冲突的可计算定义与消解	9
4.3	配比-损失关系与跨体系域映射	12
4.4	小结	13
5	问题二：经典标度律拟合与含质量的广义标度律	13
5.1	经典标度律的对数域稳健拟合	14
5.2	含质量的广义标度律设计	15
5.3	弹性、边际效用与质量-规模替代	17
6	问题三：算力约束下的资源配置优化与结构性转移	19
6.1	优化模型	19
6.2	KKT 解析刻画	20
6.3	数值求解	20
6.4	结构性转移的定义与识别	22
6.5	上下文长度的临界值与敏感性	22
7	问题四：规模与非规模贡献分解、损失-基准桥接与能力前沿预测	24
7.1	综合能力度量与口径声明	24
7.2	规模与年份项的描述性分解	25
7.3	损失-基准桥接映射	26
7.4	能力趋势情景下的经验前沿预测	27
7.5	逐任务聚合分析	28
8	模型检验与灵敏度分析	29
8.1	独立复核	29
8.2	灵敏度分析	30

8.3 适用范围	30
9 模型评价、改进与推广	30
9.1 模型优点	30
9.2 模型不足与改进方向	30
9.3 推广	31
10 结论	31
A 附录：参数取值与求解步骤	34
A.1 题面给定常量与成本函数	34
A.2 优化求解步骤	34
A.3 关于人工智能工具的使用说明	34
B 附录：核心算法代码摘录	35
B.1 问题一：质量评分与配比回归	35
B.2 问题二：经典与广义标度律	36
B.3 问题三：预算约束下的资源配置	38
B.4 问题四：能力前沿与情景预测	40

1 问题重述与问题分析

1.1 问题背景与任务

大语言模型的能力主要通过验证集交叉熵损失（全文记为 L ，单位 nats/token，越低越好）来度量。经典标度律

$$L(N, D) = E + A N^{-\alpha} + B D^{-\beta}, \quad (1)$$

把损失表示为参数规模 N 与训练数据量 D 的幂律叠加，其中 E 为不可约损失， A, α, B, β 为待估参数^[1, 2]。然而式 (1) 未显式包含数据质量 Q 与领域配比 p ，也未刻画长上下文对算力的挤占。在总算力预算 C 有限时，如何在 N, D, Q, p 与上下文长度 L_{ctx} 之间取舍，成为决定模型能力上限的核心问题。本文需要回答四个递进的问题：刻画数据的质量与配比，把它们纳入损失预测，在预算约束下求最优配置，最后把损失翻译为真实基准能力并预测其前沿。

题目提供三组真实数据：一组覆盖七个来源域、含 22 个质量信号的大规模文本样本与两个扩展集；一组来自公开模型训练的标度律轨迹与跨族、文献验证点，其中仅一小组半合成实验带有质量标度；一组开源模型评测榜单、逐任务评测记录、损失—基准桥接样本与模型架构元数据。四问按数据、标度律、预算配置与能力分析组织；实际计算依赖关系在图 1 中说明。




图 1 四问递进的整体技术路线

图 1 从左至右给出数据刻画、广义标度律、预算优化与能力预测四个阶段：问题一的域级质量作为问题三基线；配比关系为独立的辅助分析，当前广义律计算固定配比因子为

1; 标度律参数用于问题三优化目标; 问题四的桥接由独立样本拟合; 问题四的桥接可探索性地吧损失映射到能力, 但当前前沿预测直接基于榜单能力值。章节顺序对应问题的分析层次, 并不意味着每一项上游量均进入下游数值模型。

1.2 问题一的分析

问题一是“多指标综合评价、带约束回归与跨体系关联”的混合任务, 难点有三。其一, 22 个指标中有若干为逐句打分的列表型字段, 须先压缩为标量, 且各指标优劣方向不同(如教育价值越高越好、广告含量越低越好), 必须先方向统一才能客观赋权合成综合质量。其二, 须给出可计算定义, 当同一文本上强正向指标与强负向指标同时处于高分位时应判为冲突, 仅凭指标共现不能确定成因, 需用降权对照检验排序稳定性。其三, 质量信号覆盖的域与配比实验涉及的域不一一对应, 须显式建立关联并处理无同名质量域的推断域。配比与损失的定量关系借鉴按配比回归损失的思路^[3, 4], 先在训练集拟合、在多尺度检验集验证、在外推表上考察稳健性。本问的域级质量用于问题三基线, 配比回归为独立分析; 广义律数值计算没有显式使用配比效应。

1.3 问题二的分析

问题二要在经典标度律基础上纳入质量, 并讨论配比扩展, 是推理密集型任务。首先以真实训练轨迹拟合经典律, 并用族外、轨迹、跨族与文献数据分层验证泛化性。广义律的设计是核心: 一种自然方式是让高质量数据等效于更多 token, 即以有效数据量 $Q^\theta D$ 进入数据项, 并令 $Q = 1$ 时退化为经典形式; 半合成实验的质量标度方向与模型假设冲突, 质量指数在下游取结构性假定值。弹性与替代条件由对数损失的偏导解析给出, 据此可回答。本问的广义律与弹性关系是问题三优化目标的来源。

1.4 问题三的分析

问题三是“算力约束下的资源配置优化与结构性转移”的混合任务。目标函数取自问题二的广义标度律, 约束为基础训练、质量提升与长文本注意力三部分算力之和不超过预算。求解上先用 Lagrange/KKT 做解析刻画, 预算约束在最优处通常取等号, 据此得最优配置关于预算的标度关系; 再用序列二次规划配合多起点数值优化^[19] 在三档及连续预算上搜索最低损失的可行解。结构性转移须给出可判定定义, 本文以算力份额对预算对数的导数峰值作为数值判据, 并检查边界状态。上下文长度依题意作为外生参数, 须解析给出使注意力开销等于训练开销的临界值并在其可行取值上做敏感性分析。

1.5 问题四的分析

问题四是“贡献分解、桥接映射与带不确定性外推”的混合任务。能力提升既来自规模扩张也来自架构、对齐与数据工程等非规模技术进步^[11, 12]。以能力对规模变量与时间回归, 可作描述性分解; 年份项可能混入样本组成和未观测因素, 不作因果贡献解释。损失与基准的桥接用按可比性分层的单调映射建立; 前沿预测直接用榜单能力值, 不传播桥接误差。前沿预测在给定能力趋势系数的情景下外推能力分位带, 须显式声明综合能力度量、开源筛选口径与时间轴口径^[14, 15]。本问是全题落点, 把前三问的损失语言翻译为现实基准能力。

2 模型假设

本文只保留会影响可行域、模型结构或结果解释的现实简化, 每条附一句合理性说明。

(1) 22 个质量指标经方向统一后“越高越好”, 综合质量由客观赋权线性合成并映射到 $(0, 1]$ 。这样可用全部指标信息、避免主观拍权重, 也使正负向冲突可被度量。

(2) 领域配比与损失的关系在同一训练尺度内可由配比向量单独预测, 参数量与数据

量由配比实验固定，分域建模后按目标域加权。数据本按域分列损失，且同配方不同域损失差异显著，支持分域刻画。

(3) 质量以“质量增强有效数据量”方式进入广义标度律，令有效数据量为 $Q^\theta D$ ，使 $Q = 1$ 时自然退化为经典形式。高质量数据等效于更多 token，物理含义清晰且退化有据。

(4) 问题三中配比由前两问固定、仅 N, D, Q 为决策变量，配比联立优化作为扩展。固定配比使规模、数据、质量三者的结构性转移更清晰，且标度律数据无逐域配比字段。

(5) 基线质量 Q_0 取问题一域级质量的中位数，并在敏感性分析中扰动。题面未给该值，用数据驱动的中位数最中性，它是质量成本铰链的起算点。

(6) 问题四综合能力取六维基准均分，前沿样本用许可证字段非空作为代理筛选，时间轴用榜单年份；该代理不能核实严格的开源属性。均分口径透明可复现，且题目要求显式声明这些口径。

3 符号说明

下表汇总全文跨章节复用、直接进入核心目标或约束的主要符号；一次性下标在首次出现处解释。

符号	含义	符号	含义
L	验证集交叉熵损失 (nats/token)	C	总算力预算 (FLOPs)
N	模型参数量 (10^9)	$C_{\text{train}} = 6ND$	基础训练开销
D	训练 token 数 (10^9)	C_Q	质量提升开销
Q	综合数据质量评分 (0, 1]	$C_{\text{attn}} = \eta NDL_{\text{ctx}}$	长文本注意力开销
Q_0	基线质量	η	注意力开销系数 2×10^{-4}
$\mathbf{p}$	17 域配比向量	L_{ctx}	上下文长度 (tokens, 外生)
E	不可约损失	$L_{\text{ctx}}^{\text{crit}}$	注意力临界上下文 $6/\eta$
A, α	参数项系数与指数	$g(Q)$	每 token 质量成本函数
B, β	数据项系数与指数	ε_X	因素 X 的弹性
θ	质量放大指数	s_X	因素 X 的算力份额
w_j	质量指标 j 的权重	Cap	综合基准能力 (0–100)

4 问题一：数据质量评价、冲突消解与配比–损失关系

本章刻画数据本身，输出三样东西：域级综合质量 Q 、质量冲突的判据与消解结果、领域配比与损失的定量关系。三者分别对应质量信号数据的评价、稳健化，以及配比实验数据的回归建模，其产物是问题二广义标度律的直接输入。整体数据处理流程如图 2 所示，从原始质量信号出发，依次经列表型压缩、方向统一归一化、客观赋权合成与样本到域的聚合，最终产出可向下游传递的域级质量与配比关系。




图 2 问题—质量评价数据处理流程

该流程在主样本上计算样本级指标与 Q ，扩展集沿用同一归一化基准。冲突降权产生单独的对照分数；配比回归使用独立实验表，其变量口径不与质量指标共享归一化参数。

4.1 列表型压缩、方向统一与综合质量

高质量语料的筛选与配比对预训练效果有显著影响，已有工作从网页清洗、去重到质量打分提出了多种数据构造范式^[5, 6, 9]。质量信号覆盖七个来源域，含 22 个指标，其中若干为逐句或逐段的打分向量；这些指标按语义可归纳为若干层次，其体系结构见图 3。设文档 i 在列表型指标 j 上的打分序列为 $\mathbf{v}_{ij} = (v_{ij}^{(1)}, \dots, v_{ij}^{(m_{ij})})$ ，先用文档级均值压缩为标量

$$x_{ij} = \frac{1}{m_{ij}} \sum_{t=1}^{m_{ij}} v_{ij}^{(t)}, \quad j \in \mathcal{J}_{\text{list}}, \quad (2)$$

稳健性另用截尾均值与中位数对照。各指标优劣方向不同，须先做 Min-Max 归一化，再对负向指标（如广告含量，越低越好）取补转换 $1 - x$ ，使全部指标统一为“越高越好”：

$$\tilde{x}_{ij} = \text{clip}_{[0,1]} \left(\frac{x_{ij} - m_j^{\text{A1}}}{M_j^{\text{A1}} - m_j^{\text{A1}}} \right), \quad r_{ij} = \begin{cases} \tilde{x}_{ij}, & j \in \mathcal{J}_+, \\ 1 - \tilde{x}_{ij}, & j \in \mathcal{J}_-. \end{cases} \quad (3)$$

质量打分本身也可由模型学习得到，如以质量评级指导数据选择^[8]；本文则采用可解释的客观赋权路线。综合质量的权重采用熵权法客观赋权，其原理是信息量越大的指标（取值越分散、区分度越高）权重越大，可避免主观拍定，该类客观赋权在多指标综合评价中应用广泛^[20]。记归一化矩阵 $R = (r_{ij})_{n \times 22}$ ，指标 j 的比重、信息熵与权重为

$$p_{ij} = \frac{r_{ij}}{\sum_{i=1}^n r_{ij}}, \quad e_j = -\frac{1}{\ln n} \sum_{i=1}^n p_{ij} \ln p_{ij}, \quad w_j = \frac{1 - e_j}{\sum_{k=1}^{22} (1 - e_k)}. \quad (4)$$

样本级综合质量与由样本到域的聚合为

$$Q_i = \sum_{j=1}^{22} w_j r_{ij} \in (0, 1], \quad Q_d^{\text{dom}} = \frac{1}{|\mathcal{S}_d|} \sum_{i \in \mathcal{S}_d} Q_i, \quad (5)$$

其中 $\mathcal{S}_d$ 为域 d 的样本集。 m_j^{A1} 、 M_j^{A1} 是主样本的最小值和最大值；缺失值以主样本中位数填充。权重和归一化基准只在全部 51230 条主样本上拟合，扩展集沿用这套基准，超出主样本范围的值截到 $[0, 1]$ ，使跨集合分数可比。

求解与结果。熵权由式 (4) 在全样本上计算，并用 CRITIC 与主成分两种客观赋权交叉核对，三法所得质量排序的 Kendall 秩相关分别为 0.827（熵权-CRITIC）与 0.802（熵权-主成分），排序高度一致。全样本综合质量落在 $(0.038, 0.796]$ 、均值约 0.080，域级质量中位数为 0.079，该中位数作为问题三基线质量 Q_0 向下游传递。表 1 列出两种客观赋权对 22 个指标的权重。

表 1 质量指标客观权重对照

#	指标	熵权 w_j	CRITIC	#	指标	熵权 w_j	CRITIC
1	词数	0.4192	0.0055	12	可读性	0.0076	0.0535
2	句子数	0.3988	0.0082	13	整洁度	0.0072	0.0566
3	句末标点	0.0367	0.1356	14	非字母词占比	0.0065	0.0643
4	平均词长	0.0301	0.0156	15	大写占比	0.0056	0.0762
5	流畅度	0.0146	0.0742	16	unigram 熵	0.0043	0.0533
6	广告含量	0.0143	0.0687	17	数字占比	0.0004	0.0251
7	推理性	0.0129	0.0625	18	2gram 重复	0.0001	0.0143
8	唯一词占比	0.0119	0.0786	19	3gram 重复	0.0001	0.0095
9	教育价值	0.0117	0.0623	20	DSIR 书籍	0.0000	0.0055
10	专业性	0.0093	0.0574	21	DSIR 维基	0.0000	0.0047
11	QuRater	0.0087	0.0644	22	DSIR 数学	0.0000	0.0039
合计 $\sum_j w_j$						1.000000	

熵权把最大权重给了词数、句子数等区分度极高的规模型指标（二者合计权重超过 0.8），而 DSIR 类指标因取值集中权重接近于零；CRITIC 因同时考虑对比强度与冲突性，权重分布更均匀（表 1）。两法排序一致但权重形态不同，说明综合质量的稳健性主要来自高区分度指标，这一点在后文冲突分析中还会用到。须诚实指出，规模型指标主导意味着熵权综合质量在很大程度上反映了文档规模：仅以教育价值这一语义指标重排七个来源域，其域级序与全指标 Q 的秩相关接近零，二者仅在书籍域同居高位。因此本文对 Q 的定位是“含规模信息的综合可用性评分”而非纯语义质量，其作为下游相对质量信号的意义仍成立，但把它单独解读为语义质量并不稳妥，这一口径边界在问题二取用质量时会再次强调。22 个指标可按来源与语义组织成层次体系（图 3），其相关结构见图 4。



图 3 质量指标体系层次结构




图 4 质量指标相关性聚类热力图

按层次聚类重排相关矩阵后可见指标簇（图 4）。下一节关注的冲突是同一文档同时具有高教育价值与高广告含量的局部现象；它不要求两指标在全样本上负相关。

4.2 质量冲突的可计算定义与消解

“冲突”须给出可判定的量化定义。对强正向指标 j_+ （教育价值）与强负向原始指标 j_- （广告含量），若同一文档同时落入两者的高分位，则判为冲突样本：

$$\text{Conflict}(i) = \mathbb{I}[r_{i,j_+} \geq \tau_{0.8}^+ \wedge \tilde{x}_{i,j_-} \geq \tau_{0.8}^-]. \quad (6)$$

其中 $\tau_{0.8}$ 为对应指标的 0.8 分位阈值，冲突率取 $\frac{1}{n} \sum_i \text{Conflict}(i)$ 。以降权因子 $\delta \in (0, 1)$ 构造稳健性对照分数：

$$Q_i^{\text{adj}} = [1 - (1 - \delta) \text{Conflict}(i)] Q_i. \quad (7)$$

求解与结果。在全部主样本上，由式 (6) 识别出冲突样本 2542 条，冲突率 4.96%。教育价值与原始广告含量的全样本 Spearman 相关约为 +0.139，双高是局部共现而非总体负相关。取 $\delta = 0.5$ 作降权对照，并扫描 $\delta \in \{0.3, 0.5, 0.7, 1.0\}$ ；前三档的域级排序与原评分的 Kendall 相关均为 0.905，说明排序大体稳定但并非完全不变。下游使用的 Q 与基线质量 Q_0 仍是未降权主评分。图 5 展示冲突区。




图 5 教育价值与广告含量的冲突区

双高分位冲突区落在教育价值-广告含量散点的右上角（图 5）。该图只证明指标共现，不能单凭散点推断文档体裁或广告成因。调整分数用于检验域级排序对冲突处理的敏感性；两个扩展集用于检验评分的跨集合可比性。




图 6 抽样集与扩展集域级质量对照

沿用主样本归一化基准和权重后，扩展集 arxiv 的域级质量为 0.07932，主样本同名域为 0.07893；扩展集 github 为 0.07088，主样本为 0.07090（图 6、表 2）。这支持这两个域在当前口径下的跨集合数值一致性；不能据此推断全部领域或冲突降权方案都具有同等稳定性。

表 2 域级综合质量统计

域	n_{A1}	Q_{A1}	95% 区间	n_{ext}	Q_{ext}
book	171	0.22722	[0.20941, 0.24573]	—	—
c4	10000	0.09766	[0.09756, 0.09776]	—	—
commoncrawl	9640	0.07985	[0.07964, 0.08005]	—	—
arxiv	1419	0.07893	[0.07829, 0.07960]	17523	0.07932
wikipedia	10000	0.07647	[0.07631, 0.07662]	—	—
stackexchange	10000	0.07212	[0.07193, 0.07230]	—	—
github	10000	0.07090	[0.07074, 0.07108]	203752	0.07088
全样本	51230	0.07988	—	—	—

各域的样本量、域级质量与自助法区间见表 2。书籍域质量最高（约 0.227），但书籍域主样本仅 171 条，且评分受文档长度主导，不宜把这一排序直接解释为语义质量。区间由 2000 次文档级自助重采样的百分位给出，只反映当前样本内的抽样波动。

4.3 配比-损失关系与跨体系域映射

配比实验给出 512 组 17 维领域配比与对应的 13 域验证损失。借鉴按配比回归损失的思路^[3]，以配比向量 $\mathbf{p}$ 为特征、分域损失为目标，对每个有损失记录的目标域 k 建立对数域线性模型；配比输入满足单纯形约束：

$$\ln \hat{L}_k(\mathbf{p}) = a_k + \sum_{i=1}^{17} b_{ki} p_i, \quad \text{s.t.} \quad p_i \geq 0, \quad \sum_{i=1}^{17} p_i = 1. \quad (8)$$

由于 $\sum_i p_i = 1$ ，截距和全部配比系数不能同时唯一识别。计算时把系数改写为 $\sum_i b_{ki} = 0$ 的等价零和编码，并相应平移截距，使预测不变。图中的平均绝对系数只表示相对平均域的线性对比强度，不是因果影响。配比输入本身归一化到单纯形；另用梯度提升回归作拟合对照。

求解与验证。线性模型在 13 个目标域上的训练决定系数介于 0.50–0.79（中位约 0.67）。表 3 把三个留出尺度的两种指标并列：同尺度 1m 的平均 R^2 为 0.664；在 60m 与 1B 上，平均 R^2 分别降至 -5.387 和 -265.290 ，说明固定的 1m 截距与系数不能直接预测更大模型的绝对损失。平均 Spearman 相关仍为正，表明域内配比排序保留一定信息，但相关系数不能保证选出的最优配比在新尺度上仍最优。梯度提升模型在 1m 数据的五折交叉验证平均 R^2 为 0.977；它只检验同尺度拟合，不验证跨尺度泛化。

表 3 配比回归的分尺度留出检验

检验尺度	配比数	平均 $\ln L$ 的 R^2	平均 Spearman 相关
1m	256	0.664	0.844
60m	256	-5.387	0.842
1B	64	-265.290	0.736

上述数值均对有验证损失的 13 个目标域求平均。 $R^2 < 0$ 表示预测平方误差大于直接使用该检验集目标域平均 $\ln L$ 的误差，不能仅以“尺度不同”略过。若把该模型用于新规模，应先用该规模的少量已知配比重重新标定截距，再用独立配比验证排序和最优选择的遗憾值；本文没有进行这种再标定。现有排序相关只是一条迁移线索，零和编码的系数对比见图 7。




图 7 零和编码下配比系数的相对对比强度

图 7 按零和编码后的平均绝对系数排序。即使采用可复现的编码，域间相关仍会改变系数；这张图只展示线性模型内的相对对比，当前问题二的广义律也未使用这组系数。

跨体系域映射方面，质量信号覆盖的域与配比涉及的 17 个域并不一一对应。按提供的映射指南，其中三个域可直接同名对应、三个域语义近似对应，其余多数为无同名质量域的推断域。对推断域按体裁相似性借用最近的质量信号（如数学类借用 arxiv 与数学信号），这一按重要性加权借用的思路与基于重要性重采样的数据选择一致^[7]，并标注其可信度较低；四个既无对应质量域又无损失列的域（如邮件、议会记录等）仍保留其配比作为式 (8) 的解释变量，间接影响其它域损失，而非无声剔除。这样既显式处理了体系差异，又不丢失任何配比信息。

4.4 小结

本章得到域级综合质量（中位数 0.079 用作问题三的 Q_0 ）和约 4.96% 的局部双高冲突。配比回归在跨尺度检验中保留了一定排序相关，但绝对损失预测显著失准；其系数可用于后续配比建模，尚未进入本文的广义律或预算优化数值计算。

5 问题二：经典标度律拟合与含质量的广义标度律

本章先在真实训练轨迹上拟合经典标度律，再构造含质量的有效数据量扩展，并解析弹性与质量对规模的替代条件。配比影响在本章保留为待识别扩展，数值计算固定其因子为 1；问题三使用这里的损失参数，问题四的桥接由另一组损失—基准样本独立拟合。

5.1 经典标度律的对数域稳健拟合

采用题目给定的经典形式式 (1)。以 1176 行真实 Pythia 训练日志^[10] 为主拟合集（参数量 0.07–12B、数据量至 300B）。由于损失跨越约 2 到 4.7 的量级，直接在原始尺度最小二乘会被大损失点主导，故在对数域用 Huber 损失做加权非线性最小二乘，兼顾同方差化与对离群轨迹点的稳健性：

$$\min_{E, A, \alpha, B, \beta} \sum_{m=1}^M \rho_{\kappa} \left(\ln L_m - \ln (E + AN_m^{-\alpha} + BD_m^{-\beta}) \right), \quad \rho_{\kappa}(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \kappa, \\ \kappa(|u| - \frac{1}{2}\kappa), & |u| > \kappa. \end{cases} \quad (9)$$

求解用信赖域反射的非线性最小二乘并启用 Huber 稳健损失，以 $\alpha, \beta \in [0.05, 0.5]$ 的网格初值多起点启动，避免落入局部解。

结果与分层验证。拟合得 $E = 1.690$ 、 $A = 0.354$ 、 $\alpha = 0.340$ 、 $B = 1.240$ 、 $\beta = 0.280$ ，决定系数 R^2 接近 1，残差均值约 -5×10^{-8} 。两个指数落在文献常见区间 $(0, 1)$ 内，且方向正确——增大参数量或数据量都使损失下降^[1, 2]。为考察泛化，在四组独立数据上分层验证：族外半合成日志、插值轨迹、12 族收敛点与文献点，其中跨族基线决定系数 0.60、文献点 0.73，均方根误差随可比性下降而增大，符合预期。百亿参数以上的估算点仅用于外推讨论，不作为观测。图 8 给出拟合优度与残差。




图 8 经典标度律拟合优度与残差

预测–实际散点几乎落在对角线上，拟合残差 $\hat{L} - L$ 在零线附近无系统弯曲（残差标

准差约 1.5×10^{-4} nats/token，量级远小于 L 本身），说明经典幂律在真实轨迹上的拟合已相当充分，可作为广义律的可靠基底（图 8，右图横轴为残差 $\hat{L} - L$ ，单位 nats/token）。

5.2 含质量的广义标度律设计

经典律未含质量。本文让高质量数据等效于更多 token，即以有效数据量 $D_{\text{eff}} = Q^\theta D$ ($\theta > 0$) 进入数据项：

$$L(N, D, Q) = E + A N^{-\alpha} + B (Q^\theta D)^{-\beta}. \quad (10)$$

当 $Q = 1$ 时 $Q^\theta = 1$ 、 $D_{\text{eff}} = D$ ，式 (10) 严格退化为经典式 (1)——这是把质量归一到 $(0, 1]$ ($Q = 1$ 为满质量) 的直接后果，故退化成立有据而非强加。这里须呼应问题一对 Q 口径的界定： Q 是训练预处理阶段可操控的综合可用性评分，文档规模是其中的真实维度之一（过短文档的信息密度与可训练性确实偏低），故 $Q^\theta D$ 中的规模分量与 D 在量纲上并不冲突，把它解读为“更可用的数据等效于更多 token”仍然成立；若要进一步分离纯语义质量与规模的各自效应，需对 Q 做成分分解，这留作未来工作。配比调节项 $\phi(\mathbf{p})$ 可作为后续扩展，但当前拟合和问题三计算均固定 $\phi = 1$ ；因此本文数值结果没有识别配比对广义律的独立影响。作为备选，也可用质量缺陷附加项 $L = E + A N^{-\alpha} + B D^{-\beta} + \kappa(1 - Q)^\nu$ ，其在 $Q = 1$ 时同样退化。

质量放大指数的不可识别性与结构性取值。原则上质量放大指数 θ 应由带质量标度的半合成实验估计，这也是全部数据中唯一含质量标度的来源。但实测发现该实验的质量标度与验证损失呈正相关 (Spearman 约 +0.446，组内更高)，即“质量标度越高损失越高”，与“高质量有益”的方向相反，且在极低质量标度处损失甚至低于经典不可约损失。这说明该实验的质量标度并非问题一的部署质量口径，而是重标定损失区间的实验设定量（难度或多样性指标）， θ 无法从该数据中识别。为避免把无根据的经验值伪装成估计结果，本文明确将 θ 定位为结构性假定参数而非估计量：取 $\theta = 0.5$ 只是位于“质量无效” ($\theta = 0$) 与“质量和数据等弹性” ($\theta = 1$) 之间的示例设定，不是数据估计值，也没有特别的统计最优性。另以 $\{0.2, 0.5, 0.8\}$ 做情景敏感性分析；只在这些设定下讨论相应结果。据此所有依赖 θ 的下游结论（问题三最优配置）均在“ $\theta = 0.5$ 假定下成立”的限定下解读，并在 $\{0.2, 0.5, 0.8\}$ 上给出敏感性区间。需说明含质量广义律在留出集上的均方根误差 0.688 低于同参经典基线的 0.971，反映的是引入质量维度后模型自由度与拟合灵活性的提升，而非对 θ 绝对值的验证。表 4 汇总两律的参数与拟合优度。

表 4 标度律参数与拟合优度

项	经典律 $L(N, D)$	广义律 $L(N, D, Q)$
参数		
E	1.6898	0.2163
A	0.3540	0.5311
α	0.3400	0.3090
B	1.2403	2.9534
β	0.2799	0.1228
θ (经验)	—	-10.000
θ (下游取用)	—	0.50
拟合		
样本量 n	1176	2012
R^2	0.9999998	0.3389
残差标准差	1.466e-04	—
AIC	-31.6	-1842.7
BIC	-2.5	-1807.8
留出/外部集 $RMSE$		
B6 留出 ($n=502$)	0.9713	0.6879
published ($n=44$)	0.1976	—
baseline ($n=57$)	0.2927	—
cerebras ($n=1029$)	1.2431	—
参考点弹性		
ε_N	—	-0.0657
ε_D	—	-0.0860
ε_Q	—	-0.0430
$dN/dQ _L$	—	-1.3097

经典律与广义律的参数对比见表 4：经典律以近乎完美的 R^2 拟合真实轨迹；广义律行中的经验质量指数因上述设定量口径问题落在边界（不可识别），故表中明确标注为“不可识别，下游取用结构性假定值 $\theta = 0.5$ ”，这一分列正是对数据与假设冲突的诚实呈现，而非把数据改写以迎合假设。 $Q = 1$ 退化的相对误差为 0，满足等价性要求。广义律的损失曲面见图 9。




图 9 广义标度律损失曲面

固定数据量后，损失随参数量与质量的联合变化面沿任一方向增大均单调下降，质量方向的下降经 Q^θ 放大数据项体现，直观展示了质量与规模对损失的协同作用（图 9，含 $Q=1$ 退化对照线）。

5.3 弹性、边际效用与质量-规模替代

定义因素 X 的弹性 $\varepsilon_X = \partial \ln L / \partial \ln X$ 。对广义律式 (10) 求偏导得

$$\frac{\partial L}{\partial N} = -\alpha A N^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta B Q^{-\theta\beta} D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\theta\beta B Q^{-\theta\beta-1} D^{-\beta}, \quad (11)$$

从而

$$\varepsilon_N = \frac{-\alpha A N^{-\alpha}}{L}, \quad \varepsilon_D = \frac{-\beta B (Q^\theta D)^{-\beta}}{L}, \quad \varepsilon_Q = \theta \varepsilon_D. \quad (12)$$

式 (12) 表明质量弹性是数据弹性的 θ 倍：质量通过放大有效数据发挥作用，其边际效用与数据同向而幅度可调。沿等损失面 $dL=0$ ，质量与规模的替代率为

$$\left. \frac{dN}{dQ} \right|_L = -\frac{\partial L / \partial Q}{\partial L / \partial N} = -\frac{\theta\beta B Q^{-\theta\beta-1} D^{-\beta}}{\alpha A N^{-\alpha-1}}. \quad (13)$$

结果。在参考点（参数量 1、数据量 100、质量 0.5）代入拟合参数，得 $\varepsilon_N = -0.066$ 、 $\varepsilon_D = -0.086$ 、 $\varepsilon_Q = -0.043$ ，三者均为负、方向正确，且满足 $\varepsilon_Q = \theta \varepsilon_D$ 。替代率 $dN/dQ|_L =$

-1.31，即在该参考点把质量提升 0.1 约等价于减少 0.13×10^9 参数而保持损失不变——质量确可在一定范围内替代规模。需强调该数值强依赖假定的质量指数，故其量级仅在参考点邻域可信，正负号由所设正质量指数的模型形式决定，不构成独立经验验证。图 10 与图 11 分别展示弹性对照与替代关系。




图 10 各因素损失弹性对照

三个弹性中数据弹性绝对值最大、参数次之、质量最小，说明在该参考点数据量的边际效用最高；三者同为负值再次确认增大任一因素都降低损失（图 10）。




图 11 等损失线与质量-规模替代

等损失曲线在低质量区更陡（图 11），其斜率即式 (13) 给出的质量-规模即时替代率，表明质量越低时提升质量替代规模的效率越高。这一分析为问题三在预算约束下权衡质量投入与规模扩张提供了边际依据。

6 问题三：算力约束下的资源配置优化与结构性转移

本章在总算力预算有限时，求使损失最小的参数量、数据量与质量配置，并分析预算跨量级时最优策略是否发生质变。目标函数取自问题二的广义标度律，约束为三部分算力之和不超过预算。

6.1 优化模型

决策变量为参数量 $N > 0$ 、数据量 $D > 0$ 与质量 $Q \in (0, 1]$ 。 N, D 分别以十亿参数、十亿 token 为单位；记 $U = 10^9$ ，则物理计数为 UN, UD 。上下文长度 L_{ctx} 为外生参数，配比在当前数值模型中固定。目标与 FLOPs 约束为

$$\min_{N, D, Q} L(N, D, Q) = E + AN^{-\alpha} + B(Q^\theta D)^{-\beta}, \quad (14)$$

$$\text{s.t. } \underbrace{6U^2ND}_{C_{\text{train}}} + \underbrace{UD[g(Q) - g(Q_0)]_+}_{C_Q} + \underbrace{\eta U^2NDL_{\text{ctx}}}_{C_{\text{attn}}} \leq C, \quad (15)$$

$$0 < Q \leq 1, \quad N > 0, \quad D > 0, \quad (16)$$

其中基础训练开销取 Chinchilla 系数 6（每参数每 token 约 6 FLOPs，仅在标准 dense transformer 下成立；MoE 等稀疏架构需按激活比例折算，本文优化的模型族均按 dense 处理）。注意力开销是工程一阶近似， $\eta = 2 \times 10^{-4}$ ；它刻画长上下文挤占预算的趋势，不作逐架构的精确 FLOPs 计数。 $g(Q)$ 为每个物理 token 的质量成本 (FLOPs/token)，取指

数、幂、对数三型之一； $[\cdot]_+$ 表示仅当质量超过基线 Q_0 时才计增量成本。 $Q_0 = 0.079$ 取自问题一域级质量中位数。显式写出 U 可避免把“十亿”为单位的标度律变量直接代入物理 FLOPs 公式。

6.2 KKT 解析刻画

预算约束在最优处通常取等号，因为增大任一因素都降损失、必用尽预算。在 $Q > Q_0$ 的活跃段构造 Lagrange 函数

$$\mathcal{L} = E + AN^{-\alpha} + B(Q^\theta D)^{-\beta} + \mu(U^2 ND(6 + \eta L_{\text{ctx}}) + UD[g(Q) - g(Q_0)] - C), \quad (17)$$

其一阶条件为

$$\partial_N \mathcal{L} = -\alpha AN^{-\alpha-1} + \mu U^2 D(6 + \eta L_{\text{ctx}}) = 0, \quad (18)$$

$$\partial_D \mathcal{L} = -\beta BQ^{-\theta\beta} D^{-\beta-1} + \mu(U^2 N(6 + \eta L_{\text{ctx}}) + U[g(Q) - g(Q_0)]) = 0, \quad (19)$$

$$\partial_Q \mathcal{L} = -\theta\beta BQ^{-\theta\beta-1} D^{-\beta} + \mu UD g'(Q) = 0. \quad (20)$$

由式 (18)–(19) 可消去乘子 μ ，得到参数量与数据量的边际平衡关系^[2]。质量条件须分段理解： $Q < Q_0$ 时提高质量不增加 C_Q 却降低损失，故候选最优解不会停在该段；在 $Q = Q_0$ 处比较较链两侧的单边导数，在 $Q_0 < Q < 1$ 的内点使用式 (20) 的边际收益等于边际成本条件，在 $Q = 1$ 时检查上界条件。以上均为局部必要条件，不能单独证明全局最优。

6.3 数值求解

KKT 给出候选解的局部条件；数值上用序列二次规划配合多起点搜索^[19]。为避免变量尺度悬殊，对参数量与数据量取对数尺度 $(\ln N, \ln D, Q)$ ，预算约束以非线性约束形式送入求解器；每档预算取不少于 20 个初值，报告其中损失最低的可行解；多起点搜索不能证明全局最优。三档预算 $C \in \{10^{19}, 10^{22}, 10^{24}\}$ ，并在预算对数区间连续扫描以刻画转移；三型质量成本分别求解以比较其对最优解的影响。表 5 汇总结果。

可复现求解步骤。

1. 固定预算 C 、成本函数 g 与上下文长度；以式 (15) 构造归一化可行余量 $(C - C_{\text{tot}})/C \geq 0$ 。
2. 在 $(\ln N, \ln D, Q)$ 空间取一个近似规模–数据平衡初值和其余随机初值，随机种子固定为 42；数值边界取 $N \in [10^{-3}, 10^5]$ 、 $D \in [10^{-2}, 10^6]$ 、 $Q \in [10^{-3}, 1]$ 。三档主预算各用 20 个初值，连续预算扫描用 12 个。
3. 对每个初值运行 SLSQP（最多 500 次迭代，目标容差 10^{-12} ）；只保留重算后满足 $C_{\text{tot}} \leq C(1 + 10^{-6})$ 的候选，按损失选最低者。该可行性筛选不等于全局最优证书。

结构转移计算在 $\log_{10} C \in [18, 25]$ 的 36 个网格点上重复搜索，再对质量算力份额作数值差分；网格峰值应视作候选位置而非精确物理阈值。以指数型质量成本和 $C = 10^{22}$ FLOPs 为例，候选配置为约 5.52B 参数、258.6B token、 $Q = 0.968$ 。代回物理成本式，基础训练、质量与注意力开销分别约占预算的 0.856、0.086、0.058，三项之和约为 1。这一回代检验能发现单位错误或越预算解，但不能检验损失模型在该配置处的外推精度。

表 5 三档预算下的最优算力配置

C (FLOPs)	$g(Q)$	N^*	D^*	Q^*	L^*	s_{train}	s_Q	s_{attn}
10^{19}	指数型	0.231	5.8	0.5456	3.0984	0.8018	0.1434	0.0547
	幂型	0.215	6.3	0.4456	3.1147	0.8192	0.1249	0.0559
	对数型	0.521	1.4	1.0000	3.2528	0.4482	0.5212	0.0306
	Chinchilla 基线	1.249	1.2	0.0789	3.6807	0.9361	0.0000	0.0639
10^{22}	指数型	5.516	258.6	0.9680	2.1511	0.8559	0.0857	0.0584
	幂型	5.798	237.2	1.0000	2.1530	0.8251	0.1186	0.0563
	对数型	5.600	253.0	1.0000	2.1505	0.8501	0.0919	0.0580
	Chinchilla 基线	39.499	39.5	0.0789	2.4236	0.9361	0.0000	0.0639
10^{24}	指数型	40.770	3768.7	1.0000	1.9139	0.9219	0.0151	0.0629
	幂型	40.942	3739.4	1.0000	1.9141	0.9186	0.0187	0.0627
	对数型	40.703	3780.4	1.0000	1.9139	0.9232	0.0137	0.0630
	Chinchilla 基线	394.989	395.0	0.0789	2.0682	0.9361	0.0000	0.0639

预算增大时最优损失单调下降（指数型下从 3.098 经 2.151 降至 1.914），逐步趋近不可约损失 1.69，参数量与数据量单调增，预算利用率约 100%（约束活跃）；相对质量固定为基线、规模等分的 Chinchilla 基线方案，最优配置的损失改善约 0.15 到 0.58（表 5）。三型质量成本的最优解在中高预算趋于一致，仅在低预算档因质量成本经济性不同而分化：对数型使高质量相对可得，故低预算即把质量推到边界；指数型使高质量昂贵，故低预算下质量停在内点。三档预算的算力份额构成见图 12。




图 12 三档预算下的算力份额构成

基础训练份额始终主导 (0.80–0.92)，注意力份额随预算缓升，而质量提升份额在所示三档预算中随预算增大回落 (图 12)。这一份额变化提示资源结构可能转移，需要沿连续预算扫描定位。

6.4 结构性转移的定义与识别

给出可判定定义：以各部分算力份额 $s_X(C) = C_X^*/C$ 对预算对数的导数峰值定位转移点，

$$C^\dagger = \arg \max_C \left| \frac{d s_X(C)}{d \log C} \right|, \quad (21)$$

并检查数值解是否触及质量边界或质量成本铰链。连续扫描预算对数区间、数值差分求份额导数可给出候选转移点；离散网格和成本函数选择会影响其位置。

结果。在当前 $\theta = 0.5$ 、成本函数和扫描网格设定下，质量份额导数在预算约 2.5×10^{22} FLOPs 处出现峰值，作为模型内的候选结构转移点。基线质量 0.079 较低，质量成本铰链在较低预算即已激活；这一结果同时依赖经验基线和假定的质量指数，不能称为纯数据驱动结论。转移点见图 13。




图 13 最优份额演化与结构性转移点

份额随预算对数演化曲线上叠加的份额导数，其峰值位置即由式 (21) 定位的转移点 (图 13)。由于该最优轨迹来自确定性优化、不存在重复抽样，图中不画置信带，而以份额导数曲线的峰值给出结构判据，当前实现未计算 KKT 残差，不能用一阶条件数值精度为转移位置背书。

6.5 上下文长度的临界值与敏感性

上下文长度为外生参数。令注意力开销等于训练开销 $\eta NDL_{\text{ctx}} = 6ND$ ，与参数量、数据量无关，解得临界上下文

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 3 \times 10^4 \text{ tokens}. \quad (22)$$

当上下文长度达到该值时注意力开销与训练开销相当，超过它长上下文将显著挤压训练预算。敏感性扫描的取值严格取自模型架构元数据的实测集，即 2048、4096、8192、32768 与 131072。图 14 展示最优配置随上下文长度的变化。




图 14 最优配置随上下文长度的变化

在中档预算下，上下文由 2048 增至 131072 时，注意力份额从约 0.058 升至约 0.776 (图 14)。临界值 3×10^4 位于 8192 与 32768 之间；上下文不小于 32768 时，按当前成本模型，注意力开销超过基础训练开销，压缩了可用于参数量和数据量的预算。可行域见图 15。




图 15 算力预算可行域与结构转移

在参数量-数据量-质量空间中，由式 (15) 界定的预算面、等成本线与最优点位置一同表明最优解落在预算面上（约束活跃），且随预算增大最优点沿预算面移动时穿过结构转移分区（图 15）。综合本章：预算增大使损失单调改善并趋近不可约损失，最优策略在预算约 2.5×10^{22} 处发生质量投入结构的转移，长上下文以临界值 3×10^4 为界挤压训练预算。

7 问题四：规模与非规模贡献分解、损失-基准桥接与能力前沿预测

本章分析规模和年份与基准能力的关联，建立损失到基准的探索性桥接，最后在三档能力趋势假设下预测有许可证记录模型的经验前沿。

7.1 综合能力度量与口径声明

综合能力取六维基准均分（指令遵循、综合推理、数学、研究生级问答、多步推理与专业知识）：

$$\text{Cap} = \frac{1}{6} \sum_{k=1}^6 B_k, \quad k \in \{\text{IFEval}, \text{BBH}, \text{MATH}, \text{GPQA}, \text{MUSR}, \text{MMLU-PRO}\}. \quad (23)$$

口径显式声明：前沿样本按榜单中许可证字段非空筛选；这只能视作“有许可证记录”的操作性代理，不能据此核实每个模型是否满足严格的开源定义^[16, 17]。时间轴用榜单年份，六维均分口径可复现。

7.2 规模与年份项的描述性分解

以榜单数据回归综合能力对规模变量与时间，检查两项在所选样本窗中的统计关联：

$$\text{Cap}_i = f(\ln N_i) + h(t_i) + \varepsilon_i, \quad (24)$$

其中规模项 f 和时间项 h 分别给出规模、年份与能力的统计关联。年份项可能同时吸收数据、训练配方、模型组成和评测变化，不能直接解释为纯技术进步。在时间窗 $[t_0, t_1]$ 上两项回归增量的形式占比为

$$\text{scale\%} = \frac{\Delta f}{\Delta f + \Delta h}, \quad \text{nonscale\%} = \frac{\Delta h}{\Delta f + \Delta h}, \quad \text{scale\%} + \text{nonscale\%} = 100\%. \quad (25)$$

结果与识别假设。在 4561 个有效模型上回归得 $\text{Cap} = -24576 + 6.27 \ln N + 12.14 t$ ，决定系数 0.462；年份系数是控制参数量后的条件关联，不具因果解释。两变量之外仍有大量系统性变异。所选时间窗内平均参数规模下降，使回归规模项增量为负；按式 (25) 计算的两项份额约为 -25% 与 125%。超出 0-100% 只是负增量下的比值结果，且分母由拟合增量而非观测到的能力变化构成。它只能描述这套回归与样本窗，不能据此证明非规模技术进步的因果份额。占比随时间的演化见图 16。




图 16 规模与年份项的回归增量分解

图 16 用零线标明规模项在所选窗口内的负增量。该结果对时间窗、样本组成和回归设定敏感，适合作为描述性分解，不宜称规模为能力提升的净拖累。

7.3 损失-基准桥接映射

用同时含验证损失与六维基准的桥接样本建立损失到能力的单调映射，按可比性分层（高可比来自可与训练轨迹对照的模型，其余为中可比）。用单调递减的 sigmoid 型回归

$$\widehat{\text{Cap}} = \frac{S_{\max}}{1 + \exp(a(L - L_0))} + c, \quad a > 0 \text{ (损失 } \uparrow \Rightarrow \text{能力 } \downarrow), \quad (26)$$

分层拟合参数，并分别报告样本量与拟合误差。

结果与不确定性。高可比层样本仅 7 条，决定系数约 0.40；中可比层 68 条，决定系数约 0.36。映射只能作为损失到基准能力的探索性桥梁，不能给出可靠的模型外推精度。下一节的前沿直接由榜单能力值计算，不经过这条桥接，因此其预测区间不含桥接误差。图 17 展示分层样本与拟合曲线。




图 17 损失到能力的分层桥接

分层拟合的函数按约束随损失单调下降，但散点仍有较大离散（图 17）。若用问题三的最优损失推算能力，必须另行传播桥接参数与残差的不确定性；此处未给出那类能力预测。

7.4 能力趋势情景下的经验前沿预测

将有许可证记录的模型按月分箱，至少有两条记录的月份取六维均分的第 90 百分位作为经验前沿。实际有效月份仅 10 个，覆盖约 2024.46 至 2025.21。在这些月度点上拟合线性趋势；残差自助重采样后重新拟合斜率，并加入一次月度预测残差。以历史末值 F_T 为锚，情景系数 $s \in \{0, 0.5, 1\}$ 缩放历史能力前沿斜率。第 b 次自助样本在 Δ 个月后的预测为

$$F_{s,\Delta}^{(b)} = \text{clip}_{[0,100]} \left(F_T + s \hat{\beta}^{(b)} \frac{\Delta}{12} + \epsilon^{(b)} \right), \quad \Delta \in \{12, 24\}. \quad (27)$$

其中 $\hat{\beta}^{(b)}$ 是以重采样残差重新拟合的年斜率， $\epsilon^{(b)}$ 从同次残差样本抽取；共进行 2000 次。对 $F_{s,\Delta}^{(b)}$ 取经验分位数，得到相对样本末点约 2026.21 和 2027.21 的预测区间：

$$\text{Frontier}(t + \Delta) \in [\hat{F}_{10}(t + \Delta), \hat{F}_{90}(t + \Delta)], \quad \Delta \in \{12, 24\} \text{ 月}. \quad (28)$$

历史训练算力中位数约以每年 5.1 倍增长，只为情景提供背景；数据并未估计训练算力增速与能力前沿斜率之间的弹性，因此三档系数是明确的假设。每个情景内的 P_{10} – P_{90} 区间包含趋势估计和月度残差的不确定性；不同情景之间的差异须单独比较，桥接误差不参与计算。表 6 汇总三情景结果。

短期回测。为检验线性趋势是否至少优于简单基线，从前 5 个有效月度点开始，每次只用已观测点重新拟合并预测下一点，共得 5 次一步预测。趋势模型的平均绝对误差为 1.89 个能力点，平均误差（预测减实际）为 +1.50 点；直接沿用上一月前沿的平均绝对误差为 1.28 点。趋势模型在这一小样本回测中没有优于末值延续，表明斜率外推存在乐观偏差风险。一步回测既不能校准 12–24 个月区间，也无法覆盖未来模型组成变化；下表的远期数值仅作条件情景计算。

表 6 能力前沿情景预测分位数

情景	斜率系数	期限	P10	P50	P90
维持	1.0	12 月	57.47	61.28	65.68
		24 月	74.14	81.02	88.35
放缓	0.5	12 月	48.97	51.38	54.90
		24 月	57.47	61.28	65.68
停滞	0.0	12 月	39.41	41.52	46.39
		24 月	39.41	41.52	46.39
历史末值	–	2025.21			41.75
历史斜率	–	–		19.68 点/年	

按上述假设，24 个月中位数在系数 1、0.5、0 下分别约为 81、61、42（表 6）。零斜率情景的 12 与 24 个月分布相同；其余情景随时间上升是线性趋势和正系数的模型结果，不是已验证的能力不倒退规律。历史末值约 42、拟合斜率约 20 点每年；以不足一年数据外推两年，绝对数值应谨慎使用。前沿分位带见图 18。




图 18 能力前沿情景预测区间

图 18 展示各情景内的 10%–90% 分位带；零斜率情景的区间不随期限扩大，另两档随斜率估计误差扩大。图中超出历史范围的部分均为情景外推，纵轴为六维基准均分 0–100。有限月度点、样本组成变化和情景映射假设均未被区间充分覆盖。

7.5 逐任务聚合分析

仅用榜单汇总列不足以刻画能力短板，本文遍历逐任务评测记录，按目录取最新可解析记录、跳过损坏文件做逐任务聚合。共解析 1860 个目录（六维完整 1854、损坏跳过 7），覆盖满足要求。各任务难度均值为：指令遵循 40.2、综合推理 47.5、数学 11.4、研究生级问答 29.8、多步推理 40.0、专业知识 32.0，其中数学最难。图 19 展示前沿模型的六维剖面。




图 19 前沿模型逐任务能力剖面

前沿模型在综合推理与指令遵循维度较强，而在数学与研究生级问答维度普遍偏弱，六维剖面的不均衡揭示了当前能力短板集中在高难推理任务上（图 19）^[15]。这与式 (23) 均分口径下的综合能力互为补充：均分给出总体水平，逐任务剖面给出结构短板。

8 模型检验与灵敏度分析

本章对四个模型的关键结论作独立复核，并对高敏感假设做扰动分析，说明结果的适用范围。

8.1 独立复核

问题一的综合质量用三种客观赋权交叉核对，熵权与 CRITIC、主成分的排序秩相关分别为 0.827、0.802；两扩展域沿用主样本归一化基准后，均值与同名主域接近，但这不能证明全部域的泛化性。问题二的经典律在四组独立数据上分层验证；广义律在留出集的均方根误差 0.688 低于同参经典基线 0.971，但 $Q = 1$ 的零退化误差是公式恒等式，不能充作质量效应的外部验证。问题三把求得的候选配置重代入物理 FLOPs 公式核验，三项总算力均未超预算；多起点与预算回代不能证明全局最优。问题四的两项回归份额按定义和为 100%，不构成因果分解验证；一步滚动回测中趋势模型的平均绝对误差 1.89 高于末值延续的 1.28，远期分位带不宜解释为已校准的预测覆盖率。

8.2 灵敏度分析

质量放大指数 θ 不是可由现有质量标度识别的估计量，故对 Q_0 与 θ 分别作条件扰动。在指数型质量成本、 $L_{\text{ctx}} = 2048$ 和同一多起点求解规则下，重求三档预算的候选配置；结果见表 7。

表 7 质量基线与指数扰动下的候选最优质量

情景	Q_0	θ	$Q_{10^{19}}^*$	$Q_{10^{22}}^*$	$Q_{10^{24}}^*$
基准	0.0789	0.5	0.546	0.968	1.000
Q_0 降 20%	0.0631	0.5	0.546	0.968	1.000
Q_0 升 20%	0.0947	0.5	0.545	0.968	1.000
$\theta = 0.2$	0.0789	0.2	0.417	0.823	1.000
$\theta = 0.8$	0.0789	0.8	0.623	1.000	1.000

Q_0 上下扰动 20% 时，三档预算的候选质量几乎不变：低预算约 0.545–0.546，中预算约 0.968，高预算均触及 1。因此当前三档结果不支持“基线质量扰动显著改变最优配置”的说法；这也没有检验连续预算转移点的稳健性。相比之下，固定 Q_0 而将 θ 从 0.2 改为 0.8，低预算质量由 0.417 升至 0.623，中预算由 0.823 升至边界 1，高预算均为 1。不同 θ 对应不同损失函数，不能把情景间损失值的差异解释成模型性能提升。

冲突降权因子 $\delta \in \{0.3, 0.5, 0.7, 1.0\}$ 的扫描显示，前三档域级排序与原排序的 Kendall 相关为 0.905，存在局部换位。三型质量成本在低预算下也明显分化：指数、幂、对数型的候选 Q 分别约为 0.546、0.446、1.000；成本函数的选择比 Q_0 小幅扰动更影响该档配置。能力前沿的三档斜率系数决定情景间差异，每档内的自助区间只覆盖趋势估计和月度残差，均不包含情景选择或结构性模型误差。

8.3 适用范围

经典律的直接拟合支撑范围约为参数量 0.07–12、数据量至 300（均以 10^9 计）；问题三的高预算解已超出该范围，其损失是公式外推。质量指数与能力前沿斜率系数均为高敏感假设，替代率、转移点及远期能力水平不宜作确定性解读。前沿仅有 10 个有效月度点，短期回测也未证明趋势模型优于简单基线。

9 模型评价、改进与推广

9.1 模型优点

本文四问覆盖从数据刻画到能力预测的主要环节，但数值链条仍有断点：问题一的域级质量用于问题三的质量成本基线；配比贡献尚未进入广义律的数值计算，标度律参数服务于问题三的优化目标；损失到能力的桥接是单独拟合的探索性映射。质量以有效数据量方式进入并保证 $Q = 1$ 退化，使广义律在纳入新因素的同时不破坏经典律的可靠性。优化部分先用 KKT 给出结构、再用多起点数值搜索可行解，并以份额导数峰值给出可判定的结构性转移定义，避免了只定性说“变了”。全过程对数据与假设的冲突（半合成质量标度的方向异常、前沿窗口规模的负增量）均如实呈现而非改数迎合。

9.2 模型不足与改进方向

其一，质量放大指数无法从唯一一组半合成数据识别，其经验拟合落在边界且口径与部署质量不同，故下游采用了反映“质量有益”前提的取值并做敏感性；若能获得大规模真实的质量–损失联合观测，可把该指数从假设升级为估计。其二，配比没有进入当前标度

律数值计算，也未联立优化 17 维配比；改进可把配比加入决策变量并以投影梯度处理单纯形约束，代价是转移分析的可解释性下降。其三，前沿预测依赖能力斜率情景假设，并未估计算力增速到能力斜率的映射，改进可引入更细的算力供给模型或以真实新发布模型滚动校正分位带。

9.3 推广

广义标度律的“有效数据量”框架可推广到其它可归一化的数据属性（如去重率、领域纯度），只需保证满质量时退化为经典形式。问题三的部分算力约束优化可推广到含推理成本或多阶段训练的预算结构，KKT 加多起点的求解范式与结构性转移判据同样适用。问题四控制规模的贡献分解与分层桥接可推广到其它以基准评分度量的技术演进分析。这些推广均须在目标场景重新标定参数，其适用性以数据支撑范围为界。

10 结论

本文围绕算力约束下提升大语言模型能力的资源配置，建立了四段递进模型并以真实数据求解。数据刻画阶段得到域级综合质量（中位数 0.079）、约 4.96% 的质量冲突及其稳健消解、以及跨尺度排序相关较高、但绝对损失预测失准的配比-损失关系；标度律阶段以近乎完美的拟合确定经典律参数，并以质量增强有效数据量构建满足退化条件的广义律，解析给出质量对规模的替代率；优化阶段在三档预算下求得多起点搜索的最低损失可行配置，损失随预算单调趋近不可约损失 1.69，并在预算约 2.5×10^{22} 处识别出质量投入的结构性转移，解析给出注意力临界上下文 3×10^4 ；预测阶段给出规模与年份项的描述性回归分解，建立损失到基准的分层桥接，并在三档能力斜率假设下给出前沿预测分位带。上述结论为在有限算力下权衡规模、数据、质量与上下文长度提供了可复核的定量依据。

参考文献

- [1] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020. DOI: 10.48550/arXiv.2001.08361.
- [2] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models. arXiv:2203.15556, 2022. DOI: 10.48550/arXiv.2203.15556.
- [3] Liu Q, Zheng X, Muennighoff N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training. arXiv:2407.01492, 2024. DOI: 10.48550/arXiv.2407.01492.
- [4] Xie S M, Pham H, Dong X, et al. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining. arXiv:2305.10429, 2023. DOI: 10.48550/arXiv.2305.10429.
- [5] Penedo G, Kydlíček H, Ben Allal L, et al. The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale. arXiv:2406.17557, 2024. DOI: 10.48550/arXiv.2406.17557.
- [6] Shen Z, Tao T, Ma L, et al. SlimPajama-DC: Understanding Data Combinations for LLM Training. arXiv:2309.10818, 2023. DOI: 10.48550/arXiv.2309.10818.
- [7] Xie S M, Santurkar S, Ma T, Liang P. Data Selection for Language Models via Importance Resampling. arXiv:2302.03169, 2023. DOI: 10.48550/arXiv.2302.03169.
- [8] Wettig A, Gupta A, Malik S, Chen D. QuRating: Selecting High-Quality Data for Training Language Models. arXiv:2402.09739, 2024. DOI: 10.48550/arXiv.2402.09739.
- [9] Gao L, Biderman S, Black S, et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling. arXiv:2101.00027, 2020. DOI: 10.48550/arXiv.2101.00027.
- [10] Biderman S, Schoelkopf H, Anthony Q, et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. arXiv:2304.01373, 2023. DOI: 10.48550/arXiv.2304.01373.
- [11] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners. arXiv:2005.14165, 2020. DOI: 10.48550/arXiv.2005.14165.
- [12] Wei J, Tay Y, Bommasani R, et al. Emergent Abilities of Large Language Models. arXiv:2206.07682, 2022. DOI: 10.48550/arXiv.2206.07682.
- [13] Schaeffer R, Miranda B, Koyejo S. Are Emergent Abilities of Large Language Models a Mirage? arXiv:2304.15004, 2023. DOI: 10.48550/arXiv.2304.15004.
- [14] Liang P, Bommasani R, Lee T, et al. Holistic Evaluation of Language Models. arXiv:2211.09110, 2022. DOI: 10.48550/arXiv.2211.09110.
- [15] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding. arXiv:2009.03300, 2020. DOI: 10.48550/arXiv.2009.03300.
- [16] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models. arXiv:2302.13971, 2023. DOI: 10.48550/arXiv.2302.13971.
- [17] Le Scao T, Fan A, Akiki C, et al. BLOOM: A 176B-Parameter Open-Access Multilingual Language Model. arXiv:2211.05100, 2023. DOI: 10.48550/arXiv.2211.05100.
- [18] Koenker R, Hallock K F. Quantile Regression. *Journal of Economic Perspectives*, 2001, 15(4): 143–156. DOI: 10.1257/jep.15.4.143.

- [19] Boggs P T, Tolle J W. Sequential Quadratic Programming. *Acta Numerica*, 1995, 4: 1–51. DOI: 10.1017/S0962492900002518.
- [20] Chen C H. A Novel Multi-Criteria Decision-Making Model for Building Material Supplier Selection Based on Entropy-AHP Weighted TOPSIS. *Entropy*, 2020, 22(2): 259. DOI: 10.3390/e22020259.

A 附录：参数取值与求解步骤

A.1 题面给定常量与成本函数

问题三的算力构成与质量成本参数按题面原样载入，列于表 8。

表 8 题面给定常量与三型质量成本参数

物理量	取值	说明
注意力系数 η	2×10^{-4}	作用于三者乘积 $N DL_{\text{ctx}}$
Chinchilla 系数	6	每参数每 token 的训练算力
注意力临界上下文	3×10^4	由 $6/\eta$ 解析得到
指数型 $g(Q)$	$10^7 e^{6Q}$	高质量极昂贵
幂型 $g(Q)$	$5 \times 10^9 Q^4$	高质量成本居中
对数型 $g(Q)$	$2 \times 10^9 \ln(1 + 10Q)$	高质量相对可得
三档预算 C	$10^{19}, 10^{22}, 10^{24}$	FLOPs
基线质量 Q_0	0.079	问题一域级质量中位数

三型质量成本函数在中高预算下给出相近的最优质量，但在低预算档因高质量的经济性不同而分化，这是问题三比较成本函数选择影响的依据（表 8）。

A.2 优化求解步骤

问题三的数值求解按以下顺序执行：（1）以对数尺度 $(\ln N, \ln D, Q)$ 为变量，从类 Chinchilla 平衡点附近取不少于 20 个随机初值；（2）在每个初值上以序列二次规划迭代，预算式作为非线性不等式约束、质量域作为界约束；（3）求解器按自身终止条件停止；程序没有另行计算一阶最优性残差；（4）在全部收敛且可行的候选解中取目标最小者，作为多起点搜索结果而非全局最优证明；（5）对预算对数区间连续扫描重复上述过程，数值差分得算力份额对预算对数的导数，其峰值即结构性转移点。最优解写出前重代入预算式核验其可行性。

A.3 关于人工智能工具的使用说明

本文写作过程中使用了通用大语言模型辅助进行文字润色与 LaTeX 排版检查；全部数据处理、模型建立、求解计算与结果均由作者编写的程序在真实附件数据上完成，数值结论未由语言模型生成。

B 附录：核心算法代码摘录

下列代码直接摘自随文提交的四个计算脚本，展示模型计算的关键步骤；批量数据处理、绘图、结果写出和重复性检查等实现细节不在纸质附录中展开。完整可运行程序见电子材料的 `code/problem1.py-code/problem4.py`，参数定义见 `code/params.py`。

B.1 问题一：质量评分与配比回归

```
1 def fit_normalization_reference(df, indicators):
2     """只在 A1 拟合缺失填充值和 Min-Max 范围，供扩展集沿用。"""
3     reference = {}
4     for ind in indicators:
5         x = df[ind].astype(float)
6         median = float(x.median())
7         x = x.fillna(median)
8         reference[ind] = {"median": median, "min": float(x.min()),
9                           "max": float(x.max())}
10    return reference
11
12
13 def direction_unify_normalize(df, indicators, reference=None):
14     """按 A1 参考范围归一化；扩展集超出参考范围的值截到 [0,1]。"""
15     if reference is None:
16         reference = fit_normalization_reference(df, indicators)
17     R = pd.DataFrame(index=df.index)
18     for ind in indicators:
19         x = df[ind].astype(float)
20         ref = reference[ind]
21         x = x.fillna(ref["median"])
22         lo, hi = ref["min"], ref["max"]
23         if hi - lo < 1e-12:
24             norm = pd.Series(0.5, index=x.index)
25         else:
26             norm = ((x - lo) / (hi - lo)).clip(0.0, 1.0)
27         if ind in NEG_INDICATORS:
28             norm = 1.0 - norm
29         R[ind] = norm
30    return R
31
32
33 def entropy_weights(R):
34     """式3 熵权法：信息熵  $e_j$  与权重  $w_j$ 。R 为 (n,22) 归一化矩阵，非负。"""
35     Rm = R.values.astype(float)
36     n = Rm.shape[0]
37     # 避免全零列
38     col_sum = Rm.sum(axis=0)
39     col_sum[col_sum < 1e-12] = 1e-12
40     P = Rm / col_sum #  $p_{ij} = r_{ij} / \sum_i r_{ij}$ 
41     P = np.clip(P, 1e-12, None)
42     e = -1.0 / np.log(n) * (P * np.log(P)).sum(axis=0) # 信息熵  $e_j$ 
43     d = 1.0 - e # 差异系数
44     w = d / d.sum() # 权重  $w_j$ 
```

```
45 return w, e
```

代码 1 主样本归一化基准与熵权计算

```
1 def compute_Q(R, w):
2     """式4: 样本级综合质量  $Q_i = \sum_j w_j r_{ij}$  in (0,1]。"""
3     q = R.values.astype(float) @ w
4     # 映射到 (0,1]: 线性缩放后加极小正偏移保证 >0
5     q = np.clip(q, 1e-6, 1.0)
6     return q
```

代码 2 综合质量评分

```
1 def _q1_mixture(results):
2     """式6: 17域配比 p -> 13域 val_loss, 对数域带单纯形约束线性回归 + LightGBM 对
3     照。"""
4     mix = u.read_csv_checked("A_data_value/regmix_tables/train_mixture_1m.csv",
5                             512)
6     loss = u.read_csv_checked("A_data_value/regmix_tables/train_pile_loss_1m.csv",
7                             512)
8     mix_cols = [c for c in mix.columns if c.startswith("train_the_pile_")]
9     loss_cols = [c for c in loss.columns if c.startswith("metric/")]
10    P = mix[mix_cols].values.astype(float) # (512,17) 配比
11    # 归一化确保单纯形 (数据本就~1, 千分位舍入)
12    P = P / P.sum(axis=1, keepdims=True)
13    assert np.allclose(P.sum(axis=1), 1.0, atol=1e-3), "配比未满足单纯形"
14
15    coefs = {}
16    r2_train = {}
17    for lc in loss_cols:
18        y = np.log(loss[lc].values.astype(float)) # 对数域 ln L
19        dom = lc.replace("metric/the_pile_", "").replace("_val_loss", "")
20        # 带截距的线性回归 ln L = a + b · p (p 已在单纯形上)
21        X = np.hstack([np.ones((len(P), 1)), P])
22        beta, *_ = np.linalg.lstsq(X, y, rcond=None)
23        yhat = X @ beta
24        # 截距与单纯形列线性相关: 统一为 sum(b)=0 的可识别对比编码。
25        b_mean = float(beta[1:].mean())
26        beta[0] += b_mean
27        beta[1:] -= b_mean
28        assert np.allclose(X @ beta, yhat, atol=1e-10)
29        ss_res = ((y - yhat) ** 2).sum()
30        ss_tot = ((y - y.mean()) ** 2).sum()
31        r2 = 1 - ss_res / ss_tot if ss_tot > 0 else 0.0
32        coefs[dom] = {"intercept": float(beta[0]),
33                    "b": {mix_cols[i].replace("train_the_pile_", ""): float(beta[i
34                    + 1])
35                    for i in range(17)}}}
```

代码 3 单纯形配比回归及可识别系数编码

B.2 问题二：经典与广义标度律

```

1 def classic_model(params, N, D):
2     """经典标度律  $L=E+A N^{-\alpha}+B D^{-\beta}$  (式7) 。"""
3     E, A, alpha, B, beta = params
4     return E + A * np.power(N, -alpha) + B * np.power(D, -beta)
5
6
7 def _residual_log_huber(params, N, D, L):
8     """对数域残差 (least_squares 的 loss='huber' 在外层施加) 。式8。"""
9     pred = classic_model(params, N, D)
10    pred = np.clip(pred, 1e-6, None)
11    return np.log(L) - np.log(pred)
12
13
14 def fit_classic(N, D, L):
15     """对数域 Huber-NLS 多起点拟合经典律。返回最优参数与 R2。"""
16     rng = np.random.default_rng(SEED)
17     best = None
18     # 多起点: alpha,beta 网格初值 + E,A,B 合理初值
19     for alpha0 in [0.1, 0.2, 0.34, 0.5]:
20         for beta0 in [0.1, 0.28, 0.4]:
21             x0 = [min(L) * 0.9, 0.5, alpha0, 1.0, beta0]
22             try:
23                 res = least_squares(
24                     _residual_log_huber, x0, args=(N, D, L),
25                     loss="huber", f_scale=0.1,
26                     bounds=([0.0, 0.0, 0.01, 0.0, 0.01],
27                             [min(L) + 1e-6, 50, 1.0, 50, 1.0]),
28                     max_nfev=20000)
29                 pred = classic_model(res.x, N, D)
30                 ss_res = np.sum((L - pred) ** 2)
31                 ss_tot = np.sum((L - L.mean()) ** 2)
32                 r2 = 1 - ss_res / ss_tot
33                 if best is None or r2 > best["r2"]:
34                     best = {"params": res.x, "r2": float(r2),
35                             "cost": float(res.cost)}
36             except Exception:
37                 continue
38     return best

```

代码 4 经典标度律的对数域稳健拟合

```

1 def generalized_model(params, N, D, Q):
2     """广义标度律  $L=E+A N^{-\alpha}+B (Q^{\theta} D)^{-\beta}$  (式9) 。Q=1 退化经典。"""
3     E, A, alpha, B, beta, theta = params
4     # 质量增强有效数据量  $Q_{\text{eff}} = Q^{\theta} D$  (Q=1 时退化经典)
5     Q_eff = np.power(Q, theta) * D # 等价  $Q^{\theta} D$ 
6     Q_eff = np.clip(Q_eff, 1e-9, None)
7     return E + A * np.power(N, -alpha) + B * np.power(Q_eff, -beta)
8
9
10 def _residual_gen_log(params, N, D, Q, L):
11     pred = generalized_model(params, N, D, Q)

```

```

12     pred = np.clip(pred, 1e-6, None)
13     return np.log(L) - np.log(pred)
14
15
16 def fit_generalized(N, D, Q, L, classic_params, theta_bounds=(-10.0, 10.0)):
17     """在经典参数基础上新增 theta, 用 B6-B8 拟合。theta 符号由数据决定（默认自由）。
18     """
19     E0, A0, a0, B0, b0 = classic_params
20     lo_t, hi_t = theta_bounds
21     best = None
22     for theta0 in [-2.0, -0.5, 0.1, 0.5, 1.0, 2.0]:
23         if not (lo_t <= theta0 <= hi_t):
24             theta0 = 0.5 * (lo_t + hi_t)
25         # E 上界放宽: B6-B8 的 loss 尺度与 B1 不同 (Q_setpoint 重标定损失区间)
26         Lmax = float(np.max(L))
27         x0 = [min(L) * 0.5, A0, a0, B0, b0, theta0]
28         try:
29             res = least_squares(
30                 _residual_gen_log, x0, args=(N, D, Q, L),
31                 loss="huber", f_scale=0.1,
32                 bounds=([0.0, 0.0, 0.01, 0.0, 0.01, lo_t],
33                        [Lmax, 200, 1.5, 500, 1.5, hi_t]),
34                 max_nfev=30000)
35             pred = generalized_model(res.x, N, D, Q)
36             ss_res = np.sum((L - pred) ** 2); ss_tot = np.sum((L - L.mean()) ** 2)
37             r2 = 1 - ss_res / ss_tot
38             if best is None or r2 > best["r2"]:
39                 best = {"params": res.x, "r2": float(r2), "cost": float(res.cost)}
40         except Exception:
41             continue
42     return best

```

代码 5 广义标度律及质量指数拟合

B.3 问题三：预算约束下的资源配置

```

1 def loss_gen(N, D, Q, params):
2     """广义标度律  $L=E+A N^{-\alpha}+B (Q^{\theta} D)^{-\beta}$  (N,D in 1e9 单位) 。"""
3     E, A, alpha, B, beta, theta = params
4     # 质量增强有效数据量  $Q_{\text{eff}} = Q^{\theta} D$ 
5     Q_eff = np.power(Q, theta) * D # 等价  $Q^{\theta} D$ 
6     return E + A * np.power(N, -alpha) + B * np.power(Q_eff, -beta)
7
8
9 def compute_total(N, D, Q, Q0, Lctx, gkind):
10     """三部分算力和 (FLOPs) , N,D in 1e9 单位。返回 (C_tot, C_train, C_Q, C_attn)。
11     """
12     Na, Da = N * UNIT_SCALE, D * UNIT_SCALE
13     C_train = 6.0 * Na * Da
14     C_Q = Da * max(g_Q(Q, gkind) - g_Q(Q0, gkind), 0.0)
15     C_attn = ETA * Na * Da * Lctx
16     return C_train + C_Q + C_attn, C_train, C_Q, C_attn

```

```

16
17
18 def solve_budget(C, Q0, params, Lctx, gkind, n_starts=20):
19     """SLSQP 多起点求 min L s.t. C_tot<=C。对数变量(lnN,lnD)+Q。"""
20     rng = np.random.default_rng(SEED)
21     E = params[0]
22
23     def unpack(x):
24         return np.exp(x[0]), np.exp(x[1]), x[2]
25
26     def obj(x):
27         N, D, Q = unpack(x)
28         return loss_gen(N, D, np.clip(Q, 1e-4, 1.0), params)
29
30     def con_fun(x):
31         N, D, Q = unpack(x)
32         Ct, *_ = compute_total(N, D, np.clip(Q, 1e-4, 1.0), Q0, Lctx, gkind)
33         return (C - Ct) / C # >=0 可行 (归一化)
34
35     nlc = NonlinearConstraint(con_fun, 0.0, np.inf)
36     bounds = [(np.log(1e-3), np.log(1e5)), (np.log(1e-2), np.log(1e6)), (1e-3,
37         1.0)]
38
39     best = None
40     # Chinchilla 平衡点附近初值: 6 N D 1e18 ~ 0.9 C
41     ND_budget = 0.9 * C / (6.0 * UNIT_SCALE ** 2)
42     for s in range(n_starts):
43         if s == 0:
44             n0 = d0 = np.sqrt(max(ND_budget, 1e-6))
45             q0i = min(max(Q0 * 1.5, 0.1), 1.0)
46         else:
47             frac = rng.uniform(0.2, 0.8)
48             n0 = np.sqrt(max(ND_budget, 1e-6)) * np.exp(rng.uniform(-2, 2))
49             d0 = max(ND_budget / max(n0, 1e-9), 1e-3)
50             q0i = rng.uniform(0.05, 1.0)
51         x0 = [np.log(np.clip(n0, 1e-3, 1e5)), np.log(np.clip(d0, 1e-2, 1e6)),
52             np.clip(q0i, 1e-3, 1.0)]
53         try:
54             res = minimize(obj, x0, method="SLSQP", bounds=bounds,
55                 constraints=[nlc],
56                 options={"maxiter": 500, "ftol": 1e-12})
57             if not res.success and res.status not in (0, 9):
58                 continue
59             N, D, Q = unpack(res.x)
60             Q = np.clip(Q, 1e-4, 1.0)
61             Ct, Ctr, CQ, Cat = compute_total(N, D, Q, Q0, Lctx, gkind)
62             if Ct > C * (1 + 1e-6): # 越预算的解丢弃
63                 continue
64             Lval = loss_gen(N, D, Q, params)
65             if best is None or Lval < best["L"]:
66                 best = {"N": float(N), "D": float(D), "Q": float(Q), "L": float(
67                     Lval),

```

```

66         "C_tot": float(Ct), "C_train": float(Ctr), "C_Q": float(CQ),
67         "C_attn": float(Cat), "util": float(Ct / C)}
68     except Exception:
69         continue
70     return best

```

代码 6 损失、物理算力与多起点约束求解

B.4 问题四：能力前沿与情景预测

```

1  # 前沿：逐时间窗 P90 上包络
2  d_open = d_open[d_open["year"].notna()]
3  ymin, ymax = d_open["year"].min(), d_open["year"].max()
4  # 月度分箱前沿
5  bins = np.arange(np.floor(ymin), np.ceil(ymax) + 1 / 12, 1 / 12)
6  frontier_t, frontier_cap = [], []
7  for i in range(len(bins) - 1):
8      m = (d_open["year"] >= bins[i]) & (d_open["year"] < bins[i + 1])
9      if m.sum() >= 2:
10         frontier_t.append(float((bins[i] + bins[i + 1]) / 2))
11         frontier_cap.append(float(d_open[m]["Cap"].quantile(0.9)))
12 frontier_t = np.array(frontier_t); frontier_cap = np.array(frontier_cap)

```

代码 7 月度能力前沿的构造

```

1  # 线性趋势 + 残差自助重拟合, 外推 12/24 月
2  rng = np.random.default_rng(SEED)
3  t_last = frontier_t.max()
4  # 情景=相对历史算力增速的比例 (0停滞/0.5放缓/1维持历史增速), 显式声明
5  scenarios = {"low": 0.0, "mid": 0.5, "high": 1.0}
6  # 历史前沿线性斜率
7  if len(frontier_t) < 4:
8      raise ValueError("有效月度前沿点不足, 不能进行趋势自助拟合")
9  A = np.vstack([frontier_t - t_last, np.ones_like(frontier_t)]).T
10 slope, intercept = np.linalg.lstsq(A, frontier_cap, rcond=None)[0]
11 fitted = A @ np.array([slope, intercept])
12 resid = frontier_cap - fitted
13 # 扩展窗口一步 (月) 滚动检验; 与“末值延续”基线对照。
14 backtest_pred, backtest_naive, backtest_obs = [], [], []
15 for i in range(5, len(frontier_t)):
16     A_i = np.vstack([frontier_t[:i] - frontier_t[i - 1],
17                     np.ones(i)]).T
18     slope_i, anchor_i = np.linalg.lstsq(A_i, frontier_cap[:i], rcond=None)[0]
19     backtest_pred.append(anchor_i + slope_i * (frontier_t[i] - frontier_t[i - 1]))
20     backtest_naive.append(frontier_cap[i - 1])
21     backtest_obs.append(frontier_cap[i])
22 if not backtest_obs:
23     raise ValueError("有效月度前沿点不足, 不能进行一步滚动检验")
24 bt_pred = np.asarray(backtest_pred)
25 bt_naive = np.asarray(backtest_naive)
26 bt_obs = np.asarray(backtest_obs)
27 backtest = {

```

```

28     "protocol": "expanding-window one-step-ahead; initial 5 monthly points",
29     "n_forecasts": int(len(bt_obs)),
30     "trend_mae": float(np.mean(np.abs(bt_pred - bt_obs))),
31     "trend_rmse": float(np.sqrt(np.mean((bt_pred - bt_obs) ** 2))),
32     "trend_bias": float(np.mean(bt_pred - bt_obs)),
33     "last_value_mae": float(np.mean(np.abs(bt_naive - bt_obs))),
34 }
35 print(f"[Q4] 一步滚动检验 n={backtest['n_forecasts']}: 趋势 MAE={backtest['trend_mae']:.2f}, "
36       f"末值延续 MAE={backtest['last_value_mae']:.2f}")
37 n_boot = 2000
38 boot_slope = np.empty(n_boot)
39 boot_noise = np.empty(n_boot)
40 for i in range(n_boot):
41     sampled = rng.choice(resid, size=len(resid), replace=True)
42     boot_slope[i] = np.linalg.lstsq(A, fitted + sampled, rcond=None)[0][0]
43     boot_noise[i] = rng.choice(sampled)
44
45 frontier_pred = {}
46 for sc, rc in scenarios.items():
47     preds = {}
48     for months in [12, 24]:
49         dt = months / 12.0
50         t_target = t_last + dt
51         # 情景: 算力放缓使斜率按 rc 缩放 (rc=1 维持历史增速, rc=0 停滞)
52         # 用观测末值作锚; 斜率不确定性随外推期限放大。
53         boot = np.clip(frontier_cap[-1] + rc * boot_slope * dt + boot_noise,
54                        0.0, 100.0)
55         preds[f"{months}m"] = {"P10": float(np.percentile(boot, 10)),
56                                "P50": float(np.percentile(boot, 50)),
57                                "P90": float(np.percentile(boot, 90)),
58                                "t_target": float(t_target)}
59     frontier_pred[sc] = preds

```

代码 8 一步回测与残差自助情景预测